Tampereen yliopisto

Riku Korpiaho

HALLUSINAATIOISTA HALLINTAAN: KOKEELLISEN YHDISTELMÄTEKOÄLYJÄRJESTELMÄN KEHITTÄMINEN JA TESTAUS TERVEYDENHUOLLON KONTEKSTISSA

Diplomityö
Lääketieteen ja terveysteknologian tiedekunta (MET)
Tarkastaja: Alpo Värri
Tarkastaja: Joni Kämäräinen
Tarkastaja: Petri Näppi
Huhtikuu 2026

TIIVISTELMÄ

Riku Korpiaho : Hallusinaatioista hallintaan: kokeellisen yhdistelmätekoälyjärjestelmän kehittäminen ja testaus terveydenhuollon kontekstissa
Diplomityö
Tampereen yliopisto
Bioteknologian ja biolääketieteen tekniikan DI-ohjelma
Huhtikuu 2026

Laskennallisen älykkyyden evoluutio on siirtynyt symbolisesta logiikasta ja staattisista sääntöjärjestelmistä kohti stokastista todennäköisyyslaskentaa, mikä on mahdollistanut vakavasti otettavan kielellisen prosessoinnin toteuttamisen biologisista rakenteista riippumattomasti. Tämä paradigman vaihdos on kuitenkin synnyttänyt uusia, systeemisiä riskejä, kuten mallien koulutusaineistojen läpinäkymättömyyden (*black box*), kielimallien taipumuksen faktuaalisiin hallusinaatioihin sekä niitä käyttävien ihmisten kognitiivisen automaatioharhan (*automation bias*). Erityisesti terveydenhuollon kaltaisilla yhteiskunnallisesti kriittisillä aloilla nämä tekniset epävarmuudet tekevät sääntelystä ja valvonnasta ehdottoman välttämättömyyden.

Tutkimuksessa kehitettiin kokeellinen yhdistelmätekoälyjärjestelmä, joka hyödyntää arkkitehtuuriltaan RAG-analyysialustaa (*Retrieval-Augmented Generation*) helpottamaan sääntelyaineistojen, erityisesti ISO-standardiversioiden, välisten muutosten analysointia. Ratkaisu rakennettiin tiukalla "*Local-First*" -arkkitehtuurilla, jossa kaikki kielimallien ja neuroverkkojen tietojenkäsittely tapahtuvat paikallisessa infrastruktuurissa ilman ulkoisia pilvipalveluita. Tämä valinta tehtiin vastaamaan terveydenhuollon datan ja GDPR:n asettamiin tiukkoihin tietosuojavaatimuksiin. Alustan kognitiivinen prosessointikerros hyödyntää tiheän ja harvan haun yhdistävää hybridihakua, ristiinkoodaajia (*cross-encoder*) uudelleenjärjestämiseen, generatiivisia kielimalleja sekä suunnatun loogisen päättelyn (Directional NLI) koneoppimismalleja klausuulien välisten suhteiden tunnistamiseen.

Tulokset osoittavat, että pelkkä matemaattinen vektorisimilaarisuus on riittämätön sääntelytekstien analyysiin, sillä se on altis leksikaaliselle sokeudelle merkittävien normatiivisten muutosten kohdalla geneerisessä, hyvin samankaltaisessa aineistossa. Tämä ratkaistiin onnistuneesti hybridimallilla, jossa suunnatun loogisen päättelyn (NLI) malli kykeni tunnistamaan asymmetriset kattavuussuhteet ja vaatimusten asiasisällölliset supistumiset. Paikallinen infrastruktuuri osoittautui suorituskyvyltään riittäväksi: standardiaineiston analysointi ja raportointi kesti keskitason grafiikkaprosessorilla noin 13 minuuttia. Kvalitatiivisen laajan *human-in-a-loop* validoinnin lisäksi järjestelmän teknistä suorituskykyä arvioitiin kymmenen klausuulin satunnaisotoksella, jossa kohdistusalgoritmi saavutti otoksella virheettömän tarkkuuden, löytäen oikeat parit sekä tunnistaen puuttuvan vastineen (True Negative).

Johtopäätöksenä todetaan, että automatisoidulla RegTech-alustalla voidaan merkittävästi tehostaa sääntelytaakan hallintaa muuttamalla asiantuntijan rooli mekaanisesta tiedonhakijasta tulosten validoijaksi. Kehitetty dokumenttiagnostinen arkkitehtuuri vastaa terveydenhuollon tiukkoihin tietosuojavaatimuksiin mahdollistamalla arkaluonteisen aineiston prosessoinnin täysin ilman ulkoisia infrastruktuurillisia riippuvuuksia tai tietoturvaongelmia.

Avainsanat: Tekoäly, neuroverkot, design-science, regulaatio, terveydenhuolto, RAG-arkkitehtuuri, LLM, koneoppiminen, tietosuoja

Tämän julkaisun alkuperäisyys on tarkastettu Turnitin Originality Check -ohjelmalla.

ABSTRACT

Riku Korpiaho : From hallucinations to control: development and testing of an experimental compound artificial intelligence system in a healthcare context
Master of Science (MSc)
Tampere University
Master's Programme in Biotechnology and Biomedical Engineering
April 2026

The evolution of computational intelligence has transitioned from symbolic logic and static rule-based systems toward stochastic probability calculus, enabling the implementation of credible linguistic processing independent of biological structures. However, this paradigm shift has introduced new systemic risks, such as the opacity of model training datasets (black box), the tendency of language models toward factual hallucinations, and the cognitive automation bias of those utilizing them. Particularly in societally critical sectors like healthcare, these technical uncertainties make regulation and oversight an absolute necessity.

This study developed an experimental compound AI system utilizing a Retrieval-Augmented Generation (RAG) analysis platform architecture to facilitate the analysis of changes between regulatory materials, specifically ISO standard versions. The solution was built upon a strict "Local-First" architecture, where all data processing of the language models and neural networks occurs within local infrastructure, completely independent of external cloud services. This architectural choice was made to comply with the stringent data protection requirements mandated by healthcare data and the GDPR. The platform's cognitive processing layer employs a hybrid search combining dense and sparse retrieval, cross-encoders for reranking, generative language models, and directional Natural Language Inference (NLI) machine learning models to identify relationships between clauses.

The results indicate that pure mathematical vector similarity is insufficient for the analysis of regulatory texts, as it is prone to lexical blindness regarding significant normative changes within generic, highly similar datasets. This limitation was successfully resolved using a hybrid model, where the directional NLI model was capable of identifying asymmetric coverage relationships and substantive reductions in requirements. The local infrastructure proved sufficient in performance: the full analysis and reporting of the standard dataset took approximately 13 minutes using a mid-range GPU. In addition to extensive qualitative human-in-a-loop validation, the system’s technical performance was evaluated using a random sample of ten clauses. In this sample, the alignment algorithm achieved flawless accuracy, successfully identifying all correct pairs as well as the absence of a counterpart (True Negative).

In conclusion, automated RegTech platforms can significantly enhance the management of the regulatory burden by transforming the expert's role from a mechanical data seeker to a validator of results. The developed document-agnostic architecture meets the strict data protection requirements of the healthcare sector by enabling the processing of sensitive materials entirely without external infrastructural dependencies or data security vulnerabilities.

Keywords: Artificial Intelligence, neural networks, design science, regulation, healthcare, RAG architecture, LLM, machine learning, data protection

The originality of this thesis has been checked using the Turnitin Originality Check service.

TEKOÄLYN KÄYTTÖ OPINNÄYTTEESSÄ

Opinnäytteessäni on käytetty tekoälysovelluksia:

☐ Ei
☒ Kyllä

Ilmoitukseni mukaan olen käyttänyt opinnäytteessäni tutkielmaprosessin aikana seuraavia tekoälysovelluksia: Gemini Pro 3.1, Cursor IDE, Antigravity IDE, Claude 4.5 Sonnet

Tekoälysovellusten nimet ja versiot: Gemini Pro 3.1, Cursor IDE, Antigravity IDE, Claude 4.5 Sonnet

Käyttötarkoitus: Tekoälyä on hyödynnetty täydentävänä työkaluna, joka tukee omaa ajattelua, oppimista ja osaamistavoitteiden saavuttamista parhaalla mahdollisella tavalla. Käsitteellinen tuki eli termien selkeytys ja koherenssi, kirjoitusprosessin aiheiden *brainstorming*, apuna relevanttien lähteiden tutkimiseen varsinkin epäselvissä tapauksissa sekä formaalin koodaamisen syntaksin hallinta ja agenttipohjaisten toimintojen automatisointi tutkielman osana kehitettävää RAG-alustaa varten. Oppimisen lisäksi tekoälyllä hahmoteltiin kuvia työhön.

Osiot, joissa tekoälyä on käytetty: Kaikissa, koska *brainstorming* ja aiheiden sparraaminen kattaa kaikki alueet.

Olen tietoinen siitä, että olen täysin vastuussa koko opinnäytteeni sisällöstä, mukaan lukien osat, joissa on hyödynnetty tekoälyä, ja hyväksyn vastuun mahdollisista eettisten ohjeiden rikkomuksista.

ALKUSANAT

Haluan osoittaa ensimmäiset kiitokseni työn ensisijaiselle tarkastajalle, tutkimusjohtaja Alpo Värrille. Hänen laaja asiantuntemuksensa tekoälyn sääntelyn ja standardien parissa on ollut korvaamatonta työn suuntaamisessa. Erityisesti haluan kiittää häntä työhön saadun tuen lisäksi antoisista keskusteluista aiheen parissa sekä hänen kannatuksestaan päätökselleni poiketa valtavirrasta ja kirjoittaa työ rikkaalla suomen kielellä. Kiitos kuuluu myös professori Joni Kämäräiselle voimaa antavista kommenteista.

Työ on toteutettu tiiviissä yhteistyössä Taipuva Consulting Oy:n kanssa. Kiitän Petri Näppiä hänen tarjoamastaan teknisestä tuesta, arvokkaista huomioistaan työn kehitysvaiheessa sekä ympäristöjen järjestämisestä, mitkä olivat edellytys kehitystyön onnistumiselle. Haluan kiittää yhtiön operatiivista johtajaa Tapio Tuomolaa (COO) osoittamastaan luottamuksesta suosittaa minut tämän työn tekijäksi ja tekoälytyökalun rakentajaksi vaativiin älykkäiden teknologioiden tarpeisiin. Samoin kiitokset kuuluvat toimitusjohtaja Pasi Aholalle (CEO) sujuvasta yhteydenpidosta, erittäin myönteisistä kommenteista prosessin aikana.

Lisäksi osoitan kiitokseni ABB:lle luottamuksesta, mikä mahdollisti motivaation kasvamisen sille tasolle, että ohjelmasta rakennettiin lähtökohtaisesti modulaarinen ja skaalautuva tulevaisuuden tarpeisiin.

Haluan myös kiittää syvästi Teknologiateollisuuden 100-vuotissäätiötä ja kehityspäällikköä Marianna Jokilaa apurahasta, joka työlle myönnettiin osana tekoälytutkimuksien kehittämistä Teknologiateollisuus ry:n jäsenyrityksen kanssa. Tämä stimuloi vahvasti varsinkin työkalun rakentamista, jonka rakentaminen vaati myös rahallisia resursseja ajallisten lisäksi kuten lisenssien ostamista.

Viimeisenä kiitän ystäviäni, jotka ovat simuloineet ja ruokkineet mielikuvitustani neurotieteen ja tekoälytutkimuksen teemoissa, erottamattomana osana prosessia. Edelleen kiitän lähipiiriäni, puolisoani, lastani sekä yrityskumppaneitani tuesta ja kannustavasta ilmapiiristä liittyen tutkielman kirjoittamiseen. Sekä kaikkien ymmärryksestä siihen, kuinka paljon aikaa ja keskittymistä tämä kokonaisuus lopulta vaati.

Teknologiateollisuuden
100-vuotissäätiö

Tampereella, 15.4.2026

Riku Korpiaho

SISÄLLYSLUETTELO

1. JOHDANTO 1
1.1 Tutkimuksen tausta ja motivaatio 1
1.2 Tutkimuskysymykset 3
1.3 Työn tavoitteet sekä rajaukset 4
1.4 Työn rakenne 5
2. TEKOÄLYN TEKNINEN JA TEOREETTINEN TARKASTELU HISTORIASTA NYKYTILAAN 6
2.1 Tekoälyn lyhyt historia 6
2.1.1 Älykkyys irti biologiasta 6
2.1.2 Generatiivisen tekoälyn aikakausi 7
2.2 Moderni tekoäly 8
2.2.1 Perceptron matemaattinen luokittelija 9
2.2.2 Koneoppimisen paradigmat 11
2.2.3 Syväoppiminen 12
2.3 Mallit tieteessä, tekoälymallit, kielimallit 13
2.3.1 Tekoälymallit, ihmisen mieli ja kielimallit 13
2.3.2 Kielimallien päättely 15
2.3.3 Autonomiset agentit ja riskiprofiili 16
2.4 Tekoälyjärjestelmät ja integraatiot sääntelykontekstissa 17
2.4.1 Arkkitehtuurivalinnat, integraatiot ja tietosuoja 18
2.4.2 RAG-arkkitehtuuri kielimallien dynaamisena muistina 20
2.4.3 RAG-putket sääntelykontekstissa 22
2.4.4 Laskennallinen tekstianalyysi 23
2.5 Tekoälyn yleiset ongelmat, uhkakuvat ja tarpeet sääntelylle 25
2.5.1 Stokastinen ennustaminen ja hallusinaatiot 27
2.5.2 Oppimisen datasettien tilastolliset rajoitteet: ylisovittaminen ja vinoumat 30
2.5.3 Dynaamiset elinkaaririskit: Datan kierre ja mallin heikkeneminen ajassa 31
2.5.4 Tietoturva, tietosuoja ja mallien manipulointi 33
2.5.5 Tulevaisuuden ongelmia: riippuvuus, osaamisen rapautuminen ja järjestelmätason haavoittuvuus 34
2.6 Terveydenhuolto digitalisaatiosta tekoälyyn 35
2.6.1 Terveydenhuolto murroksessa 35
2.6.2 Eurooppalainen datasääntely 36
2.7 Kielimallien sääntelykehykset ja lainsäädäntö terveydenhuollossa 38
2.7.1 Sääntelykentän kokonaiskuva 38
2.7.2 Yleiskäyttöisten kielimallien (GPAI/LLM) velvoitteet 41
2.7.3 Terveydenhuollon erityiskysymykset: MDR/IVDR ja AI Act -yhteispeli, EHDS ja FRIA 43
2.7.4 Standardit ja hallintamallit terveydenhuollossa 46
3. TUTKIMUSMENETELMÄT JA AINEISTO 47
3.1 Arkkitehtuuri ja teknologiavalinnat 47
3.1.1 Kolmikerrosarkkitehtuuri ja asynkronisuus 47

3.1.2 Tiedonhallinta ja vaatimustenmukaisuus 48
3.2 Analyysiputki esikäsittelystä datan järjestelyyn 49
3.3 Deterministiset sovitusalgoritmit 51
3.3.1 Vastaavuusanalyysi (*Alignment mode*) 51
3.3.2 *Bipartite matching* -arviointi 55
3.3.3 Muutosanalyysi (*Diff mode*) 55
3.4 Aineistovalinta 56
4. TULOKSET JA ANALYYSI 57
4.1 Toteutettu ohjelmistoratkaisu 57
4.1.1 Järjestelmän parametrivalinnat ja käyttöliittymä 57
4.1.2 Vastaavuusanalyysin toiminnallinen toteutus ja tulosmetriikat 58
4.1.3 Muutosanalyysin näkymän tuloksia 61
4.2 Suorituskykyanalyysi 62
4.3 Järjestelmän validointi ja keskeiset havainnot 64
4.3.1 Klausuulien mikrotason validointi 64
4.3.2 Makrotason validointi, kohdistustulokset ja yhteenveto 66
5. KESKUSTELU JA JOHTOPÄÄTÖKSET 69
5.1 Tulosten pohdinta ja johtopäätökset 69
5.1.1 Teknisen samankaltaisuuden ja normatiivisen merkityksen väliset ristiriidat mikrotasolla 69
5.1.2 Makrotason havainnot ja johtopäätökset 72
5.2 Yhteenveto tutkimuskysymyksistä 74
5.3 Jatkokehitys 76
5.3.1 Tekninen skaalautuvuus ja mallien päivitykset 76
5.3.2 Automaation syventäminen, auditointi ja muutosvahti 76
LÄHTEET 77

LYHENTEET JA MERKINNÄT

Agnostinen	järjestelmän tai mallin kyky toimia riippumattomasti tietystä teknisestä alustasta, toteutustavasta tai tiedostomuodosta
AI Act	Euroopan unionin tekoälyasetus, riskiperusteinen säädöskehys joka asettaa velvoitteita tekoälyjärjestelmien kehittäjille ja käyttäjille turvallisuuden varmistamiseksi
API	ohjelmointirajapinta, jonka kautta eri ohjelmistokomponentit vaihtavat tietoa ja kutsuvat toistensa funktioita
Automation bias	automaatioharha, ihmisen taipumus luottaa liikaa automaatioon tai tekoälyyn
Bias	tilastollinen tai kognitiivinen vääristymä datassa tai vastauksessa
Bipartite matching	kaksijakoinen sovitusalgoritmi klausuuliparien yhdistämiseen toisiinsa
Black Box	suljettu tai koulutusmateriaaliltaan läpinäkymätön järjestelmä jonka logiikkaa tai tietopohjaa käyttäjä ei voi suoraan auditoida
BM25	avainsanoihin perustuva hakualgoritmi, arvioi kuinka merkittäviä haetut avainsanat ovat suhteessa dokumentin pituuteen
Chunking	tekstin paloittelu tai esikäsittelyvaihe, jossa pitkät sääntelydokumentit jaetaan semanttisesti loogisiin yksiköihin
Cloud Act	laki, joka velvoittaa yhdysvaltalaiset yritykset luovuttamaan dataa viranomaisille riippumatta palvelimen fyysisestä sijainnista
CloudPC	virtuaalinen työpöytä pilvessä
CPU	tietokoneen suoritin, ei optimi *transformer* tekoälylaskennassa
COT	ajatusketju tai eksplisiittinen päättelyketju
Cross-encoder	ristiinkoodaaja, neuroverkkomalli tekstien tarkkaan semanttiseen uudelleenjärjestämiseen
Data poisoning	opetusaineiston tahallinen vääristely eli myrkytys
Deskilling	ammatillisen osaamisen rapautuminen järjestelmäriippuvuuden vuoksi
Docker-kontitus	teknologia, jolla sovelluksen eri osat (esim. Redis, Celery, FastAPI) eristetään omiksi suoritettaviksi kokonaisuuksikseen
Directional NLI	suunnattu looginen päättely, joka tunnistaa tekstien implikaatiosuhteita
DPA	tietojenkäsittelysopimus
DPIA	vaikutustenarviointi
EHDS	Euroopan terveysdatan tilaa koskeva asetus
Embedding	kielellisen merkityksen numeerinen esitysmuoto (vektori) matemaattisessa avaruudessa, toimii myös RAG-arkkitehtuurin teknisenä perustana
Epoch	opetusjakso tai -sykli koneoppimismallien koulutuksessa
FAISS	eräs vektoritietokanta indeksointiin ja hakuun
FISA 702	Yhdysvaltain laki, joka mahdollistaa ulkomaisen datan seurannan
FRIA	perusoikeusvaikutusten arviointi
GDPR	EU:n yleinen tietosuoja-asetus
GPAI	yleiskäyttöinen tekoälymalli
GPU	erikoistunut suoritinarkkitehtuuri, joka on optimi massiiviseen rinnakkaislaskentaan
Grounding	ankkurointiprosessi, jossa tekoälymallin vastaus sidotaan suoraan haettuun lähdemateriaaliin esimerkiksi vektoritietokannasta
Hallusinaatio	generatiivisen tekoälymallin tuottama faktuaalisesti virheellinen, perätön mutta ehkä uskottavalta kuulostava väite
HNSW	tiheän haun indeksi likimääräistä lähimmän naapurin hakua varten
Human-in-the-loop	ihmisen suorittama valvonta tekoälyn päätöksenteossa
IVDR	in vitro -diagnostiikan asetus
Jailbreak	tekoälymallin suojamekanismien kiertäminen
kanoninen teksti	klusteria edustavin, primitiivisin, synteettisesti generoitu ydinteksti
Klausuuli	lause tai yksikkö, joka ilmaisee säännöksen, velvoitteen tai oikeudellisen proposition
Kosinisimilaarisuus	matemaattinen mittari, jolla lasketaan kahden vektorin välinen etäisyys
LLM	suuri kielimalli, joka on koulutettu massiivisesta materiaalista ennustamaan ja generoimaan luonnollista kieltä
Local-First	arkkitehtuuri, jossa kaikki laskenta tapahtuu paikallisessa infrastruktuurissa
Loss function	häviöfunktio, joka mittaa ennusteen virhettä suhteessa totuuteen

Malli	ilmiötä mallintava rakenne tai abstraktio, joka yksinkertaistaa todellisuutta tehdäkseen tutkittavasta ilmiöstä käsiteltävän ja ennustettavan
MDR	lääkinnällisten laitteiden asetus
ML	koneoppiminen eli tietokoneen kyky oppia aineistosta toistuvuuksia
Model collapse	tekoälymallin romahdus, kun sitä koulutetaan tekoälyn tuottamalla datalla
Model drift	mallin suorituskyvyn tai oppimisen heikkeneminen ja siirtymä ajan myötä
NIS2	kyberturvallisuusdirektiivi erittäin kriittisille toimialoille
Perceptron	keinotekoisen neuroverkon alkeellisin yksikkö ja binäärinen lineaarinen luokittelija
PMS	markkinoiden jälkeinen valvonta
Predictive coding	aivojen ennakoivaa toimintaa kuvaava neurotieteen teoria
Prompt injection	kehotteen manipulointi turvarajojen sivuuttamiseksi
QMS	laatujärjestelmä
RAG	tekoälyarkkitehtuuri, jossa kielimallin tuottama vastaus ankkuroidaan ja rikastetaan hakemalla relevanttia tietoa ulkoisista tietolähteistä ennen tekstin generointia
ReAct	tekoälyagentin päättelyä ja toimintaa yhdistävä suunnittelumenetelmä
RegTech	Regulatory Technology, sääntelyprosessien digitalisointi ja automatisointi
SaaS	ohjelmisto pilvipalveluna (Software-as-a-Service)
SSE	Server-Sent Events, reaaliaikainen tiedonsiirtoteknologia
Stokastinen	todennäköisyyksiin ja ennustamiseen perustuva prosessi, jossa lopputulos ei ole täysin ennalta määrätty
Token	tekstin pienin laskennallinen yksikkö tekoälyn merkkien generoinnissa
Transformer	neuroverkkoarkkitehtuuri, joka mullisti kielimallien kehityksen
True Negative	luokittelutulos, jossa järjestelmä jättää oikeaoppisesti yhdistämättä klausuulit, joilla ei ole asiasisällöllistä yhteyttä
Vektorisimilaarisuus	matemaattinen mittari tekstien väliselle matemaattiselle samankaltaisuudelle
VRAM	GPU videomuisti, arvokas resurssi tekoälylaskennassa
Z-score	dynaaminen, keskihajontaan perustuva tilastollinen suodatusmenetelmä

1. JOHDANTO

Ihmiskunnan pyrkimys järjestelmälliseen laadunvarmistukseen ja yhteensopivuuteen on historiallisesti kulkenut rinnan teknologisen kehityksen kanssa. Järjestäytynyt maailma on aina rakentunut sellaisten standardien varaan, jotka on johdettu joko luonnon vakioista (painovoima) tai kollektiivisen mielikuvituksen tuottamina sopimuksina (laki) (Harari, 2015). Olipa kyse pituuden mittayksiköistä: anatomiseen mittasuhteeseen perustuvasta jalasta tai maapallon meridiaaniin ankkuroidusta metristä tai tietoteknisistä protokollista, standardit ja säännökset toimivat välttämättömänä yhteisenä kielenä. Standardien voidaan ajatella edustavan luottamusta sekä yhteistyötä monimutkaisessa ympäristössä. (Bøgh, 2015)

Siinä missä varhaiset standardit keskittyivät fyysisten mittojen ja materiaalien yhteismitallisuuteen, nykyajan teknologia vaatii dynaamista ja monitahoista sääntelykehikkoa, joka kykenee vastaamaan tekoälyn asettamiin haasteisiin. Terveydenhuollon digitalisaatio ja lääketieteellisten ohjelmistojen yleistyminen sekä varsinkin tekoälyjärjestelmien saapuminen terveydenhuoltoon ovat synnyttäneet sääntelyllisen paineen, joka kulminoituu Euroopan unionin lääkinnällisten laitteiden asetukseen (MDR), in vitro -diagnostiikan asetukseen (IVDR) sekä uuteen EU:n tekoälyasetukseen (AI Act) sekä näiden lisäksi soveltuvat useat standardit (esim. laatujärjestelmiä, riskienhallintaa ja ohjelmistokehitystä koskevat ISO- ja IEC-standardit).

Sääntely on osaltaan välttämätön mekanismi potilasturvallisuuden ja eettisen toiminnan takaamiseksi. Kuitenkin sääntelytekstien ja kansainvälisten ISO-standardien (kuten ISO 13485 tai ISO/IEC 42001) jatkuvasti kasvava sekä päivittyvä massa on johtanut tilanteeseen, jossa asiantuntijaresursseja kuluu kohtuuttomasti manuaaliseen tekstianalyysiin, dokumentaation päivittämiseen ja vaatimustenmukaisuuden todentamiseen. Tämä "regulaatiotaakka" muodostaa merkittävän esteen innovaatioiden markkinoille pääsylle, erityisesti pienille ja keskisuurille yrityksille, vaikka sinänsä säädösten tarkoitus onkin hyväntahtoinen.

1.1 Tutkimuksen tausta ja motivaatio

Tekoälyohjelmistojen ja erityisesti terveydenhuollon tekoälysovellusten käyttöönotto kytkeytyy suoraan tiukkaan sääntelykehykseen. Sääntelyn ensisijainen tavoite on potilasturvallisuuden, laadun ja luotettavuuden varmistaminen. Käytännössä vaatimusten

määrä, tulkinnanvaraisuus ja dokumentaatiota koskevat odotukset muodostavat kuitenkin yrityksille merkittävän lisäkuorman, joka kilpailee samoista resursseista varsinaisen tuotekehityksen kanssa.

Useat alan raportit osoittavat, että MDR- ja IVDR-vaatimusten myötä dokumentaatiovaatimukset, auditointiprosessit ja tulkintaerot viranomaisten ja ilmoitettujen laitosten välillä ovat nostaneet kustannuksia ja hidastaneet markkinoille pääsyä sekä jopa johtaneet innovatiivisten laitteiden poistumiseen markkinoilta. (”MedTech Europe 2024 Regulatory Survey: key findings and insights”, 2024) Tämä jännite: turvallisuuden ja läpinäkyvyyden vahvistaminen toisaalta, ja innovaation ja pk-yritysten toimintaedellytysten turvaaminen toisaalta on keskeinen taustatekijä tälle työlle. Sääntelyä pidetään välttämättömänä ja periaatteessa tavoiteltavana, mutta käytännön tasolla se näyttäytyy monelle toimijalle “pakollisena pahana”, joka vie aikaa, rahaa ja fokusta ydintoiminnasta.

Manuaalinen prosessi on altis inhimillisille virheille, hitaille päivityssykleille ja tulkintaeroille, mikä heikentää sääntelydokumentaation laatua ja jäljitettävyyttä. MDR ja siihen liittyvät ohjeistukset, AI Actin pykälät ja liitteet sekä eri standardien (esim. laatujärjestelmä-, riskienhallinta- ja ohjelmistostandardit) yksityiskohtaiset vaatimukset muodostavat satojen sivujen tekstimassan, jota täytyy lukea, tulkita, päivittää ja soveltaa organisaation prosesseihin. Toisaalta niiden noudattamatta jättäminen voi tulla erittäin kalliiksi organisaatiolle.

EU AI Actin arvioidaan aiheuttavan merkittäviä kertaluonteisia ja jatkuvia kustannuksia erityisesti korkean riskin järjestelmien tarjoajille. Pienille ja keskisuurille toimijoille (PK-yritykset) suhteellinen taakka on usein suurempi kuin suurille yrityksille, koska vaadittavat prosessit (riskienhallinta, dokumentointi, mallin valvonta, läpinäkyvyysraportit) pitää toteuttaa huomattavasti pienemmällä henkilöstöllä ja osaamisresursseilla.

Motivaationa työlle toimii *Regulatory Technology* (RegTech) -ajattelu, jossa sääntelyprosessit digitalisoidaan ja automatisoidaan. Työssä kehitetään ja analysoidaan kokeellista ohjelmistoalustaa, joka hyödyntää yhdistelmää suuria kielimalleja (LLM), deterministisen analyysin ja vektorihakua standardien analysoinnissa. Järjestelmä on toteutettu yhdistelmätekoälyjärjestelmään perustuvana analyysialustana, joka on optimoitu autonomiseen tiedonkäsittelyyn perinteisen interaktiivisen keskusteluarkkitehtuurin sijaan. Ratkaisun keskeinen arvo sääntelyasiantuntijalle on verifiointiprosessin nopeutuminen: järjestelmä kytkee generatiiviset tulokset suoraan lähdeaineiston kontekstiin mahdollistamalla PDF-dokumenttien avaamisen täsmällisesti viitattujen klausuulien kohdalta.

1.2 Tutkimuskysymykset

Tämän tutkimuksen päätavoitteena on tutkia ja osoittaa, kuinka suuria kielimalleja (LLM) ja RAG-arkkitehtuuria (*Retrieval-Augmented Generation*) hyödyntävä automatisoitu analyysialusta kykenee tukemaan sääntelyasiantuntijoiden työtä. Työssä kehitetään ja validoidaan RegTech-sovellus, joka tuottaa deterministis-generatiivisia ja täysin jäljitettäviä raportteja monimutkaisten sääntelyaineistojen muutoksista ja vastaavuuksista.

Alusta on rakennettu dokumenttiagnostiseksi työkaluksi. Sen kokeellinen validointi suoritetaan ISO/IEC 27001 -standardin eri versioilla, joka on keskeinen tietoturvakehikko myös terveydenhuollon tekoälyn ohjelmistoratkaisuissa.

Tutkimuksen päätutkimuskysymys on:

1. Miten automatisoidulla, kielimalleihin, determinismiin ja vektorihakuun perustuvalla analyysialustalla voidaan tehostaa terveydenhuoltoon liittyvän sääntelyaineiston hallintaa, ja missä määrin se kykenee tunnistamaan sekä raportoimaan standardien versioiden välisiä muutoksia ja vastaavuuksia ilman jatkuvaa interaktiivista ohjausta? Järjestelmän suorituskykyä ja luotettavuutta arvioidaan tässä tehtävässä yhdistämällä laaja laadullinen asiantuntija-analyysi mittareista ja suppea kvantitatiivinen mittaus (tarkkuus ja saanti) kokeellisessa otoksessa.

Päätutkimuskysymystä tarkennetaan seuraavilla alakysymyksillä:

2. Kuinka optimoidusti tehokkaan järjestelmän voi kehittää ilman ulkoista laskentaa niin, että se on mahdollista ajaa aineistolle käyttäen pelkkiä CPU-ytimiä (suoritin) tai keskitasoista GPU (näytönohjainta)? Minkälaisia arkkitehtuurisia ja teknisiä haasteita sisältyy kokeellisen *design science* -ohjelmiston kehitykseen?
3. Raportoinnin luotettavuus ja jäljitettävyys: Missä määrin yhdistelmätekoälyjärjestelmän analyysimoottori kykenee tuottamaan deterministisiä, tiivistettyjä raportteja sääntelyhavainnoista siten, että täysi jäljitettävyys alkuperäislähteisiin säilyy asiantuntija-arviointia tai *human-in-the-loop* arviointia varten? Kuinka hyvin luettavissa automaatio on ihmisen perspektiivistä ja tehostaako se standardien manuaalista tulkintaa?

Työn kokeellisessa osiossa vastataan näihin kysymyksiin testaamalla kehitetyn alustan kykyä tuottaa automaattisia vertailuanalyysejä ja vaatimustenmukaisuusmatriiseja ilman perinteisille keskusteluboteille tyypillistä interaktiivista kehotteiden muotoilua. Tämä lähestymistapa korostaa järjestelmän roolia autonomisena analyysityökaluna, joka muuntaa staattisen sääntelymassan dynaamiseksi ja hallittavaksi tiedoksi.

1.3 Työn tavoitteet sekä rajaukset

Työssä rakennetaan alusta alkaen uusi ohjelmisto hyödyntäen sekä perinteisiä manuaalisia että agenttisia ohjelmointimekanismeja. Ratkaisu toteutetaan itsenäisesti ilman nojaamista valmiisiin avoimen lähdekoodin kokonaisratkaisuihin. Vaikka kehitettävän järjestelmän tavoite on laajuudessaan massiivinen, työ toimii siten kokeellisena testinä siitä, mihin yksittäinen henkilö kykenee nykyaikaisia tekoälyavusteisia ohjelmointityökaluja hyödyntämällä.

Kehitetyn ohjelmiston tuottamien tulosten arviointi perustuu pääosin ihmisen tekemään laadulliseen arviointiin. Vaikka ihmisen tekemä arviointi on valittu työn mielekkäimmäksi validointimenetelmäksi, tuloksissa on käytetty myös suppeaa kvantitatiivista menetelmää klausuuliparien löytämisen objektiiviseksi arvioimiseksi. Erityisesti homogeenisissa aineistoissa jo alle kymmenen havainnon otos riittää usein teemallisen saturaation saavuttamiseen, minkä jälkeen otoskoon kasvattaminen ei enää olennaisesti vaikuta tuloksiin (Guest, Namey ja Chen, 2020). Koska työn ensisijainen tavoite on konstruktiivinen (design science) eli toimivan arkkitehtuurin ja teknisen putken rakentaminen – kvantitatiivisen validoinnin otoskoko on rajattu toimimaan teknisenä konseptintodennuksena (*proof-of-concept).* Tilastollisen yleistettävyyden sijaan otannassa keskitytään syvälliseen, klausuulitason mikrotarkasteluun, jolla todennetaan järjestelmän sisäisen putken (kuten NLI-päättelyn jne) tekninen eheys.

Työhön liittyy useita merkittäviä rajauksia, jotka johtuvat sen toteuttamisesta tiiviissä yhteistyössä kohdeyritysten kanssa:

1. Analyysin rajaus: Työn tekninen laajuus on rajattu tarkastelemaan nimenomaan saman dokumentin eri versioiden välisiä eroja. Laajemmat useiden täysin erilaisten säännösten väliset ristiinvertailut on rajattu tämän työn ulkopuolelle, vaikka sen tulee pystyä siihenkin.
2. Salassapito (NDA): Vaikka järjestelmää testattiin ja kehitettiin yhteistyössä kohdeyrityksen kanssa, ohjelmiston tuottama kokonaisvaltainen ja yrityskohtainen loppuanalyysi on salassapitosopimusten (NDA) alainen, eikä sitä esitellä tässä työssä julkisesti.
3. Immateriaalioikeudet (IP): Kehitetyn ohjelmiston syvällinen arkkitehtuurikuvaus ja lähdekoodi on jätetty työn ulkopuolelle immateriaalioikeuksien suojaamiseksi. Diplomityön tarkoituksena on tuottaa myöhemmin skaalattuna soveltavaa ja kaupallista arvoa suoraan kohdeyrityksille sekä esitellä konseptin toimivuus tieteellisesti, ei toimia vapaasti hyödynnettävänä koulutusmateriaalina laajoille datankeruualustoille. Siksi tekninen kuvaus joistain komponenteista on suppea.

1.4 Työn rakenne

Tämä diplomityö koostuu viidestä pääluvusta. Ensimmäinen luku on johdanto, jossa määritellään tutkimuksen tausta, motivaatio, tutkimuskysymykset sekä työn rajaukset.

- Toisessa luvussa rakennetaan työn teoreettis-tekninen pohja analysoimalla tekoälyteknologioiden kehityskaarta, niiden synnyttämiä riskejä sekä terveydenhuollon tekoälysovellusten sääntelymekanismeja, jotka on kehitetty vastaamaan näihin teknologisiin epävarmuuksiin.
- Luvussa 3 kuvataan tutkimusmenetelmät, käytetty aineisto sekä kehitetyn paikallisen analyysialustan tekninen arkkitehtuuri ja siinä hyödynnetyt algoritmit sekä koneoppimismallit.
- Luku 4 keskittyy toteutetun ratkaisun käyttöliittymän esittelyyn, sen suorituskyvyn analysointiin, sekä keskeisiin havaintoihin sääntelyn hallinnan automatisoinnista.
- Viidennessä luvussa tuloksia arvioidaan suhteessa tutkimuskysymyksiin ja pohditaan alustan ja tulosten merkitystä sekä kootaan yhteen työn tavoitteiden toteutuminen ja esitetään ehdotuksia järjestelmän jatkokehitykselle.

2. TEKOÄLYN TEKNINEN JA TEOREETTINEN TARKASTELU HISTORIASTA NYKYTILAAN

Ihmiskunnan pyrkimys mekanisoida järki ja ulkoistaa ajattelu koneille on vuosisatoja vanha unelma, joka on vihdoin saavuttanut teknologisen kypsyyden pisteen, jota on aiemmin pidetty naiivin puhtaana tieteiskirjallisuutena. Siinä missä varhaiset yritykset rakentuivat symbolisen logiikan ja staattisten sääntöjen varaan, nykyinen vallankumous perustuu valtaviin datamassoihin ja laskennalliseen ennustamiseen, joka haastaa perinteiset käsityksemme tiedon olemuksesta ja myös älykkyyden rajoista. Siirtymä deterministisestä sääntölogiikasta stokastiseen todennäköisyyslaskentaan ei ole vain tekninen muutos, vaan syvällinen paradigman vaihdos siinä, miten koneellinen järjestelmä tulkitsee maailmaa.

Tässä luvussa luodaan tekninen ja teoreettinen perusta, jonka varaan nykyaikaiset kielimallit, ongelmat ja niiden sääntelykehykset rakentuvat. Tarkastelu etenee laskennallisen älykkyyden historiallisista juurista neuroverkkojen evoluutioon ja edelleen monimutkaisiin järjestelmäkokonaisuuksiin, kuten RAG-arkkitehtuureihin ja agentteihin eli autonomisiin tekoälyjärjestelmiin. Samalla analysoidaan niitä rakenteellisia riskejä ja teknisiä rajoitteita, jotka tekevät tekoälyn hallinnasta ja sääntelystä välttämättömyyden erityisesti terveydenhuollon kaltaisilla yhteiskunnallisesti kriittisillä aloilla.

2.1 Tekoälyn lyhyt historia

Seuraavissa aliluvuissa tarkastellaan tekoälyn evoluutiota teoreettisen pohjan luomisesta teknologiseen läpimurtoon. Analyysi kattaa älykkyyden määritelmän laajenemisen biologisen kontekstin ulkopuolelle, tekoälytutkimuksen eri kehitysvaiheet sekä nykyhetken haasteet järjestelmien hallittavuuden ja faktuaalisen luotettavuuden suhteen.

2.1.1 Älykkyys irti biologiasta

Vuonna 1950 julkaistussa artikkelissaan ”Computing Machinery and Intelligence” Alan Turing ehdotti ajatuskoetta, jota hän kutsui “jäljittelyleikiksi” (*imitation game*). Sen tarkoituksena oli selvittää, pystyykö kone viestinnän keinoin esiintymään ihmisenä niin, että keskustelija ei pysty varmasti erottamaan sitä ihmisvastauksesta. Testi tunnetaan nykyään Turingin testinä, ja sen merkitys ei ollut pelkästään tekninen, vaan perustavanlaajuinen: se määritti älykkyyden havaittavana ilmiönä, ei sisäisenä ominaisuutena.

Ajatus “tekoälystä” oli kulkenut kauan ennen itse sanaa. Jo antiikissa mielen toimintaa selitettiin aikansa parhaan teknologian avulla: sielu virtasi kuin hydraulinen järjestelmä (Hippokrates ja Galenos); 1600-luvulla ihminen oli “kellokoneisto” (Descartes), 1800-luvulla hermosto oli kuin lennätin (Helmholtz), 1900-luvulla puhelinverkko (Sherrington) – ja 1900 - 2000-luvuilla mieli rinnastettiin tietokoneeseen (Putnam). Vertaus muuttuu teknologian vaihtuessa, mutta peruskysymys pysyy: mikä osa järjestyksestä ja päättelystä on luonnostaan inhimillistä ja mikä on mekanisoitavissa. (Müller, 2008)

Turingin lähestymistapa irrotti älykkyyden ajatuksen yksinomaan biologisesta perustasta ja teki siitä universaalin laskennallisen ongelman. Koneen ei tarvinnut “ajatella” tai “olla tietoinen” biologisen ihmisen tavoin, vaan sen tuli käyttäytyä riittävän uskottavasti kielellisessä/ symbolisessa vuorovaikutuksessa. Tämä oivallus loi pohjan myöhemmälle tekoälytutkimukselle, jossa älykkyys määritellään yhä useammin toimintana, ei olemuksena. Nykyisellään modernit kielimallit läpäisevät Turingin testin. Jo ChatGPT 4.5 läpäisi Turing Testin, ”huijaamalla” 73 prosenttia ihmisistä (Jones ja Bergen, 2025), mutta vain ja ainoastaan silloin, kun tutkijat nimenomaisesti ohjeistivat mallia simuloimaan inhimillistä erehtyväisyyttä.

2.1.2 Generatiivisen tekoälyn aikakausi

Tekoäly on kiistatta yksi aikamme eettisesti haastavimmista ja samalla kiehtovimmista teknologisista ilmiöistä. Sen monitahoisuus ja antropomorfisuus; ihmisen kaltaisten piirteiden jäljittely ja tuottaminen pakottavat arvioimaan uudelleen ihmisen ja koneen välistä rajaa. Ajatus ”hiekan opettamisesta puhumaan” ei ole pelkkä metafora (Miller, 2022), vaan konkreettinen kuvaus fyysisestä todellisuudesta: kvartsihiekasta jalostettuihin piisiruihin ohjattava sähkövirta ja koneoppimisen parametrit on saatu simuloimaan kieltä ja ajattelua tavalla, joka horjuttaa syvästi käsitystä ihmisen älyllisistä erityisoikeuksista.

Tätä inhimillistä reaktiota teknologiseen kehitykseen ja kognitiivisen rajapinnan hämärtymiseen kuvaa käsitteellisesti niin sanottu tekoälyefekti (engl. *AI effect*). Ilmiöllä tarkoitetaan havaittua taipumusta siirtää älykkyyden määritelmän rajoja aina, kun tietokone saavuttaa uuden inhimillisenä pidetyn kognitiivisen virstanpylvään. Heti kun algoritmin toimintalogiikka ymmärretään tai ongelma on ratkaistu, kyseistä suoritusta oli se sitten shakinpeluu, kääntäminen tai luonnollisen kielen tuottaminen – ei enää tyypillisesti pidetä osoituksena ”todellisesta” älykkyydestä, vaan pelkkänä mekaanisena optimointina ja laskentana. Ilmiö on kiteytetty Teslerin teoreemana, jonka mukaan ”tekoälyä on kaikki se, mitä ei ole vielä tehty” (Kazzazi, 2021). Tämä jatkuva määritelmällisen riman nostaminen heijastaa ihmisen sisäistä tarvetta varjella ”älyllistä ainutlaatuisuutta” tilanteessa,

jossa koneet kykenevät simuloimaan ja automatisoimaan yhä korkeamman tason kognitiivisia prosesseja.

Tähän asetelmaan ei kuitenkaan tultu yhtäkkisesti, vaan syklisesti nousu- ja laskukausien ”tekoälytalvien” kautta, mutta itse läpimurto, eli 2022 loppuvuodesta OpenAI:n lanseeraus onnistui kuitenkin yllättämään lähes kaikki - se oli laadullisesti täysin eri tasolla kuin mikään aikaisempi *chatbot*. Kyseinen läpimurto perustui Googlen tutkijoiden jo vuonna 2017 esittelemään *Transformer*-arkkitehtuuriin, jota käsitellään tarkemmin pian tässä työssä. Samaan aikaan eskaloitui monia muita tekoälyn sovellusmuotoja, kuten kuvageneraattorit, jotka ovat nykyisellään siinä pisteessä, ettei nykyajan kuvista enää pysty sanomaan ovatko ne tietokoneluotuja vai todellisia valokuvia. Siinä mielessä kuva on menettänyt ”kuva kertoo enemmän kuin tuhat sanaa” -ylivertaisen selityksellisen asemansa jopa täydellisesti vuonna 2025.

Yleisesti, yhteiskunnassa tekoälyn ensimmäinen vallankumous ajateltiin todennäköisesti olevan ihmisen fyysisiä rutiinitehtäviä kuten varastotöitä automatisoiva, mutta tekoäly automatisoikin liki ensimmäisenä korkeimmat älylliset ominaisuudet. Tekoälytutkimuksen klassinen Moravecin paradoksi kuvaa ilmiötä, jossa ihmiselle kognitiivisesti vaativat tehtävät ovat tietokoneille helppoja, kun taas ihmiselle luontaiset sensomotoriset toiminnot ovat koneille äärimmäisen vaikeita. Käytännön esimerkkinä tästä on robottikäden ja kameran ohjaaminen, joka on osoittautunut tekoälylle huomattavasti monimutkaisemmaksi ongelmaksi kuin abstrakti looginen päättely – tosin siinäkin ollaan nyt otettu valtava harppaus eteenpäin ja robotiikka näyttääkin olevan seuraava aalto. (Moravec, 1995)

Tekoälyn vallankumous on joka tapauksessa alkanut, ja monia tehtäviä pystytään automatisoimaan koneellisesti. On myös todettava, että on hämmentävää ajatella tekoälyn historiaa tähän päivään asti, ja kuinka arkipäiväiseltä se absurdisti yhtäkkiä tuntuu: jokaisen taskussa kulkee nykyään kyvykäs tekoälyjärjestelmä, jolle voi puhua luonnollista kieltä ja jolta voi odottaa perusteltuja vastauksia mihin tahansa kysymykseen. Joskin toki kaikkea ihmisen, sekä tekoälyn laatimaa materiaalia tulee edelleen tarkastella lähdekriittisesti.

2.2 Moderni tekoäly

Ennen kuin tarkastellaan tekoälymallien ideaa, pitää tarkastella, miten ne syntyvät; miten niitä koulutetaan. Ne eivät istu Tampereen yliopiston luennoilla, mutta toki kahmivat kaiken materiaalin, joka sieltä tulee ulos eri muodoissaan. Niille opetetaan tietomassaa koneoppimisen kautta, johon mennään ensimmäisenä.

Koneoppimisen perusajatuksena on hahmontunnistus (*pattern recognition*): algoritmi oppii tunnistamaan datasta toistuvia säännönmukaisuuksia ja luokittelemaan havaintoja ilman eksplisiittisesti käsin kirjoitettuja sääntöjä. Teknologinen evoluutio tällä saralla muodostaa selkeän jatkumon. Siinä missä perinteinen koneoppiminen nojaa asiantuntijan etukäteen määrittelemiin piirteisiin, syväoppiminen (*deep learning*) kykenee tunnistamaan nämä rakenteet datasta automaattisesti. *Transformer*-arkkitehtuurit puolestaan hyödyntävät huomiomekanismeja (*attention*) poimiakseen olennaisimman informaation valtavista datamassoista (Vaswani *ym.*, 2017), ja lopulta suuret kielimallit (LLM) kääntävät tämän monitahoisen tilastollisen optimoinnin ymmärrettäväksi luonnolliseksi kieleksi. Tässä aliluvussa luodaan tekninen katsaus näihin tekoälyn peruspilareihin.

2.2.1 Perceptron matemaattinen luokittelija

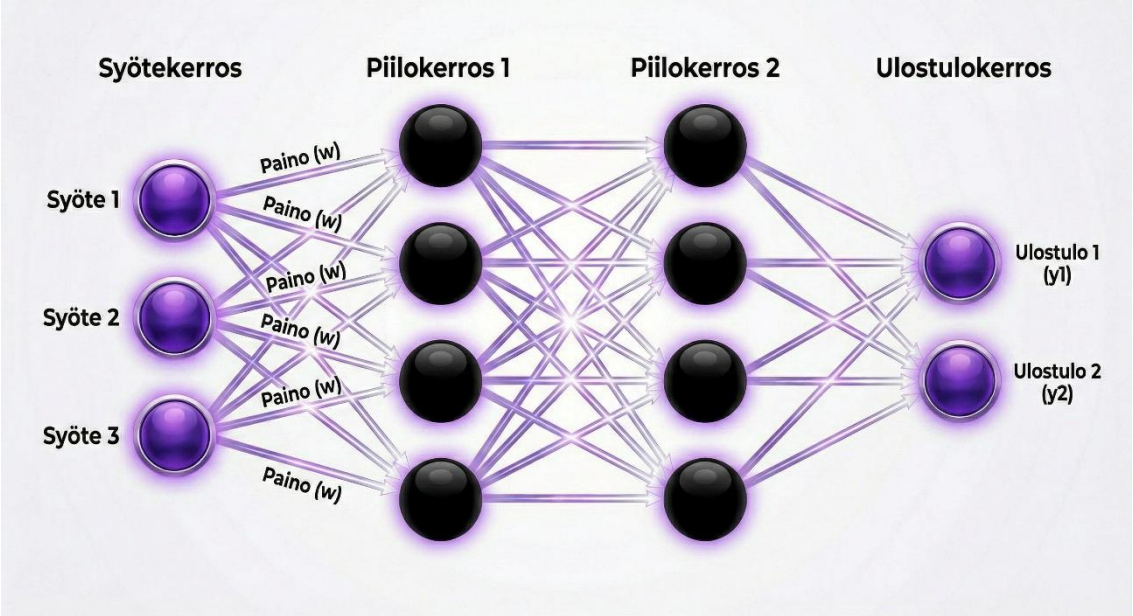
Matemaattisessa mielessä *perceptron* on keinotekoisen neuroverkon kaikkein yksinkertaisin alkeisyksikkö. Se kehitettiin alun perin jäljittelemään biologisen hermosolun toimintaa, ja se mallintaa päätöksentekoa yksinkertaisena lineaarisena yhtälönä. Mallin toimintalogiikka on suoraviivainen: se ottaa vastaan numeerisia syötteitä (havaintodatan arvoja), kertoo jokaisen syötteen sille määritetyllä painokertoimella (*weights*) ja laskee näiden tulojen summan. Tämän jälkeen summa syötetään erilliseen aktivointifunktioon, joka toimii matemaattisena kynnyksenä. Jos summa on riittävän suuri ja ylittää kynnysarvon, perceptron "aktivoituu" ja tuottaa lähtösignaalin (*output*) aivan kuten biologinen hermosolu laukaisee sähköisen aktiopotentiaalin (Rosenblatt, 1958). Alla on esitetty perceptronin toimintaa mallintava matemaattinen yhtälö:

$$y = f\left(\sum_{i=1}^{n} w_i x_i + b\right)$$

Vaikka tämä varhainen malli kykeni oppimaan yksinkertaisia sääntöjä, sen kyvyillä oli tiukat matemaattiset rajat. Minsky ja Papert osoittivat tunnetussa teoksessaan vuonna 1969, että yksikerroksinen perceptron pystyy ratkaisemaan vain niin sanotusti lineaarisesti erotettavia ongelmia (Minsky ja Papert, 1969). Lineaarisesti erotettava ongelma tarkoittaa yksinkertaista jakoa, jossa on pystysuora viiva erottamassa esimerkiksi ”kissa ja koira rodut” toisistaan, jotka sijaitsevat pisteinä koordinaatistossa.

Käytännön läpimurrot koneoppimisessa viipyivät pitkään mm. laskennallisten rajoitteiden ja menetelmien kypsymättömyyden vuoksi, joskin kuitenkin mainittakoon, että monikerroksinen perceptron (*MLP*) muodostaa edelleenkin monentyyppisen nykyaikaisen syväoppimismallin (*deep learning*) perusrakenteen: se koostuu kerroksittain kytketyistä keinotekoisista neuronikerroksista (kuva 1), jotka oppivat esittämään syötteen piirteitä

yhä abstraktimmassa muodossa, kerros kerrokselta (Heaton, 2018). Alla olevassa kuvassa yksittäistä perceptronia edustaisi vain yksi ”musta ennustuspallo”, eikä toista piilokerrosta olisi lainkaan. Alun perin Frank Rosenblattin kehittämä malli on siis yksittäinen algoritmi (yksi neuroni), joka ottaa vastaan syötteitä, painottaa ne ja tuottaa yhden ulostulon eli toimii kuin matemaattinen kytkin.



Kuva 1: Monikerroksisen perceptronin (MLP) arkkitehtuuri. Piilokerrokset mahdollistavat datan piirteiden oppimisen eri abstraktiotasoilla. Siinä missä esimerkkikuvan kaltaisessa yksinkertaisessa verkossa kytkentöjä on vain kymmeniä, nykyaikaiset syväoppimismallit voivat sisältää satoja miljardeja vastaavia painotettuja yhteyksiä.

”Kytkimen”, neuronin eli perceptronin ulostulokerros vastaa siis lopulta luokittelun tuloksen, kuten ”kissa” tai ”pitkä”, jos luokkaan viittaavien piirteiden painotus on riittävä ylittämään aktivointifunktion kynnyksen. Usein aktivointifunktiona käytetään epälineaarista logistista *sigmoid*-funktiota, joka muuntaa eli normalisoi arvot jatkuvaksi todennäköisyydeksi:

$$f(x) = \frac{1}{1 + e^{-x}}$$

Logistinen sigmoid-funktio on siis klassinen tapa puristaa mikä tahansa neuroverkon ulostulo todennäköisyydeksi välille 0 ja 1. Tätä kaavaa käytetään myös työn ohjelmistossa muuntamaan raaka logit-arvoja luettavammiksi todennäköisyyksiksi käyttäjälle.

2.2.2 Koneoppimisen paradigmat

Koneoppiminen (*machine learning*, ML) on tilastollinen menetelmäperhe, jossa tietokoneelle annetaan esimerkkejä halutusta käyttäytymisestä ja algoritmi oppii näistä yleistäviä sääntöjä ilman, että jokainen päätösehto kirjoitetaan käsin. Esimerkiksi ihmisen kielet ovat tässä ”helposti” opittavissa olevaa syntaksia kuten samoin myös koodikielet kuten python, mutta koneoppimista voidaan soveltaa nykyisellään mihin tahansa, kuten videoihin, kuviin ja vaikkapa genomidataan.

Käytännössä oppiminen muotoillaan optimointiongelmana: valitaan häviöfunktio (loss), joka mittaa ennusteen virhettä suhteessa havaittuun “totuuteen”, ja säädetään mallin parametreja niin, että tämä virhe pienenee.

Koneoppimisen paradigmat jaetaan karkeasti:

1. Ohjattuun oppimiseen (*supervised*), annetaan valmiita kysymys–vastaus-pareja, joiden pohjalta se oppii ennustamaan vastauksia uusiin, samankaltaisiin syötteisiin.
2. Ohjaamattomaan oppimiseen (*unsupervised*), etsii raakadatasta piileviä rakenteita, kuten samankaltaisuuksia tai ryhmiä (klusterointi), täysin ilman valmiita nimikkeitä.
3. Vahvistusoppimiseen (*reinforcement learning*), oppii yrityksen ja erehdyksen kautta, saaden ympäristöltään "palkintoja" onnistuneista valinnoista.
4. Itseohjattu oppiminen *(Self-supervised learning)* on kehittyneempi oppimisen muoto, jossa malli koulutetaan ilman ihmisen antamia valmiita vastauksia, mutta kuitenkin niin, että se tuottaa itse harjoitustehtäviä datasta. Käytännössä osa syötteestä poistetaan, peitetään tai siirretään, ja mallin tehtävä on opetella ennustamaan puuttuva osa muun datan perusteella. Toisin sanoen output siirretään inputiksi: malli oppii datasta datan avulla.

Kielimallit sijoittuvat tyypillisesti ohjatun ja itseohjatun oppimisen jatkumolle: malli oppii ennustamaan seuraavan tokenin (eli tekstin pienimmän yksikön, kuten sanan, sanaosan tai merkin, jota malli käsittelee laskennallisesti) aiemman kontekstin perusteella, mikä on muodollisesti tilastollisen ennustamisen ongelma. Kun tätä todennäköisyyksien laskentaa toistetaan massiivisilla tekstikorpuksilla, suuret kielimallit oppivat vähitellen tunnistamaan ja sisäistämään kielen säännönmukaisuuksia, kuten sanaston ja syntaksin välisiä tilastollisia suhteita. (Bishop, 2006)

Käytännössä tapauksessa tämä tarkoittaa, että järjestelmä saa syötteekseen esimerkiksi tekstin pätkän, josta yksi tai useampi sana (*token*) on poistettu, ja sen pitää ennustaa,

mitä puuttuu. Malli saa siis opettajakseen oman syötteensä rakenteen. Samalla se oppii lauserakenteita, sanojen suhteita ja merkityksiä ilman ulkopuolista merkintää. Prosessi muistuttaa ihmisen arvaamista lauseessa: “Lääkäri kuunteli potilaan ___ stetoskoopilla.” – ihminen täydentää automaattisesti sanan “sydämen” kontekstin perusteella.

2.2.3 Syväoppiminen

1980-luvulla takaisinkytkentäoppiminen (*backpropagation*) mahdollisti monikerroksisten verkkojen tehokkaan kouluttamisen (Rumelhart, Hinton ja Williams, 2002). Vaikkakin välillä 1990-luvulla perinteisemmät koneoppimismenetelmät, kuten tukivektorikoneet (SVM), hallitsivat kenttää vankan matemaattisen perustansa ansiosta, mutta 2010-luvulla laskentatehon (erityisesti GPU-laskennan) ja massiivisten tietoaineistojen kasvu johti syväoppimisen (*deep learning)* uuteen nousuun. Monitasoisten representaatioiden oppiminen suoraan raakadatasta osoittautui poikkeuksellisen tehokkaaksi ja ohitti perinteiset menetelmät selvästi (LeCun, Bengio ja Hinton, 2015).

Syväoppimisen arkkitehtuuri perustuu nimensä mukaisesti useisiin peräkkäisiin laskentakerroksiin. Kun data kulkee verkon läpi, alimmat kerrokset tunnistavat yksinkertaisia piirteitä (esimerkiksi kuvasta ääriviivoja), ja ylemmät kerrokset yhdistävät näistä yhä abstraktimpia kokonaisuuksia (kuten muotoja tai käsitteitä).

Tämä hierarkkinen piirteiden erottelu on menetelmän tehokkuuden ydin: informaatio jalostuu yhä tiiviimmiksi matemaattisiksi representaatioiksi eli vektoriesityksiksi (*embeddings*) verkon syvyyden kasvaessa. Voikin siis olla, että opetettavan datan merkitys tuleekin esiin vasta myöhemmissä kerroksissa, eivätkä näy lainkaan ensimmäisissä abstraktiokerroksissa.

Oppiminen tapahtuu toistuvissa sykleissä (*epoch*). Jokaisen kierroksen päätteeksi verkko laskee tekemänsä virheen ja käyttää *takaisinpropagointia*: algoritmi kulkee verkon takaperin ja laskee jokaiselle parametrille (painoille ja biaseille) tarkan suunnan ja suuruuden (gradientin), johon sitä on muutettava virheen minimoimiseksi.

Nykyään tutkijoiden ei tarvitse laskea näitä monimutkaisia derivaattoja käsin. Avoimen lähdekoodin laskentakirjastot (kuten PyTorch ja TensorFlow) hoitavat optimoinnin automaattisen differentiaation (*autodiff*) ja rinnakkaislaskentaan kykenevien grafiikkaprosessorien (GPU) avulla. Tämä on madaltanut mallien kehityskynnystä merkittävästi ja kiihdyttänyt koko alan kehitystä.

Varhaisten syvien verkkojen ongelmana oli "gradientin katoaminen", jossa oppimissignaali vaimeni matkalla verkon läpi, estäen syvimpien kerrosten oppimisen. Tämä pullonkaula ratkaistiin matemaattisilla keksinnöillä, kuten tehokkaammilla aktivointifunktioilla

(*ReLU*) ja ohitusyhteyksiä hyödyntävillä residuaaliverkoilla (*ResNet*) (He *ym.*, 2015). Kun näihin yhdistettiin moderneja optimointialgoritmeja (esim. *Adam*) ja ylisovittumista estäviä tekniikoita (esim. *dropout*), verkoista saatiin luotettavasti yleistäviä.

Vuodesta 2017 alkaen *Transformer*-arkkitehtuurin itsehuomio (self-*attention*) mullisti erityisesti kielimallien tehtävät ja loivat pohjan ns. perusmalleille (*foundation models*), joita voidaan hienosäätää laajasti erilaisiin tehtäviin. (Bommasani *ym.*, 2021). Transformer arkkitehtuuri muutti kentän täysin, koska koneen ei enää tarvitse lukea tekstiä järjestyksessä kuin ihminen, vaan se voi huomioida kaikki sanat kerralla rinnakkain, ja päätellä, mitkä kohdat ovat kulloinkin merkityksellisiä suhteessa mihinkin. Tämä oli syväoppimisen tärkein murros metodologiana nykyiseen laajuuteensa suurten kielimallien koulutuksessa.

2.3 Mallit tieteessä, tekoälymallit, kielimallit

Mallilla tarkoitetaan tieteenfilosofiassa työvälinettä, joka tekee ilmiön hahmotettavaksi, käsiteltäväksi tai käsitteellistettäväksi: se rajaa, idealisoi ja tuottaa johtopäätöksiä, joita voidaan vertailla havaintoihin. Mitä tahansa voidaan mallintaa. Mallit ovat ihmiskunnan älykkyyden eräänlainen mittari, mitä tehokkaampia malleja meillä on: yleensä sitä kehittyneempiä olemme.

Kartta ei ole maasto, mutta ilman karttaa emme löydä maastossa. Ilman malleja (esimerkiksi teorioita tai hypoteeseja) emme pystyisi kysymään ilmiöstä mitään tarkkaa (Korzybski, 2005). Tätä kautta mallit ovat tieteellisen ajattelun perusyksikkö: teoriat, mittaukset ja päätelmät nojaavat aina johonkin esitystapaan, jossa todellisuutta muotoillaan käyttökelpoiseen (ja väistämättä yksinkertaistettuun) muotoon. Tiivistäen, mallien avulla pystytään ekstrapoloimaan eli jatkamaan ja arvioimaan tuntematonta jo valmiiksi tunnettujen arvojen jatkumona.

2.3.1 Tekoälymallit, ihmisen mieli ja kielimallit

Tekoälymalli on “matemaattinen muistirakenne” ja koneoppimisalgoritmin tuotos, joka esittää datassa havaittuja suhteita niin, että sen avulla voidaan arvioida tai ennustaa uusia havaintoja. Tekoälymallit ovat siis eräänlaisia ennustuskoneita, jotka oppivat tunnistamaan toistuvuuksia datassa (Bishop, 2006).

Itseasiassa nykyisellään kehittyneimmät neurotieteen teoriatkin ovat ottaneet käsitteet *prediction* ja *probability* lähtökohdaksi, vaikka alunperin tekoälymalleissa oli tarkoitus ”ir-

rota biologian rajoista”: Predictive Coding -teorian mukaisesti ihmisaivot luovat ennustuksia perustuen aiempaan tietoon, jonka perusteella luulot, oletukset sekä uskomukset syntyvät, mahdollisesti myös päivittyvät. Uskomukset ovat tavallaan luottamusta, luuloa, pohjautuen ”parhaaseen arvaukseen” epätäydellisen tiedon perusteella. Uskomus ei tietenkään rajoitu vain uskontoihin, vaan myös koviin uskomuksiin, kuten tieteen teorioihin jotka sisältävät poikkeuksetta oletuksellisia komponentteja. Kognitiivisen tieteen edelläkävijä George Kelly kutsui ihmisiä ”naiiveiksi tutkijoiksi” (Kelly, 1991), jotka tuottavat ennustavia malleja maailmasta automatisoidakseen elämäänsä ja helpottamaan päätöksentekoa epävarmassa ympäristössä.

Keinotekoiset hermoverkot ovat karkeita laskennallisia analogeja biologisille hermoverkoille: neuroni laskee painotetun summan ja aktivointifunktion. Neurotieteellinen inspiraatio näkyy käsitteissä (synapsipainot, kerrokset), mutta nykyverkot (esim. *transformerit*) ovat suunniteltu ennen kaikkea tilastollisen optimoinnin ja rinnakkaislaskennan ehdoilla: ne eivät tietenkään kuvaa aivojen rakennetta täysin realistisesti.

Joka tapauksessa, ennakoiva koodaus -ajattelussa aivot nähdään jatkuvasti ennustuksia tuottavana järjestelmänä: ne eivät ”odota” ärsykkeitä passiivisesti, vaan muodostavat koko ajan parhaan arvauksensa siitä, mitä seuraavaksi tapahtuu, ja vertaavat tätä arvauksen ja todellisen aistitiedon välistä eroa. Tätä eroa kutsutaan ennustevirheeksi. Kun ennustevirhe on pieni, kokemus maailmasta on tällöin vakaa ja ennakoitava; kun virhe on suuri, järjestelmän on joko päivitettävä sisäistä malliaan (”olen ymmärtänyt tilanteen väärin”) tai oletettava, että kyse on satunnaisesta poikkeuksesta (”No kyllä minä olen kuitenkin oikeassa, poikkeus vahvistaa uskomukseni”). Tällä tavalla aivot säästävät laskennallisia resursseja: kaikkea ei tarvitse laskea alusta pitäen, vaan vain se, mikä yllättää, vaatii mahdollisen korjausliikkeen. (Friston, 2010)

Prediktiivisen koodauksen ja keinotekoisten hermoverkkojen vertailu auttaa myös suhtautumaan kriittisesti liian yksinkertaisiin analogioihin ”tekoälyaivoista”. Biologinen järjestelmä on upotettu kehoon, tunteisiin, motivaatioihin ja sosiaalisiin suhteisiin; tekoälymalli toimii rajatussa tilastollisessa avaruudessa, jossa syötteenä on esimerkiksi teksti ja tavoitteena tietyn tappiofunktion minimointi. Tietysti orgaaniset aivotkin koittavat minimoida virheitä. Mutta siinä, missä aivojen ennustaminen liittyy myös selviytymiseen, arvoihin, energian säästämiseen ja huomion suuntaamiseen, kielimalli pyrkii vain tuottamaan tilastollisesti uskottavan jatkon annetulle syötteelle. Yhtäläisyys on siis pikemminkin abstraktissa laskennallisessa muodossa (”järjestelmä, joka ennustaa ja oppii”), ei rakenteessa tai merkityksessä. Tietyssä mielessä tekoälymalleja voidaan käsitellä myös tehokkaina tietovarastoina eli pakkausalgoritmeja (Delétang *ym.*, 2023), joissa maailmaa

koskeva tieto on tiivistetty mallin painoihin (*weights*) parametriseksi muistiksi. Esimerkiksi 8B -malli (noin 8 miljardia parametria) vie kvantisoituna vain noin 4–5 GB levytilaa, kun sen kouluttamiseen on viety teratavuittain tekstiä. (Hassabis *ym.*, 2017)

Generatiivisten mallien “hallusinaatioiksi” kutsutut virheet ovat kuitenkin teknisesti johdonmukaisia: malli täydentää todennäköisimmän jatkon, ei välttämättä toden jatkon. Filosofisesti tämä muistuttaa pitkää kiistaa näennäisestä ja todellisesta tiedosta. Humen induktio-ongelma kertoo, että menneet havainnot eivät loogisesti pakota tulevia; Peircen abduktio lisää, että teemme parhaat arvaukset keskeneräisestä evidenssistä (Niiniluoto, 2002). Tekoälyn ongelmia analysoidaan tarkemmin luvussa 2.5.

Lopuksi voidaan nähdä, että tekoälymallit ovat aina myös eräänlaisia tieteellisiä mallinnuksia ihmisen mielestä, kuten on myös prediktiivinen koodaus -teoria. LLM tekoälymalli on aina malli ihmisen älykkyydestä, vaikka se käsitetään pääsääntöisesti työkaluna. LLM on kuin kehoton muistirakenne, joka heijastaa oppinutta tietoaan, joten tekoäly on kritiikistä huolimatta hyvin osuva termi asialle.

2.3.2 Kielimallien päättely

Yllättävän suuri osa ihmisten arkiajattelusta voidaan simuloida jo pelkällä todennäköisyysketjun jatkamisella; kieli itsessään kantaa sisällään rakenteita, tapoja ja maailmantietoa. Kuitenkin tietyissä tehtävissä, kuten monivaiheisessa päättelyssä, matemaattisissa ongelmissa tai juridisten ehtojen tulkinnassa, pelkkä “seuraavan sanan ennustaminen” ei riitä, vaan tarvitaan eksplisiittisempiä päättelyn rakenteita.

Tämän rajoitteen ratkaisemiseksi on kehitetty menetelmiä, jotka ohjaavat mallia muodostamaan eksplisiittisiä päättelyketjuja (engl. Chain-of-Thought, CoT). Tällöin malli ei tuota vastausta välittömästi, vaan generoi sarjan välivaiheita, joissa ongelma pilkotaan pienempiin osiin ennen lopullista johtopäätöstä. Ajatuksena on myös, että malli ei vain “arvaa oikeaa lausetta”, vaan tuottaa luonnollisella kielellä näkyville sen, miten se on päätynyt vastaukseen, joten samantyyppisesti kuin ihminen “ajattelee ääneen” ratkoessaan ongelmaa.

Korkealla tasolla *reasoning*-mallit voidaan nähdä kahtena kerroksena saman järjestelmän sisällä. Alimmalla tasolla on edelleen syväoppimiseen perustuva kielimalli, joka ennustaa seuraavia tokeneita valtavan parametrijoukon ja todennäköisyysjakaumien avulla. Sen päälle rakennetaan eksplisiittinen “päättelykerros”, joka ohjaa mallia tuottamaan rakenteellisesti pidempiä, vaiheittaisia vastauksia: malli ohjataan pilkkomaan teh-

tävä pienempiin osiin, tekemään välipäätelmiä ja tarkistamaan niitä. Samalla mallin tuotosta voidaan käyttää ikään kuin sisäisenä muistiinpano-tilana, jota seuraavat vaiheet lukevat ja hyödyntävät.

Toinen olennainen tekniikka on kehotus eli *promptaus*: käyttäjä tai järjestelmäkehittäjä pyytää mallia eksplisiittisesti “ajattelemaan vaiheittain” (“let’s think step by step”) tai tuottamaan ensin perustelut ja sitten erillisen loppuvastauksen.

Yhteenvetona voidaan todeta, että *reasoning*-mallit ja agentit siirtävät painopisteen pelkästä tuloksen ennustamisesta päättelyprosessin mallintamiseen. Ne tuovat näkyväksi osan siitä, mitä pidämme inhimillisessä ajattelussa tärkeänä: kyvyn perustella, pilkkoa ongelma vaiheisiin ja käyttää ulkoisia apuvälineitä kuten kynää, paperia tai ohjelmistoja: ajattelun jatkeena.

Tämä tekee niistä erityisen kiinnostavia myös sääntelyn ja läpinäkyvyyden näkökulmasta: mallin ei tarvitse antaa vain vastausta, vaan myös ”puhuu itselleen ääneen”, miten siihen päädyttiin.

2.3.3 Autonomiset agentit ja riskiprofiili

Klassinen agenttiteoria korostaa kolmea asiaa: autonomiaa (agentti ei ole pelkkä funktiokutsu, vaan tekee valintoja omien “sisäisten tilojensa” ja tavoitteidensa pohjalta), jatkuvaa vuorovaikutusta ympäristön kanssa sekä kykyä sopeutua muutoksiin ajassa. Moniagenttijärjestelmissä useat tällaiset agentit toimivat samassa ympäristössä; joskus yhteistyössä, joskus kilpailullisesti muodostaen abstrakteja ilmiöitä, joita ei voi palauttaa yhden agentin näkökulmaan (Wooldridge, 2002).

Perinteinen kielimalli ei vielä itsessään ole agentti. Toisin kuin perinteiset kielimallit, jotka toimivat passiivisina kysymys-vastaus-järjestelminä, tekoälyagentit (*AI Agents*) kykenevät autonomiseen toimintaan saavuttaakseen asetetun tavoitteen. Agenttiteoriassa autonomia määritellään järjestelmän kyvyksi operoida ympäristössään ja tehdä valintoja ilman jatkuvaa ihmisen ohjausta. Generatiivisen tekoälyn kontekstissa tämä tarkoittaa arkkitehtuuria, jossa kielimalli ei ainoastaan tuota tekstiä, vaan kykenee käyttämään ulkoisia työkaluja (*tool use*), suunnittelemaan monivaiheisia suorituspolkuja (*planning*) ja ylläpitämään muistia aiemmista toiminnoistaan.

Kun kielimallin ympärille rakennetaan rakenne, jossa sillä on

1. rooli tai profiili (esimerkiksi “asiantuntija-avustaja lääkärille”)
2. pysyvä muisti aikaisemmista havainnoista

3. pääsy työkaluihin ja ulkoisiin järjestelmiin (internet haku, tietokannat, laskenta, API-kutsut jne) sekä tärkeimpänä
4. kiertokulku, jossa se toistuvasti suunnittelee seuraavan askeleen, toimii ja havainnoi seuraukset, tekoälyjärjestelmästä tulee agentti.

Tyypillinen nykyaikainen LLM-agentti rakennetaan siten, että kielimalli saa syötteenään paitsi käyttäjän kysymyksen, myös kuvauksen omasta roolistaan, listan käytettävissä olevista työkaluista (esimerkiksi “web-haku”, “tietokantakysely”, “laskin”), lyhyen yhteenvedon menneistä tapahtumista (muisti) ja nykyisen tehtävän tavoitteen.

Sääntelyn ja erityisesti potilasturvallisuuden näkökulmasta agentit muodostavat merkittävän haasteen verrattuna staattisiin malleihin. Kun järjestelmälle annetaan toimijuutta; esimerkiksi oikeus tehdä ajanvarauksia, tilata laboratoriotestejä tai muokata potilastietoja: riskiprofiili muuttuu informatiivisesta operatiiviseksi. AI Act ja MDR korostavat ihmisen valvontaa (*human oversight*), mutta autonomisten agenttien kohdalla valvonta on vaikeampaa, sillä järjestelmän sisäinen päätösketju voi olla monimutkainen ja osin läpinäkymätön. Agenttien kyky ketjuttaa toimintoja voi johtaa tilanteisiin, joissa pieni hallusinaatio prosessin alussa kertaantuu merkittäväksi virheeksi lopputuloksessa ilman, että käyttäjä havaitsee virhettä prosessin aikana.

Yhteenvetona voidaan todeta, että viime vuosina LLM-pohjaisista agenteista on muodostunut kokonainen tutkimusala. Laajat katsausartikkelit jäsentävät kenttää kehikkoihin, joissa agentilla on LLM), havaintokerros, toimintakerros ja usein palaute- tai reflektiomekanismi; samalla erottuvat yksittäiset agentit, ihmisen kanssa toimivat *human-in-the-loop* -agentit ja moniagenttiset järjestelmät, joissa useat LLM-agentit neuvottelevat, tekevät kompromisseja tai simuloivat yhteiskunnallisia prosesseja (Wang *ym.*, 2024; Xi *ym.*, 2025). Näissä töissä agentti nähdään yhä useammin arkkitehtuurisena “superrakenteena” LLM:n ympärillä eikä vain uutena mallityyppinä.

2.4 Tekoälyjärjestelmät ja integraatiot sääntelykontekstissa

Tekoälysovellusten kehittämisessä on tehtävä selkeä käsitteellinen ja tekninen ero tekoälymallin (*AI model*) ja tekoälyjärjestelmän (*AI system*) välillä. Vaikka suuret kielimallit (LLM) muodostavat sovelluksen operatiivisen ytimen, ne ovat luonteeltaan stokastisia ja pelkistetyimmillään vain todennäköisyyksiä ennustavia laskennallisia moottoreita. Jotta tällaista moottoria voidaan käyttää turvallisesti ja luotettavasti korkean riskin ympäristössä, kuten terveydenhuollossa, se on ympäröitävä hallinta- ja valvontakerroksilla. Tätä kokonaisuutta kutsutaan yhdistelmätekoälyjärjestelmäksi (Compound AI System), jossa

kielimalli on vain yksi komponentti muiden ohjelmistojen, tietokantojen, käyttöliittymien ja sääntöjen joukossa. (Zaharia et al., 2024)

Tämä arkkitehtuurinen jako on keskeinen myös sääntelyn noudattamisen kannalta. Esimerkiksi Euroopan unionin tekoälyasetus rakentuu erottelulle yleiskäyttöisten mallien (GPAI) ja varsinaisten tekoälyjärjestelmien välillä. Myös OECD:n päivitetyt määritelmät korostavat järjestelmätasoa, jossa mallin toiminta sidotaan tiettyyn kontekstiin ja käyttötarkoitukseen. MDR näkökulmasta vaatimustenmukaisuus, riskienhallinta ja kliininen validointi kohdistuvat nimenomaan lopulliseen järjestelmään ja sen tuottamaan lopputulokseen, eivät pelkkiin mallin sisäisiin painokertoimiin. Tässä luvussa käsitellään niitä arkkitehtuurisia ratkaisuja ja optimointimenetelmiä, joilla stokastisesta kielimallista rakennetaan deterministinen, valvottu ja sääntelyn vaatimukset täyttävä järjestelmä.

Sääntely kohdistuu harvoin pelkkään malliin, vaan koko tekoälyjärjestelmään (AI System), kuten AI Act määrittelee. Sääntely otetaan tarkasteluun täsmällisemmin luvuissa 2.5, 2.6 ja 2.7.

2.4.1 Arkkitehtuurivalinnat, integraatiot ja tietosuoja

Tekoälyjärjestelmän arkkitehtuurivalinta, eli missä data fyysisesti prosessoidaan ja missä mallin parametrit sijaitsevat, on nykyisessä sääntely-ympäristössä (GDPR, AI Act, EHDS, nämä avataan myöhemmin) ensisijaisesti juridinen päätös, ei ainoastaan tekninen. Valinta julkisen pilven (SaaS), yksityisen pilven ja paikallisen (*Local*) toteutuksen välillä määrittää suoraan sovellettavan lainsäädännön, vastuukysymykset sekä tietoturvan hyökkäyspinta-alan. Luonnollisesti terveysdatan kanssa asia on kertaluokkaa kriittisempi.

Yleisin nykyinen tekoälyn toimitusmalli on *Software-as-a-Service (SaaS)*, jossa organisaatio lähettää datansa rajapinnan (API) yli palveluntarjoajan, kuten Microsoftin, OpenAI:n tai Googlen, hallinnoimaan infrastruktuuriin. Tietosuojan näkökulmasta tämä muodostaa merkittävän riskin, sillä data poistuu rekisterinpitäjän (esimerkiksi sairaalan) teknisestä kontrollista. Tavallaan siis tiedot voidaan epätietoisesti syöttää, mahdollisesti ulkoisten, privaattien tekoälymallien opetusdataksi esimerkiksi tiedustelupalveluiden käyttöön.

Pysytään nyt kuitenkin julkisissa tekoälymalleissa privaattien sijaan. Vaikka tietojenkäsittelysopimukset (DPA) juridisesti ”sitovat” palveluntarjoajaa, tekninen riski säilyy: data saatetaan tallentaa palveluntarjoajan lokeihin tai sitä voidaan käyttää siis julkisten LLM mallien jatkokouluttamiseen, jolloin luottamuksellinen tieto voi "palaa kiinni" mallin para-

metreihin ja paljastua myöhemmin toisille käyttäjille. Tästä varoittavana esimerkkinä toimii Samsungin tapaus vuodelta 2023, jossa työntekijöiden ChatGPT optimoitavaksi syöttämä luottamuksellinen lähdekoodi päätyi osaksi palveluntarjoajan koulutusdataa (Gurman, 2023). Lisäksi monivuokralaisissa (*multi-tenant*) pilviympäristöissä on havaittu haavoittuvuuksia, joissa ohjelmistovirheet ovat vuotaneet käyttäjien keskusteluhistorioita toisille asiakkaille (OpenAI, 2024). Tapauksia on runsaasti, eikä niitä ole tässä järkevää käsitellä lisää.

Eurooppalaisessa terveydenhuollon kontekstissa pilvipalveluiden käyttöä rajoittaa merkittävästi Euroopan unionin tuomioistuimen Schrems II -ratkaisu. Ratkaisu kumosi EU:n ja Yhdysvaltojen välisen Privacy Shield -järjestelyn todeten, että Yhdysvaltojen lainsäädäntö (erityisesti FISA 702) ei takaa eurooppalaisille henkilötiedoille riittävää suojaa tiedusteluviranomaisten pääsyltä (*Data Protection Commissioner v. Facebook Ireland Limited ja Maximillian Schrems*, 2020). Vaikka pilvipalveluntarjoaja sijoittaisi palvelimensa fyysisesti EU-alueelle (esimerkiksi Irlantiin), yhdysvaltalaisen emoyhtiön alaisena se on edelleen Yhdysvaltojen CLOUD Act -lain alainen. Tämä laki velvoittaa yhdysvaltalaiset palveluntarjoajat luovuttamaan hallussaan olevan datan viranomaisille riippumatta palvelimen fyysisestä sijainnista (Christakis, 2019). Tämä luo ns. suvereniteettiongelman: arkaluonteista potilasdataa käsittelevä organisaatio ei voi täysin taata tietosuojaa, mikäli inferenssiarkkitehtuuri nojaa ulkovaltojen pilviteknologiaan (Moldovanska, 2025). Suvereniteetti on kasvava ja tärkeä osa nykyistä teknologista pelikenttää.

Myös välimuotoisina pidetyt ratkaisut, kuten virtuaaliset työpöydät (CloudPC) tai mallivarastot, sisältävät piileviä riskejä. Vaikka CloudPC näyttäytyy käyttäjälle paikallisena työpöytänä, tekoälymallin ajaminen siellä tarkoittaa laskentaa palveluntarjoajan konesalissa. Data on taas alttiina samoille infrastruktuuritason riskeille kuin perinteisessä pilvessä. (NCSC, 2022)

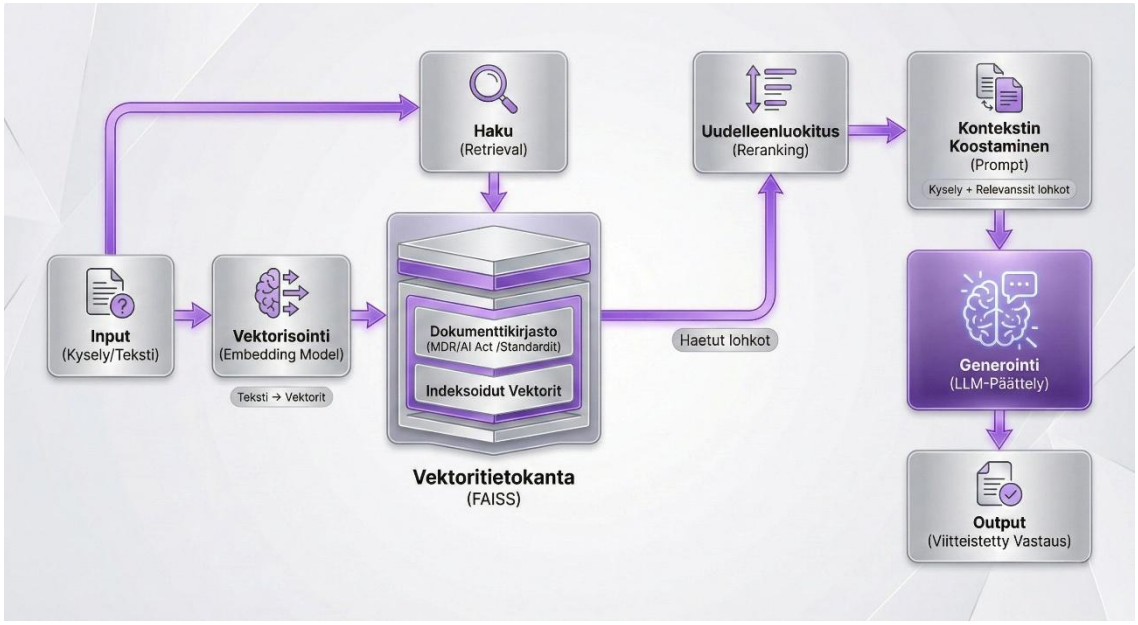
Pilviympäristöjen konfiguraatiovirheet ovat osoittautuneet massiiviseksi riskiksi: Microsoftin omat tekoälytutkijat altistivat vahingossa 38 teratavua dataa julkiseen internetiin väärin konfiguroidun SAS-tokenin vuoksi (Wiz Research, 2023). Vastaavasti Hugging Face -alustalta on löydetty tuhansia vuotaneita API-avaimia, jotka olisivat mahdollistaneet pääsyn yksityisiin malleihin ja koulutusdatoihin (Lasso Security, 2023).

Näiden havaintojen valossa paikallinen Local-First arkkitehtuuri, jossa malli ladataan ja ajetaan organisaation omassa, eristetyssä infrastruktuurissa, on ainoa oikea tapa toteuttaa GDPR:n oletusarvoisen tietosuojan (Privacy by Design) periaate täysimääräisesti. Kun data ei poistu laitteesta, poistuvat myös kansainvälisiin tiedonsiirtoihin, kolmannen

osapuolen virheisiin ja CLOUD Actiin liittyvät juridiset riskit. Sääntelyn ja potilasturvallisuuden näkökulmasta hyökkäyspinta-ala on paikallisessa ratkaisussa hallittavissa, kun taas pilviarkkitehtuureissa luottamus joudutaan ulkoistamaan.

2.4.2 RAG-arkkitehtuuri kielimallien dynaamisena muistina

RAG on ensimmäinen varsinainen tekoälymallien ympärille rakennettu matemaattinen ”laajennusosa”, jonka käyttö on standardia nykyisessä tekoälyssä monilla aloilla. Se on arkkitehtuuri ja käytännön toteutuskehys, jossa generatiivinen tekoälykielimalli kytketään suoraan tietolähteeseen erillisen upotus- ja hakuvaiheen kautta (Kuva 2). Näin malli ei perustu vain koulutuksessa mallin sisään talletettuun tietoon, vaan voi perustella vastauksensa haetuilla lähteillä, päivittää “tietonsa” ilman uudelleenkoulutusta ja toimia luotettavammin tiedonintensiivisissä tehtävissä. Klassinen määrittely esiteltiin Lewis et al. (2020) -työssä, jossa *seq-to-seq*-malli yhdistettiin tiheään vektori-indeksiin; tuloksena oli läpimurto avoimen kysymyksenvastauksen tarkkuudessa ja faktuaalisuudessa. Kun LLM generoi vastauksen RAG-putkessa, sen parametrit eivät muutu; se vain kysyy ei-parametriselta muistilta (vektoritietokannalta) ja ankkuroi vastauksensa palautettuun aineistoon.



Kuva 2: RAG-arkkitehtuurin yleinen tietovuo, jossa kielimalli (LLM) hyödyntää ulkoista vektoritietokantaa vastauksen ankkuroimiseen ja faktuaalisuuden parantamiseen.

Vektoritietokanta tarkoittaa tietokantajärjestelmää, joka tallentaa ja indeksoi valmiiksi lasketut vektoriesitykset matemaattiseksi esitykseksi. Data käännetään erillisellä *embedding* tekoälymallilla vektorimuotoon, eli koko datakannasta tulee vektoriesitys. Vektoritietokantaa voi ajatella “kielenä”, jota kone ymmärtää erityisen sujuvasti: kun tekstit on

upotettu $\mathbb{R}^d$-avaruuden vektoreiksi, kysely ja haku pelkistyvät matriisi- ja vektorilaskentaan (pistetulot, normit, lähinaapurit). (Lewis *ym.*, 2021; Gao *ym.*, 2023)

RAG-järjestelmän operatiivinen suoritusvaihe (*inference pipeline*) alkaa vaiheella, jossa käyttäjän syöttämä kysely muunnetaan numeeriseksi vektoriesitykseksi (*query embedding*) käyttäen samaa upotusmallia kuin tietokannan indeksoinnissa. Tätä seuraa tiedonhakuvaihe, jossa suoritetaan lähimmän naapurin haku (*Nearest Neighbor Search*) hyödyntäen samankaltaisuusmetriikoita, kuten kosinisimilaarisuutta, kyselyvektorin ja tietokantaan tallennettujen vektorien välillä.

Haun tarkkuuden maksimoimiseksi prosessiin voidaan integroida uudelleenluokitteluvaihe (*reranking*), jossa semanttisesti lupaavimpia dokumenttikatkelmia arvioidaan syvällisemmin niiden kontekstuaalisen relevanssin perusteella. Valitut tekstisegmentit muodostavat dynaamisen kontekstin, joka välitetään suurelle kielimallille (LLM) osana laajennettua kehotetta (*augmented prompt*). Tämän ankkurointiprosessin (*grounding*) seurauksena malli kykenee generoimaan faktapohjaisen vastauksen, joka on suoraan johdettu ja viitattu haetusta lähdemateriaalista. (Gao *ym.*, 2023)

Oikein rakennettuna (hyvä semanttinen/hybridihaku + järkevä paloittelu) RAG ei tuo vain “hieman parempia vastauksia”, vaan voi käytännössä nostaa tehtäväkohtaista tarkkuutta kymmenillä prosenttiyksiköillä verrattuna samaan LLM:ään ilman haku-komponenttia erityisesti tietointensiivisissä, domain-spesifeissä ympäristöissä kuten terveydenhuollossa.

RAG-arkkitehtuurin tarjoamista merkittävistä eduista huolimatta järjestelmään liittyy useita kriittisiä rajoitteita, jotka on huomioitava sen implementoinnissa ja validoinnissa. Ensinnäkin, suurten kielimallien rajallinen konteksti-ikkuna (*context window*) asettaa fyysisen rajan sille informaatiomäärälle, joka voidaan integroida mallin päättelyprosessiin samanaikaisesti. Toiseksi, järjestelmän suorituskyky on suoraan riippuvainen hakukomponentin onnistumisesta; mikäli hakuprosessi epäonnistuu relevanttien dokumenttien noutamisessa, generaatiovaihe ei kykene itsenäisesti korjaamaan puutteellista tietopohjaa tai vastaavasti voi hallusinoida sinne täyttääkseen tyhjät tiedot. Kolmanneksi, vaikka ankkurointi tietolähteisiin vähentää virheriskiä, kielimallit voivat silti yhdistellä hajanaista evidenssiä loogisesti virheellisellä tavalla, mikä korostaa totuudenmukaisuuden varmistamisen haastetta. Hallusinaatioista puhutaan luvussa 2.5 lisää. Viimeiseksi, järjestelmän tehokkuus on vahvasti sidoksissa aineiston esikäsittelyyn, kuten tekstin paloitteluun ja metadatastrategioihin. Puutteellinen segmentointi tai epätarkka indeksointi heikentää suoraan sekä tiedonhaun kattavuutta (*recall*) että vastauksen tarkkuutta (*precision*), jolloin tekniset esikäsittelyvalinnat nousevat kriittisiksi muuttujiksi järjestelmän kokonaisvaliditeetin kannalta. (Gao *ym.*, 2023)

2.4.3 RAG-putket sääntelykontekstissa

Euroopan unionin tekoälyasetuksen ja lääkinnällisten laitteiden asetuksen valossa RAG siirtää painopisteen pelkästä mallin sisäisestä logiikasta koko prosessiputken (*pipeline*) validointiin. Koko putken tarkastelu yhden komponentin sijaan on kriittistä terveydenhuollossa, jossa järjestelmän on kyettävä osoittamaan vastausten faktuaalinen alkuperä ja hallitsemaan hallusinaatioihin liittyviä riskejä.

RAG:n tuottama raportti ei saa tietenkään olla lopullinen päätös. Järjestelmässä on oltava käyttöliittymätaso, jolla ihminen voi ohittaa, hyväksyä tai korjata tekoälyn tuottaman sisällön. Tämä on RAG-järjestelmässä suoraviivaisempaa, koska RAG antaa sitaatit. RAG:n etu on jäljitettävyys: sääntely vaatii, että järjestelmä pystyy osoittamaan, mihin lähteeseen kukin väite perustuu.

Sääntelyllinen tarkastelu RAG-putkien osalta voidaan jakaa karkeasti kolmeen tasoon: datan hallintaan, läpinäkyvyyteen ja riskienhallintaan:

Datan hallinta ja laatu (AI Act, Artikla 10): RAG-arkkitehtuurissa vektoritietokanta muodostaa järjestelmän ei-parametrisen muistikomponentin, joka erottaa faktuaalisen tietosisällön kielimallin parametreihin tallentuneesta assosiatiivisesta logiikasta. Euroopan AI Act 10 artikla asettaa korkean riskin tekoälyjärjestelmille tiukkoja vaatimuksia käytettävän datan hallinnalle, edustavuudelle ja virheettömyydelle. RAG-putkessa tämä velvoite kohdistuu erityisesti tietokantaan indeksoitavaan materiaaliin ja hakuprosessin validointiin. (Artzt ja Dung, 2022)

Toisin kuin perinteisissä suljetuissa malleissa, joissa tieto on staattisena mallin painoarvoissa, RAG mahdollistaa tietokannan dynaamisen päivittämisen ilman laskennallisesti raskaista uudelleenkoulutusprosesseja. Tämä arkkitehtuurinen ratkaisu tarjoaa kaksi keskeistä etua sääntely-ympäristössä:

1. Läpinäkyvyys ja jäljitettävyys (AI Act, Artikla 13, 14 & MDR): Yksi RAG-toteutuksen merkittävimmistä eduista on sen kyky tuottaa viitteitä (*citations*) alkuperäislähteisiin kuten jo mainittiin. Tämä tukee suoraan sääntelyvaatimusta, jonka mukaan korkean riskin tekoälyjärjestelmän toiminnan on oltava tulkittavissa ja jäljitettävissä. Terveydenhuollon ammattilaiselle tämä mahdollistaa "human-in-the-loop" -periaatteen toteutumisen, kun tekoälyn ehdotukset voidaan verifioida välittömästi lähdemateriaalista.
2. Tekninen vankkuus ja virheiden hallinta: Sääntely (kuten ISO/IEC 23894) vaatii järjestelmän suorituskyvyn ja virhetilojen systemaattista arviointia.

Vuonna 2026 RAG-pohjaiset ratkaisut nähdäänkin osana laajempaa RegTech-kehitystä, jossa samaa arkkitehtuuria käytetään sääntelytekstien analysointiin ja vaatimustenmukaisuuden automatisointiin. Paikallisesti operoiva RAG-toteutus, jossa vektori-indeksointi ja haku tapahtuvat organisaation omassa infrastruktuurissa, on tällöin ainoa tapa täyttää GDPR:n ja Schrems II-ratkaisun asettamat tiukat tietosuojavaatimukset arkaluonteiselle terveystiedolle. (Umar *ym.*, 2025)

RAG-arkkitehtuuria voidaan terveydenhuollon sääntelyn näkökulmasta ajatella eräänlaisena “proto-regulaatiomoottorina”. Kun vektoritietokantaan indeksoidaan laaja joukko sääntelylähteitä; kuten MDR- ja IVDR-asetukset, AI Act, GDPR, komission ohjeistukset sekä keskeiset standardit, eli järjestelmä pystyy hakemaan kysymystä vastaavat säädös- ja standardikohtaiset “paloitellut” velvoitteet ja syöttämään ne kielimallille kontekstina. Tämä mahdollistaa kysymykset tyyliin “mitä MDR ja AI Act edellyttävät riskienhallintaprosessilta tässä laitekategoriassa?” sekä automaattiset tiivistelmät eri dokumenttien välillä.

Samalla arkkitehtuuri tukee jäljitettävyyttä: vastaus voidaan sitoa takaisin niitä tuottaneisiin säädöskohtiin, mikä on olennainen ehto terveydenhuollon regulaatiossa. Tuore tutkimus- ja kehitystyö osoittaa, että juuri tällaiset RAG-pohjaiset ratkaisut soveltuvat hyvin sääntelyasiakirjojen analyysiin ja vaatimustenmukaisuuden tarkistamiseen eri aloilla, kun taustalla on vektoritietokantaan rakennettu kerroksellinen tietomalli. Näin sama arkkitehtuuri toimii yleisenä perustana myöhemmässä luvussa kehitettävälle terveydenhuollon sääntelyn analysointi- ja automatisointialustalle. (Sun, Luo ja Li, 2025)

2.4.4 Laskennallinen tekstianalyysi

Jotta tekoälyjärjestelmät voivat luotettavasti analysoida ja kohdistaa sääntelytekstejä, sen on kyettävä muuhunkin kuin vain tekstin generoimiseen kielimalleilla. Tässä työssä esiteltävän analyysialustan taustalla olevia tekstianalyyttisiä metodeja:

Deterministinen rakenteistaminen (Regex): Analyysiputken perustana toimivat säännölliset lausekkeet, joiden avulla rakenteeton tekstidata muunnetaan koneellisesti analyysikelpoiseen muotoon. Niitä hyödynnetään säädösten klausuulien ja hierarkioiden tunnistamiseen, metadatan puhdistamiseen sekä lajitteluun. Tämä vaihe varmistaa datan eheyden ja sen, että myöhemmät vaiheet kohdistuvat asiasisällöllisesti ehyisiin kokonaisuuksiin. (Koreeda ja Manning, 2021)

Vektoriesitykset ja hybridihaku, joita myös usein käytetään RAG arkkitehtuureissa. (Dense & Sparse Retrieval):

Leksikaalinen haku ”Sparse” (kuten BM25-algoritmi) perustuu tarkkoihin sanaosumiin. Se on kuin perinteinen sanahaku: jos kaksi säädöstä käyttävät täsmälleen samaa sanaa "potilasturvallisuus", järjestelmä löytää ne. Tämä on sääntelytyössä kriittistä, sillä termien täsmällisyys on juridinen vaatimus. Pelkkä sanahaku on kuitenkin "sokea" merkitykselle; se ei ymmärrä, että "henkilötieto" ja "yksityisyyteen liittyvä informaatio" tarkoittavat usein samaa asiaa.

Semanttinen vastaavuus ”Dense” puolestaan pyrkii ymmärtämään tekstin sisältöä ja kontekstia. Tämä toteutetaan muuttamalla teksti numeerisiksi vektoreiksi, jolloin tekoäly voi laskea tekstien välisen "matemaattisen etäisyyden" merkitysavaruudessa. Mitä lähempänä kaksi klausuulia ovat toisiaan merkitykseltään, sitä pienempi on niiden välinen etäisyys, vaikka ne käyttäisivät eri sanoja.

Uudelleenluokittelu (Reranking): Koska vektorihaku on joskus epätarkka, käytetään ristiinkoodaajaa. Se suorittaa klausuulipareille syvällisen, token-tason ristiinvertailun (*cross-attention*), jossa kummankin tekstin sanojen väliset kontekstuaaliset suhteet analysoidaan samanaikaisesti. Tämä on laskennallisesti raskasta, mutta välttämätöntä sääntelytekstien pienten, mutta merkittävien vivahteiden erottamiseksi.

Klusterointi (Macro-level clustering): tapa hyödyntää ohjaamatonta oppimista asiasisällöltään samankaltaisten klausuulien automaattiseen ryhmittelyyn. Algoritmi sijoittaa tekstisegmenttien vektoriesitykset vektoriavaruuteen ja identifioi sieltä tihentymiä samankaltaisuuden kynnysarvoon perustuen. Tämä mahdollistaa laajan dokumenttimassan jäsentämisen teemoittain ilman etukäteen määriteltyjä luokkia, järjestelmä kykenee muodostamaan kunkin klusterin toisteisista vaatimuksista yhden synteettisen, kanonisen eli edustavimman kuvauksen. Tämä helpottaa makrotason ymmärryksen muodostamista ja poistaa sääntelylle tyypillistä informaatioähkyä. Mikäli analyysi kohdistuu vain kahden samankaltaisen dokumentin väliseen täsmälliseen vertailuun, klusterointivaihe ei ole pääosassa, ja painopiste siirtyy deterministiseen 1:1-kohdistukseen.

Graafiteoreettinen 1:1 kohdistus (Bipartite Matching): Kun ristiinkoodaaja on pisteyttänyt parhaat kandidaatit, järjestelmä siirtyy deterministiseen sovitusvaiheeseen. Jotta vältettäisiin sekava "kaikki kaikille" -tulos, käytetään kaksijakoista sovitusalgoritmia. Algoritmi tarkastelee klausuulien välisiä samankaltaisuuspisteitä ja valitsee "ahneella" (greedy) strategialla globaalisti parhaan kokonaisratkaisun. Näin jokainen klausuuli yhdistetään vain yhteen, sille todennäköisimpään vastineeseen.

Looginen päättely ja suuntaavuus (Directional NLI): Vaikka uudelleenluokittelu löytää merkitykseltään varmimmat vastinparit, pelkkä samankaltaisuus ei ota kantaa sääntelytekstien väliseen loogiseen suhteeseen (Koreeda ja Manning, 2021). Tämän ratkaisemiseksi analyysiputken huipulla käytetään luonnollisen kielen päättelyyn (Natural Language Inference) erikoistunutta toista ristiinkoodaajaa (kuten DeBERTa NLI -mallia). Se asettaa löydetyt klausuuliparit vuorotellen "premissin" ja "hypoteesin" rooleihin ja analysoi ne kumpaankin suuntaan selvittääkseen, onko kyseessä looginen seuraus, eli paljastaa nimenomaan asymmetrisen kattavuuden.

Versionvertailussa (Word-level diff) kahden saman säädöksen tai standardin eri versioiden väliset erot analysoidaan deterministisesti erikoistuneella tekstianalyysityökalulla. Työkalu suorittaa ensin tarkan klausuulitason matchingin (esimerkiksi tunnisteen ja tekstisamankaltaisuuden perusteella) ja luokittelee sen jälkeen muutokset systemaattisesti tekstuaalisiksi, semanttisiksi tai parametrisiksi muutoksiksi. Viimeiseksi DiffToken tyyppiset funktiot esittävät “kirurgisesti” sanatasolla, mitä on muuttunut pukemalla muutokset väreihin käyttöliittymässä. Tämä on viimeisenä putkessa, jos käyttäjä haluaa validoida itse eri versioiden tekstejä vaivattomasti, ilman pelkoa kielimallien hallusinaatioista.

Tämänkaltainen monivaiheinen lähestymistapa varmistaa, että järjestelmät ei ainoastaan "arvaa" vastaavuuksia, vaan suorittaa hierarkkisen analyysin sanatasolta logiikkaan asti.

2.5 Tekoälyn yleiset ongelmat, uhkakuvat ja tarpeet sääntelylle

Tilastollisesti katsoen ongelmia on monenlaisia. Yksi on suoraan datasetin, eli aineiston sisäänrakennettu vinouma. Tietyllä tavalla tekoälymallit ovat ”peilejä”, jotka peilaavat ihmisen ajattelua ja siten myös kulttuurien välisiä rajoja: eli jos tekoälyä koulutetaan pääosin eurooppalaisella aineistolla, se ”ajattelee” lähtökohtaisesti kuin eurooppalainen. Toisaalta tekoälyjen nykyinen ”*black box*” mentaliteetti vaikeuttaa niiden arvioimista, koska lähdedataa ei ole saatavilla. Tämä tarkoittaa läpinäkymätöntä järjestelmää, jota voidaan lähinnä tulkita sen syötteiden ja vastausten perusteella. Koska tekoälymallin koulutus on itsessään ”yksisuuntainen prosessi”, pelkästä mallista ei juuri koskaan voida palauttaa vastauksen alkuperäistä lähdettä tai sivunumeroa.

Laajojen kielimallien koulutusdatan alkuperä on myös herättänyt merkittäviä tekijänoikeudellisia ongelmia. Esimerkiksi Claude-tekoälyä kehittävä Anthropic epäiltiin ladanneen jopa 7 miljoonaa tekijänoikeuden alaista kirjaa luvattomista varjokirjastoista (kuten Library Genesis), joka lopulta ”rajattiin” 500000 kirjaan tuomioistuimessa. Asia päättyi

syksyllä 2025 historiallista kokoluokkaa olevaan 1,5 miljardin dollarin korvausratkaisuun. (*Bartz v. Anthropic PBC, 3:24-cv-05417 - CourtListener.com*, 2024; Kim, 2025)

Teknologisesta näkökulmasta tarkasteltuna kielimalli ei toimi perinteisen tiedonhaun deterministisellä logiikalla; se ei ole enää datasetti, josta faktoja voitaisiin poimia ”ctrl + F” -haun mekaanisella varmuudella. Todellisuudessa jokainen mallin tuottama lause on luonteeltaan rakennelma, konstruktio: tilastollinen ja stokastinen arvaus, joka sattuu olemaan faktuaalisesti oikeassa silloin, kun opetusdatan todennäköisyysjakauma on riittävän tiheä. Se selittää teknisesti, miksi malli on varma yleisissä faktoissa mutta arvailee ja hallusinoi marginaalisimmissa aihepiireissä. Tästä tilastollisesta luonteesta johtuu myös se, että kielimallit vastaavat samaan kysymykseen aina eri tavoin, ellei *temperature*-parametriä ole asetettu tasan arvoon 0. Tämä parametri onkin kenties kriittisin säätömekanismi mallin ohjaamisessa, sillä se määrittää ns. ”luovuuden” ja jos siihen asetetaan liian alhainen arvo, voi ajautua toistamaan samaa rakannetta kehämäisesti ”silmukkaan”. Eli temperature -säätöjen pitäminen korkeammalla tasolla on tietoinen päätös mitä tekoälyltä halutaan, mutta se myös tuo mukaan ”luovan arvailun” eli hallusinaation kuvioihin, mikä lopulta hämärtää rajan tiedon ja sepityksien väliltä. Muistetaanhan, että moderni kielimalli kuulostaa aina älykkäältä ja asiantuntevalta vaikuttavaa tekstiä täysin riippumatta siitä, onko väitteillä lainkaan todellisuuspohjaa.

Nykyisellään tekoälyn hallitsematon käyttö näkyy jo korkean tason raporteissa, sekä tutkimuksissa, mikä ilmenee esimerkiksi kielimalleille ominaisten sanavalintojen epätavallisena yleistymisenä tieteellisissä julkaisuissa. Yleisesti tämä käy selväksi esimerkiksi siitä, että tutkimuskielessä yhtäkkiä ”yllättäen” onkin alettu käyttämään tiettyjen tekoälymallien suosimia sanoja entistä enemmän, kuten ”*delve*” tai ”*realm*” (Masukume, 2024). Ongelma ei ole tekoälyn tuottaman materiaalin hyödyntäminen itsessään, vaan se, ettei tuotettua sisältöä enää välttämättä altisteta inhimilliselle tarkastukselle vaan sorrutaan automaatioharhaan. Tämä kulminoituu käytännön tasolla usein mekaaniseen, niin kutsuttuun *copy-paste*-menettelyyn, jossa tekoälyn generoima sisältö siirretään sellaisenaan osaksi virallista dokumentaatiota ilman asiantuntijan suorittamaa sisällöllistä validointia. Samaa virhettä toistetaan valtiotason kalliiden tutkielmien kanssa, kuten tapaus Deloitte ja Australian valtio (Gerard, 2025), ja myös valtamedian aikakausilehdet ovat sisältäneet toistuvasti jäännöksiä tekoälyn tuottamasta materiaalista.

Tämä lisää painetta siirtyä tehokkuudesta eteenpäin kohti luotettavuutta, erilaisiin sääntelyihin ja validointimekanismeihin jotta tekoälystä voisi todella kuoriutua luotettava päätöksenteon väline (Grace *ym.*, 2025). Luotettavuus on erityisen haastavaa kriittisillä aloilla, kuten terveydenhuollossa, jossa virheet maksavat pahimmillaan ihmishenkiä. Oi-

kein hyödynnettynä tekoälyjärjestelmä moninkertaistaa asiantuntijan analyysikapasiteetin, mutta ihmisen rooli tulosten kriittisenä validoijana on nykyisellään välttämätön järjestelmän luotettavuuden varmistamiseksi. Hallusinaatiot alkavat kiertää ja normalisoitua; luottamus internettiin ja tekstiin yleisesti kokee kolauksen jo valmiiksi sosiaalisten medioiden disinformaatiotulvan keskellä.

Tekoäly ei ole vain ohjelmistoteknologian ”seuraava vaihe”, vaan ilmiö, joka pakottaa yhteiskunnan määrittelemään uudelleen tiedon, vastuun ja työn käsitteet. Se toimii samanaikaisesti laskentana, hakukoneena, kommunikaationa ja päätöksentekona ja siksi sen vaikutus ulottuu politiikasta filosofiaan ja terveydenhuollosta taiteeseen. Teknologinen kehitys on tuonut tekoälyn käyttöön valtavat datamassat ja rinnakkaislaskennan voiman, mutta samalla herättänyt kysymyksen siitä, kuka ohjaa ja ymmärtää järjestelmiä, jotka pian oppivat nopeammin kuin niiden rakentajat.

Tulevaisuuden haaste ei ole niinkään tekoälyn rakentaminen, vaan sen hallinta: miten varmistamme, että se palvelee yhteiskuntaa yhtä viisaasti kuin tehokkaasti. Tehokkuus ei aina ole yksiselitteisesti hyvä asia, varsinkaan kriittisessä päätöksenteossa kuten terveydenhuollossa. Sääntely on varsinkin EU:n alueella yksi kerros vastaamassa alati nousevaan ongelmaan.

2.5.1 Stokastinen ennustaminen ja hallusinaatiot

Seuraavassa osuudessa esiteltävä formaalin matemaattisen logiikan (propositiokalkyyli, predikaattikalkyyli ja ZF-aksioomat) tiivistelmä on yksityiskohtainen. Sen tarkoituksena on havainnollistaa terävää kontrastia perinteisen, ehdottomiin ja todistettaviin sääntöihin perustuvan ohjelmistologiikan ja modernien tekoälymallien välillä.

Siis, jokainen LLM:n vastaama teksti on todennäköisyysjakaumaan perustuva arvaus, vaikka se olisikin usein erittäin todenmukainen arvaus, mikäli kouluttamisessa käytetty datasetti on koherentti ja laadukas. Klassinen matematiikka voidaan redusoida (palauttaa) formaaliksi järjestelmäksi, jossa totuus ei perustu ”intuitioon”, vaan merkkijonojen käsittelyyn tarkasti määriteltyjen sääntöjen mukaan. Havainnollistetaan klassisen matemaattisen logiikan ja neuroverkkojen ero seuraavaksi täsmällisesti ensinnä tiivistämällä logiikka.

Sääntöpohjainen matematiikka on todistettavissa formaalina järjestelmänä, jonka looginen arkkitehtuuri on seuraava.

A. Pohja: Propositiokalkyyli (Lauselogiikka)

Se käsittelee väitteiden totuusarvoja ilman, että se välittää väitteiden sisällöstä.

Operaattorit: ∧ (ja), ∨ (tai), ¬ (ei), → (implikaatio).

Sääntö (esim. Modus Ponens): Jos tiedämme, että P on tosi ja P→Q on tosi, voimme päätellä, että Q on tosi.

B. Runko: Predikaattikalkyyli (Ensimmäisen kertaluvun logiikka)

Tämä laajentaa lauselogiikan koskemaan objekteja ja niiden ominaisuuksia.

Kvanttorit: ∀ (kaikille), ∃ (on olemassa).

Muuttujat: x,y,z.

Predikaatit: P(x) (x:llä on ominaisuus P).

Tämä antaa meille kielen puhua "jostakin" tai "kaikesta".

C. Sisältö: Zermelo-Fraenkelin aksioomat (ZF)

Logiikka on vain tyhjä sääntökirja ilman pelinappuloita. ZF-joukko-oppi tarjoaa nämä nappulat.

Klassisessa matematiikassa kaikki ovat joukkoja. Luvut, funktiot ja geometriset kuviot määritellään joukkojen avulla.

Aksioomat: Nämä ovat "alkutotuuksia", joita ei todisteta. Esimerkiksi ekstensionaalisuus-aksiooma: Kaksi mitä tahansa joukkoa ovat samat, jos niillä on samat alkiot.

Yllä mainituilla metodeilla voidaan kuvata koko klassinen matematiikka. Vaikka Gödelin epätäydellisyyslauseet osoittivat, ettemme voi koskaan todistaa järjestelmää täydelliseksi sen itsensä sisältä, tämä "Logiikka + ZF" on edelleen se standardi, jonka päälle lähes kaikki nykymatematiikka on rakennettu.

Matemaattisen logiikan sijaan pelkkien LLM:n mallien toiminta ei ole formaalia logiikkaa. Tämä on yksi tekoälyn filosofian ja teknologian syvällisimmistä eroista. Lyhyesti: neuroverkot eivät sisäisesti käytä formaalia logiikkaa (kuten ZFC tai propositiologiikka), vaan ne käyttävät jatkuvaa matematiikkaa todennäköisyyslaskentaa kuten on aiemmin jo tässä teesissä todettu (Bishop, 2006). Neuroverkot kylläkin simuloivat loogista päättelyä etsimällä kielellisiä hahmoja (*patterns*) ja laskemalla todennäköisyyksiä.

Klassinen tietokoneohjelma tai matemaattinen todistus on symbolinen:

Sääntö: JOS (x > 5) niin (tulosta "Suuri"). Tämä on diskreettiä (on/off, tosi/epätosi).

Neuroverkko (kuten *transformer*) on sub-symbolinen:

Se ei sisällä yhtäkään IF-THEN -lausetta. Sen "logiikka" on valtava määrä desimaalilukuja (painokertoimia) ja todennäköisyyksiä.

Transformer-mallin sisäinen toiminta voidaan pelkistää yhteen matemaattiseen prosessiin: vektorimuunnoksiin korkeaulotteisessa avaruudessa, missä ydinerona voidaan sanoa että klassinen logiikka etsii totuutta, missä neuroverkko etsii tilastollista korrelaatiota minimoimalla virhettä.

Generatiivisten kielimallien tunnetuin ”virhe” on niin kutsuttu hallusinaatio: malli tuottaa näennäisesti vakuuttavaa, muodollisesti oikein jäsenneltyä tekstiä, joka on kuitenkin faktuaalisesti virheellistä tai täysin keksittyä. Riskinä ei ole pelkkä virhe, vaan virheen muoto: malli esittää vastauksensa samaan itsevarmaan sävyyn riippumatta siitä, onko taustalla luotettava tieto vai pelkkä tilastollinen arvailu. NIST:n (kyberturvallisuuskehykset) generatiivisen tekoälyn riskiprofiili korostaa (Tabassi, 2023), että tällainen epäluotettavuus on yksi keskeisistä generatiivisen tekoälyn riskikategorioista, koska se voi johtaa virheellisiin päätöksiin myös korkean riskin ympäristöissä.

Teknisenä ilmiönä hallusinaatio ei ole ”bugi”, vaan suora seuraus seuraavan tokenin ennustamiseen perustuvasta arkkitehtuurista. Jos opetusdatassa on aukkoja, ristiriitaisuuksia tai harvinaisia tilanteita, malli täyttää tyhjät kohdat tuottamalla todennäköisimmän jatkon: ei välttämättä totuudenmukaisinta. OECD:n generatiivista tekoälyä koskevat politiikkahuomiot korostavat, että mallien kyky tuottaa sujuvaa luonnollista kieltä hämärtää käyttäjän mahdollisuuksia erottaa ”todennäköinen” ja ”todellinen” tieto toisistaan. (Lorenz, Perset ja Berryhill, 2023)

Terveydenhuollossa tämä korostuu erityisesti: kliinistä päätöksentekoa tukevat mallit voivat ehdottaa uskottavan kuuloisia, mutta väärin viitteistettyjä hoitosuosituksia, olemattomia tutkimuksia tai vanhentuneita lääkeannostuksia. Malli ei ”tiedä valehtelevansa”, vaan jatkaa tekstiä tilastollisesti johdonmukaisella tavalla. Disinformaatiota lukeneen ihmisen kohdalla hänkin toistaa valheita, mutta yleensä ihmisestä voi arvioida kuinka auktoriteetti hän on ylipäätään ”tietämään” asiasta jotain. Tekoälyn kohdalla ongelma on monimutkaisempi, koska malli rakentaa oman tilastollisen maailmansa: version todellisuudesta, joka voi olla vääristynyt/ puutteellinen, mutta silti näyttää ulkoapäin ammattimaisen pätevältä. Tekoälyyn myös suhtaudutaan usein ”auktoriteettina”, toisin kuin valeinformaatiota puhuvan ihmisen koulutustausta voi olla yksi hyvä tapa arvioida hänen väitteitään.

Vaikka teknisen turvallisuuden puutteita pyritään usein paikkaamaan asettamalla ihminen osaksi päätöksentekoprosessia (*human-in-the-loop*), tämä ratkaisu sisältää merkittävän inhimillisen haavoittuvuuden. Kun järjestelmä on useimmiten oikeassa ja sen ulosanti on kielellisesti vakuuttavaa, käyttäjälle muodostuu helposti kognitiivinen vinouma, jota kutsutaan automaatioharhaksi (*automation bias*). Se tarkoittaa ihmisen taipumusta luottaa liiallisesti automatisoitujen järjestelmien tuottamaan tietoon, sivuuttaen samalla muista lähteistä tulevan ristiriitaisen tiedon tai jopa oman asiantuntijaharkintansa. (Qazi *ym.*, 2025)

Vastuu siirtyy väistämättä käyttäjälle ja organisaatiolle, joiden pitäisi pystyä validoimaan jokainen kriittinen vastaus. NIST:n AI RMF -kehys ja siihen liittyvä generatiivisen tekoälyn profiili ehdottavatkin hallusinaatioiden hallintaan muun muassa systemaattista verifiointia, korkean riskin käyttökohteiden rajaamista ja juurikin ”human-in-the-loop” -ratkaisuja.

Regulaation kannalta hallusinaatiot pakottavat tarkentamaan, milloin generatiivista mallia saa käyttää ensisijaisena tietolähteenä ja milloin se on vain apuväline, jonka tuottama teksti on aina sidottava tarkistettaviin lähteisiin. Myös esimerkiksi diagnoosien tekeminen on syytä poikkeuksetta jättää ihmisen lopulliselle vastuulle kyseisen ongelman takia.

2.5.2 Oppimisen datasettien tilastolliset rajoitteet: ylisovittaminen ja vinoumat

Koneoppimisen ja tekoälyn klassisimpia käytännön ongelmia on mallien yleistäminen eli kyky toimia oikein sellaisessa tilanteessa, jota ne eivät ole aiemmin nähneet. Jos malli oppii opetusaineiston liian tarkasti, se ei opi ilmiön rakenteita, vaan ainoastaan muistaa esimerkit ulkoa. Tätä ilmiötä kutsutaan ylisovittamiseksi (*overfitting*). Se on kuin opiskelija, joka osaa vastaukset ulkoa harjoituskokeesta, mutta epäonnistuu heti, kun kysymys muotoillaan eri tavalla. Tilastollisesti tämä tarkoittaa, että mallin ennusteiden varianssi kasvaa: se reagoi herkästi pieniin satunnaisiin poikkeamiin datassa, jotka eivät oikeasti kerro ilmiöstä mitään olennaista.

Ylisovittaminen liittyy suoraan tilastotieteen perusongelmaan: kuinka erottaa signaali kohinasta. Tilastollinen päättely pyrkii arvioimaan, mikä havainto on merkityksellinen ja mikä vain sattumaa. Jos malli on liian monimutkainen suhteessa havaintojen määrään tai laatuun, se alkaa tulkita kohinaa rakenteena. Tämä johtaa virheellisiin ennusteisiin ja joskus vaarallisiin päätöksiin, etenkin kriittisillä aloilla.

Koneoppimisen kannalta jonkinlainen *bias,* eli vinouma on väistämätön, koska data on aina jonkun tekemän valinnan tulosta: mitä mitattiin, mitä jätettiin pois ja millä tavoin asiat nimettiin. Tilastollinen vinouma ei siis ole pelkästään virhe, vaan ikkuna siihen, mitä yhteiskunta pitää tärkeänä. Tekoäly ei synnytä näitä vinoumia vaan se heijastaa niitä kylmästi ja tehokkaasti, ilman tietoista korjausta. Juuri siksi tilastollisen vinouman ymmärtäminen on tekoälyn luotettavuuden ja eettisen käytön perusedellytys.

Tällainen vinouma siis syntyy datan epätasapainosta. Jos malli oppii pääosin yhden ryhmän esimerkeistä, sen ennusteet vääristyvät toisten ryhmien kohdalla. Tämä ei ole pelkkä tekninen virhe, vaan heijastus todellisen maailman epätasa-arvoista: kone jatkaa sitä, mitä data sille opettaa (Mehrabi *ym.*, 2022). Tästä voidaan helposti nähdä, miksi tarvitaan laajaa aineistoa ja ollaan tilastollisen vinouman ytimessä, jos syötetty tieto on jo valmiiksi esimerkiksi rasistista, politisoitunutta tai data on jopa tarkoituksellisesti myrkytettyä (*data poisoning*) niin päädytään tilanteeseen, jossa ongelmat ovat sisäänrakennettuja malliin.

Tilastollinen vinouma tarkoittaa järjestelmällistä virhettä, joka vääristää mallin tai tutkimuksen tuloksia tiettyyn suuntaan. Toisin kuin satunnaisvirhe, *bias* ei häviä, vaikka havaintoja lisättäisiin: se on sisäänrakennettu näkökulmaharha datassa, menetelmässä tai jopa kysymyksenasettelussa. Esimerkiksi jos tekoälymalli opetetaan pääosin länsimaisten potilaiden terveystiedoilla, se saattaa ennustaa sairauksia heikommin muista väestöryhmistä. Malli ei tee “virhettä” teknisessä mielessä, vaan toimii täsmälleen niin kuin sen data opetti – vääristyneesti. (Mehrabi *ym.*, 2022)

Bias on siis tilastotieteen näkökulmasta valikoituneen tiedon ongelma, ja samalla esimerkiksi psykologiassa kysymys siitä, mitä pidetään “tyypillisenä”. Psykologiassa on havaittu, että jo kysymyksen muoto voi ohjata vastauksia: jos ihmiseltä kysytään “Kuinka tyytyväinen olet elämääsi?” ennen kuin häneltä kysytään “Kuinka usein seurustelet ystävien kanssa?”, vastaus korreloi sosiaalisen aktiivisuuden kanssa, mutta jos kysymysten järjestys käännetään, korrelaatio katoaa. Tämä tunnetaan *framing effect* -ilmiönä, ja se koskee myös tekoälyä. Tavanomaisesti tätä kutsutaan johdatteluna. Datassa on aina olemassa jonkinlaista vääristymää ihan jo kielen rakenteen takia.

2.5.3 Dynaamiset elinkaaririskit: Datan kierre ja mallin heikkeneminen ajassa

Siinä missä ylisovittaminen ja vinoumat ovat mallin koulutusvaiheeseen ankkuroituja rakenteellisia puutteita, mallin suorituskyvyn heikkeneminen (*model drift*) sekä datan kierre edustavat tekoälyjärjestelmän elinkaaren dynaamista ja ajallista riskiä. Katsotaan nämä läpi seuraavaksi.

1. Datan kierre on yksi tilastollinen uhkakuva.

Tekoälyn tuottaman materiaalin eksponentiaalinen lisääntyminen internetissä on luonut uuden, systeemisen riskin tulevaisuuden kielimallien kehitykselle. Koska nykyiset mallit on koulutettu pääosin ihmisen tuottamalla, historiallisella datalla, ne kykenevät heijastamaan luonnollisen kielen ja ilmiöiden rikasta varianssia. Ongelma muodostuu, kun tulevien sukupolvien malleja aletaan kouluttaa yhä enenevissä määrin datalla, joka on jo edellisten tekoälymallien tuottamaa. Tätä ilmiötä kutsutaan mallin romahdukseksi (*model collapse*). (Shumailov *ym.*, 2025)

Tilastollisesti ilmiö tarkoittaa negatiivista takaisinkytkentäsilmukkaa (*feedback loop*), jossa alkuperäisen datan todellinen todennäköisyysjakauma alkaa vääristyä. Kun tekoäly tuottaa tekstiä, se suosii jakauman keskellä olevia, korkeimman todennäköisyyden ulostuloja ja karsii pois harvinaisempia ilmiöitä (ns. hännät eli *tail events*). Kun tämä kaventunut, synteettinen data syötetään uuden mallin koulutusaineistoksi, mallin ymmärrys maailman monimuotoisuudesta supistuu entisestään. Useiden iteraatioiden jälkeen malli kadottaa kykynsä tuottaa merkityksellistä ja monimuotoista sisältöä, ja sen tuottama tieto muuttuu homogeeniseksi ja virhealttiiksi. Informaatioteoreettisesta näkökulmasta järjestelmän entropia laskee keinotekoisesti, mikä tuhoaa mallin kyvyn yleistää reaalimaailman monimutkaisia rakenteita.

2. LLM mallin suorituskyvyn heikkeneminen ajassa (*model drift*) edustaa tekoälyjärjestelmän elinkaaren dynaamista ja ajallista riskidimensiota.

Vaikka mallin koulutusdata olisi staattinen, sen suorituskyky käyttöympäristössä voi heikentyä ilmiöllä nimeltä *model drift*. Vuonna 2026 tästä on muodostunut tekoälytutkimuksen keskeinen operatiivinen haaste varsinkin, kun järjestelmiä käytetään terveydenhuollon kaltaisessa kriittisessä infrastruktuurissa. (Chen, Zaharia ja Zou, 2023)

Drift voidaan jakaa tässä kahteen päätyyppiin:

Ensinnäkin mallin siirtymä *model drift*: syötedatan jakauma muuttuu (esim. potilaspopulaation demografian tai diagnostiikkamenetelmien muuttuessa), jolloin malli kohtaa tilanteita, joita se ei enää tunnista. Toisekseen: käsitteellinen siirtymä (*concept drift*): Syötteen ja tavoiteltavan lopputuloksen välinen suhde muuttuu (esim. lääketieteellisten hoitosuositusten päivityttyä), jolloin mallin "äly" antaa lääketieteellisesti vanhentuneita vastauksia.

Drift on kuin kompassi, joka alkaa näyttää asteen verran väärään suuntaan joka kuukausi. Jos sitä ei kalibroida säännöllisesti, järjestelmä voi vuoden päästä ohjata käyttäjän täysin virheellisiin päätelmiin.

Lopulta tekoälyn “äly” on tilastollista todennäköisyyttä, ei varmaa tietoa. Siksi sen tuottamat vastaukset on ymmärrettävä aina arvioina, ei totuuksina. Tilastotiede muistuttaa meitä, että jokainen malli on vain hypoteesi siitä, miltä maailma näyttää datan kautta katsottuna.

2.5.4 Tietoturva, tietosuoja ja mallien manipulointi

Tässä ongelma ei liity pelkästään mallin sisäiseen tilastolliseen vinoumaan vaan siihen, kuinka helposti mallin käyttäytymistä voidaan tarkoituksellisesti manipuloida. Suurten kielimallien suojamekanismeja voidaan kiertää niin sanotuilla *jailbreak*-hyökkäyksillä tai *prompt injection* -tekniikoilla, joissa hyökkääjä muotoilee syötteen siten, että malli sivuuttaa sille asetetut turvarajat. Yhdistyneen kuningaskunnan AI Safety Institute on osoittanut, että useiden kaupallisten mallien turvamekanismit voidaan kiertää suhteellisen yksinkertaisilla kehotteilla, minkä seurauksena mallit suostuvat esimerkiksi kuvailemaan kyberhyökkäyksiä, tuottamaan haitallista koodia tai rakentamaan uskottavia disinformaatiosisältöjä – tai suoraan vaikka paljastamaan arkaluontoista dataa ”vahingossa” aineistosta.

UK:n ”Frontier AI: capabilities and risks” -raportti korostaa, että edistyneet generatiiviset mallit voivat huomattavasti laskea kynnystä monimutkaisten hyökkäysten suunnitteluun ja suorittamiseen (*Frontier AI: capabilities and risks – discussion paper*, 2025). Raportissa kuvataan skenaarioita, joissa mallit voivat tukea muun muassa automatisoitua tietojenkalastelua, tarkasti kohdennettuja sosiaalisen manipuloinnin kampanjoita ja haittakoodin kehittämistä siten, että aiemmin korkeaa osaamistasoa vaatineet hyökkäykset muuttuvat keskitasoisen hyökkääjän ulottuville.

Kolmas keskeinen ongelma liittyy siihen, mistä tekoälymallit ovat oppineet ja mitä ne voivat siksi vuotaa ulos. Generatiivinen tekoäly perustuu massiivisiin datakokonaisuuksiin, jotka on usein kerätty verkosta ilman, että yksittäisillä rekisteröidyillä olisi realistista mahdollisuutta ymmärtää tai hallita omien tietojensa käyttöä. Eurooppalaiset tietosuojaviranomaiset ovat jo puuttuneet tähän: Italian tietosuojavaltuutettu on määrännyt sakkoja sekä Replika-chatbotin kehittäjälle, että OpenAI:lle muun muassa sillä perusteella, ettei henkilötietojen käyttöä mallien koulutukseen ole perusteltu asianmukaisella käsittelyperusteella, eikä rekisteröidyille ole annettu riittävää läpinäkyvyyttä tai tehokkaita ikärajasuojauksia.

Eurooppalaisten tietosuojavastaavien yhteistyöjärjestö CEDPO on korostanut generatiivisen tekoälyn tietosuojavaikutuksia koskevassa kannanotossaan, että riskit eivät rajoitu pelkkään koulutusvaiheeseen. Henkilötietoja voidaan vuotaa myös mallin ulostuloista – esimerkiksi silloin, kun malli rekonstruoi yksittäisen potilaan kaltaisia profiileja, toistaa

verkosta poimittuja tekstikatkelmia tai yhdistää erillisistä lähteistä peräisin olevia tietoja uudella tavalla. Siksi CEDPO painottaa muun muassa tietosuojan sisäänrakentamista (*privacy by design*), vaikutustenarviointeja (DPIA) ja koulutus- sekä inferenssivaiheen erottelua hallinnollisesti ja teknisesti. (CEDPO AI Working Group, 2023)

Teknisesti mallien tietovuotoihin liittyy myös niin sanottuja *model inversion* ja *membership inferenc*e -hyökkäyksiä, joissa hyökkääjä pyrkii päättelemään, onko tietty henkilö tai tietue ollut mukana koulutusdatassa, tai rekonstruoimaan koulutusdatan piirteitä mallin vasteista. Teolliset ohjeistukset, kuten suurten pilvipalvelutoimijoiden generatiivista tekoälyä koskevat turvallisuussuositukset, pitävät näitä hyökkäyksiä olennaisena riskiluokkana ja korostavat, että generatiivinen tekoäly tuo perinteisen tietosuojan lisäksi uuden kerroksen – mallitasolla tapahtuvan vuotoriskin. (AWS, 2025)

Terveydenhuollossa tämä yhdistyy GDPR:n erityisiin suojavaatimuksiin terveystiedoille. Jos kielimalli koulutetaan tai hienosäädetään potilasdatalla, jokainen myöhempi kysely voi periaatteessa toimia kanavana, jonka kautta malliin koodattu tieto tihkuu ulos yksittäisiä tapauksia muistuttavina esimerkkeinä. Tällöin koulutusdatan läpinäkymättömyydestä tulee eettinen ja oikeudellinen ongelma: potilas ei voi realistisesti tietää, missä kaikkialla hänen tietojaan mallin ”muistiin” on upotettu, eikä organisaatio välttämättä pysty vastaamaan rekisteröidyn oikeuksiin (esimerkiksi oikeus tulla unohdetuksi) pelkällä perinteisellä tietokantapoistolla.

2.5.5 Tulevaisuuden ongelmia: riippuvuus, osaamisen rapautuminen ja järjestelmätason haavoittuvuus

Tekoälyn käyttöönotto ei synnytä vain yksittäisiä teknisiä riskejä, vaan myös uudenlaista riippuvuutta: sekä yksilö- että järjestelmätasolla. Kun päätöksenteko integroidaan yhä tiiviimmin tekoälyjärjestelmiin, vaarana on, että ammattilaisten oma arviointikyky ja taitotaso heikkenevät vähitellen, ja organisaatiot alkavat nojata ”mustaan laatikkoon” tavalla, josta ei ole helppo perääntyä.

UNESCO:n generatiivista tekoälyä koskeva ohjeistus koulutukseen ja tutkimukseen varoittaa eksplisiittisesti kahdesta ilmiöstä: toisaalta opiskelijoiden ja opettajien liiallisesta riippuvuudesta generatiivisista työkaluista, toisaalta osaamisen rapautumisesta (*deskilling*), jos analyysi- ja kirjoitustyö ulkoistetaan liiaksi malleille (*Guidance for generative AI in education and research* | *UNESCO*, 2023). Vaikka konteksti on koulutus, ongelma on rakenteellisesti sama terveydenhuollossa: jos kliiniset päätökset, dokumentointi ja potilasviestintä kulkevat järjestelmällisesti tekoälyn kautta, osa ammatillista osaamista siirtyy

hiljalleen järjestelmään itseensä. Tällöin kriittinen kysymys ei ole vain ”toimiiko malli oikein nyt”, vaan ”mitä tapahtuu, jos malli yhtenä päivänä ei ole käytettävissä” lainkaan.

NIST:n AI Risk Management Framework korostaa, että tekoälyjärjestelmä on aina osa laajempaa sosioteknistä kokonaisuutta, jossa ihmiset, prosessit ja teknologia kietoutuvat toisiinsa. Yksi tunnistetuista riskiluokista on *automation bias* joka esiteltiin jo aiemmin (Tabassi, 2023). Terveydenhuollossa tämä voi tarkoittaa esimerkiksi sitä, että lääkäri ei enää kyseenalaista järjestelmän antamaa diagnoosiehdotusta tai riskiluokitusta, vaikka potilaan kokonaistilanne viittaisi muuhun. NIST:n generatiivisen tekoälyn profiili laajentaa tätä huolta koskemaan myös malleja, joiden käyttäytyminen on dynaamista ja vaikeammin ennustettavaa.

Regulaation näkökulmasta riippuvuus- ja *deskilling*-ongelma kytkee yhteen useita periaatteita. NIST ja OECD korostavat molemmat, että luotettava tekoäly edellyttää organisatorista resilienssiä: kykyä ylläpitää ihmisten osaamista, vaihtoehtoisia prosesseja ja läpinäkyvää dokumentaatiota myös tilanteissa, joissa tekoälyjärjestelmä ei ole käytettävissä tai sen toiminta joudutaan keskeyttämään. Terveysalalla tämä tarkoittaa esimerkiksi sitä, että kriittisiin tehtäviin ei saa syntyä ”mallimonopolia”, jossa kliinistä toimintaa ei voida jatkaa ilman tiettyä suljettua järjestelmää tai yksittäistä kaupallista mallia. Tämä on Euroopan unionin riippuvuuden suurimpia ongelmia. EU on riippuvainen ei ainoastaan Yhdysvaltojen kielimalleista, mutta myös pilvipalveluista, vaikka Euroopassa on voimakkaita tekoälytoimijoita, kuten Mistral. (Widder, West ja Whittaker, 2023)

Tämän vuoksi olisi tärkeää pitää *open-source* ajattelu päällimmäisenä. Kriittiset järjestelmät pitäisikin olla ehdottomasti avoimia jo aivan yleisenkin turvallisuuden takia. Nykyinen kapitalismikilpa ja superälyn tavoittelun kilpajuoksu ei varsinaisesti helpota tätä.

2.6 Terveydenhuolto digitalisaatiosta tekoälyyn

Kuten on kuvattu, tekoälyn suhde terveydenhuoltoon on haastava ja se tarvitsee tiukan sääntelykehyksen, mutta samaan aikaan terveydenhuolto nähdään alana, jolla tekoälyllä on suurinta potentiaalia. Ei tietenkään ainoastaan kielimalleilla, mutta yleisesti tekoälyteknologian, kuten esimerkiksi visuaalisen hahmontunnistuksen, mutta niitä ei tässä työssä käsitellä rajauksen takia lainkaan. Tässä tutkielmassa keskitytään LLM-teknologiaan.

2.6.1 Terveydenhuolto murroksessa

Terveydenhuolto elää samanaikaisesti kahta murrosta. Yhtäältä väestö ikääntyy Euroopassa, krooniset sairaudet yleistyvät ja henkilöstöpula pahenee. Toisaalta digitaalinen

data, tekoäly ja erityisesti generatiiviset mallit juurtuvat yhä syvemmälle kliiniseen arkeen. Näiden trendien risteyskohdassa terveydenhuollosta tulee yhä riippuvaisempi IT-järjestelmistä, kun samaan aikaan kun sääntely kiristyy ja vaatimukset turvallisuudesta, läpinäkyvyydestä ja jäljitettävyydestä kasvavat.

Terveydenhuoltojärjestelmä on 2020-luvulla yhtä aikaa taloudellisen, demografisen, teknologisen ja sääntelyyn liittyvän murroksen keskellä. OECD:n tuore Health at a Glance 2023 -katsaus kuvaa, kuinka terveysmenot ovat pysyneet korkealla pandemian jälkeen (keskimäärin 9,2 % BKT:sta vuonna 2022) (OECD, 2023), samalla kun palvelutarve kasvaa väestön ikääntymisen ja kroonisten sairauksien lisääntymisen seurauksena.

Samanaikaisesti raportissa nostetaan ensimmäistä kertaa esiin digitaalinen terveys “nousevana terveyden määrittäjänä”, mikä korostaa digiratkaisujen merkitystä sekä hoidon saatavuuden että järjestelmän kestävyyden kannalta. Vaikka digitalisaation tavoitteena on prosessien tehostaminen, sähköiset järjestelmät voivat tosiasiassa lisätä kliinisen työn kuormitusta ja synnyttää uusia virhelähteitä. Modernissa keskustelussa on päivänselvää, että esimerkiksi digitaaliset potilastietojärjestelmät tuottavat lääkäreille ja terveydenhuollon ammattilaisille monesti kohtuutonta lisätyötä. Kaikki ei vielä ole valmista edes digitalisaation käyttöönotossa, mutta samaan aikaan digitalisaation rinnalla vyöryy tekoälyn vallankumous.

2.6.2 Eurooppalainen datasääntely

Murrosta syventää se, että terveydenhuolto ei enää ole vain kansallinen järjestelmä, vaan yhä selkeämmin osa eurooppalaista datasääntelyn ja tekoälyregulaation kokonaisuutta. Euroopan terveysdatan tilaa koskeva asetus (European Health Data Space, EHDS) muodostaa ensimmäisen sektorikohtaisen EU:n datasääntelykehyksen, jonka tavoitteena on sekä parantaa yksilöiden mahdollisuuksia hallita omaa sähköistä terveystietoaan että mahdollistaa datan laaja toissijainen käyttö tutkimuksessa, innovaatiotoiminnassa ja sääntelyssä. EHDS on ensimmäinen nimenomaan terveysdataan kohdistuva, sektorikohtainen datasääntelykehikko.

EHDS-asetus (EU) 2025/327 kytkee terveydenhuollon rakenteellisesti uuteen, EU-laajuiseen dataekosysteemiin: sähköisille potilastietojärjestelmille, tietojärjestelmien yhteentoimivuudelle ja datan toissijaiselle käytölle asetetaan yksityiskohtaisia vaatimuksia, ja tarjoajat joutuvat käytännössä suunnittelemaan palvelurakenteensa niin, että potilasdata liikkuu läpi koko hoitoketjun standardoidussa, koneellisesti hyödynnettävässä muodossa. (*European Health Data Space Regulation (EHDS) - Public Health*, 2025)

EHDS-asetus on rakennettu laajemman yleisen tietosuoja-asetuksen (General Data Protection Regulation, GDPR) pohjalle, joka toimii kaikelle henkilökohtaiselle datalle lähtökohtana. Vaikka GDPR:ää on hiljalleen ajateltu pehmennettäväksi, se on edelleen nykyisellään tiukka vaatimus yksityisyydestä EU:n alueella. EU:n yleinen tietosuoja-asetus (*General Data Protection Regulation*, GDPR, asetus (EU) 2016/679), joka muodostaa horisontaalisen perustan kaikelle henkilötietojen käsittelylle, myös tekoäly- ja datavetoisissa järjestelmissä. GDPR luonnehtii terveyttä koskevat tiedot erityiseksi henkilötietoryhmäksi (*special category data*) ja asettaa niiden käsittelylle korotetun suojan: terveysdataa saa käsitellä vain poikkeusperusteiden nojalla ja lähtökohtaisesti ainoastaan silloin, kun se on välttämätöntä terveyden- ja sosiaalihuollon palvelujen järjestämistä, potilasturvallisuutta tai tutkimusta ja muuta yleistä etua varten.

GDPR ei siis ole vain “yksi sääntelykehikko muiden joukossa”, vaan perustuslakimainen taustakerros, joka rajaa sitä, millaista dataa voidaan ylipäätään kerätä, millä oikeusperusteella sitä voidaan käyttää ja millaisia suojatoimia (kuten pseudonymisointi, minimointi ja vaikutustenarvioinnit) on toteutettava erityisesti terveysdatan kohdalla.

Kuitenkin, jos ei huomioida CLOUD Actia, muodollisesti terveydenhuollossa GDPR tarkoittaa, että kaikki myöhemmät sektorikohtaiset säätelyt, kuten EHDS ja tekoälyasetus, joutuvat toimimaan GDPR:n puitteissa sen sijaan, että ne korvaisivat tai löysentäisivät tietosuojavaatimuksia.

Käytännössä GDPR ja EHDS tarkoittavat, että hyvinvointialueiden ja muiden terveydenhuollon toimijoiden on samanaikaisesti:

1. täytettävä GDPR:n vaatimukset lainmukaisesta käsittelyperusteesta, erityisiin henkilötietoryhmiin liittyvistä poikkeusperusteista ja tietoturvasta
2. rakennettava järjestelmänsä siten, että ne noudattavat EHDS:n asettamia teknisiä ja organisatorisia standardeja datan yhteentoimivuudelle, standardoinnille ja hallitulle uudelleenkäytölle.

Tämä kaksoisrooli tekee terveysdatasta samaan aikaan sekä arvokkaan resurssin (tutkimus, innovaatiot, tekoälyn koulutus) että tiukasti säännellyn riskikohteen, jossa yksilön perusoikeudet ja järjestelmän kehittäminen täytyy sovittaa yhteen.

GDPR:n vaikutus terveydenhuollossa on ennen kaikkea sitä, että moni “tekninen yksityiskohta” muuttuu juridiseksi velvoitteeksi. Käytännössä terveydenhuollon toimijoiden on pystyttävä osoittamaan, kuka on päässyt potilastietoihin, milloin ja millä perusteella: lokitietojen, pääsynhallinnan ja riskiperusteisen suojauksen (mm. salaus, käyttöoikeuksien rajaus, auditointi) on oltava dokumentoidusti kunnossa (GDPR artiklat 5, 9, 30, 32

ja 35). Tämä tarkoittaa muun muassa systemaattisia vaikutustenarviointeja (DPIA) laajamittaiselle terveysdatan käsittelylle, erillisten suostumusten hallintaa silloin, kun käsittely perustuu suostumukseen, sekä sitä, että myös ulkoiset järjestelmätoimittajat ja pilvipalvelut on sidottava tiukkoihin henkilötietojen käsittelyä koskeviin sopimuksiin.

Euroopan unioni, osittain riippuvaisena Yhdysvalloista, rikkoo mahdollisesti itse omia säännöksiään (GDPR) käyttämällä muita kuin eurooppalaisia pilvipalvelualustoja datan säilyttämiseen ja prosessointiin. (*European Commission's use of Microsoft 365 infringes data protection law for EU institutions and bodies | European Data Protection Supervisor*, 2026). Tätä on jälkeenpäin yritetty tietenkin korjata, mutta sama ongelma on edelleen.

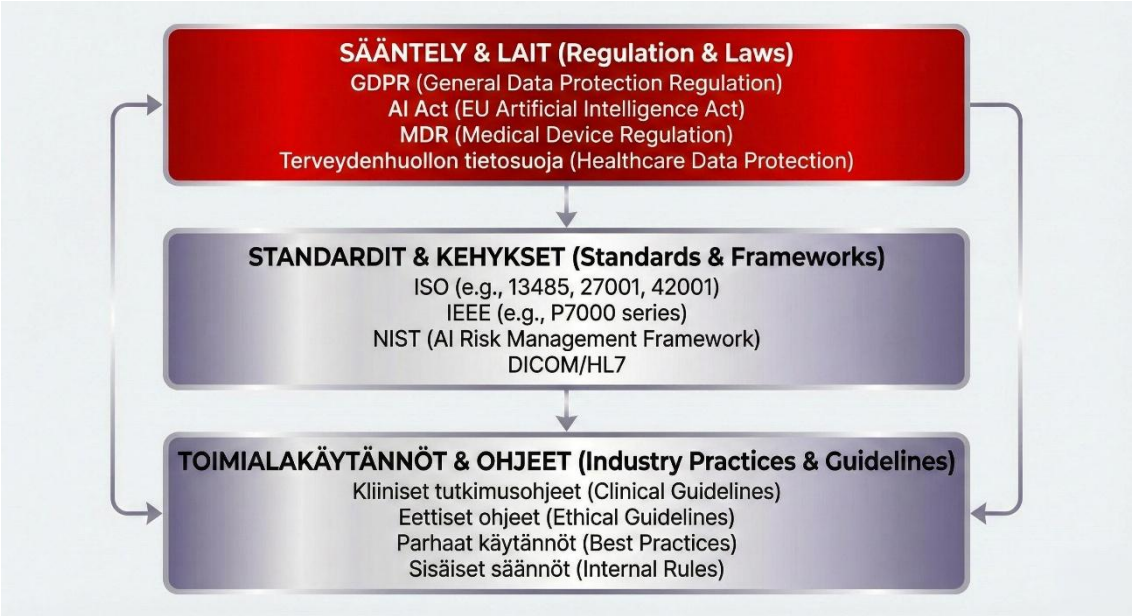
2.7 Kielimallien sääntelykehykset ja lainsäädäntö terveydenhuollossa

Tekoälyasetuksen (Artificial Intelligence Act, AIA asetus EU 2024/1689) voimaantulo ei muuta aikaisempaa sääntelyn perustilannetta, vaan lisää kolmannen kerroksen: korkean riskin tekoälyjärjestelmiä koskevat vaatimukset (mm. riskienhallinta, datan laatu, ihmisen valvonta ja läpinäkyvyys) tulevat sovellettaviksi erityisesti niissä terveydenhuollon sovelluksissa, jotka tukeutuvat potilasdataan, mutta kysymys datan käsittelyn lainmukaisuudesta ratkaistaan edelleen ensisijaisesti GDPR:n ja sitä täydentävän EHDS-sääntelyn kautta. Tämä korostaa sitä, että terveydenhuollon tekoälyä ei voida tarkastella irrallaan datasääntelystä: kielimallien käyttö kliinisessä kontekstissa on aina samanaikaisesti tekoäly- ja tietosuojakysymys.

Vaikka tekoälyasetus (AI Act) asettaa suoria vaatimuksia korkean riskin tekoälyjärjestelmien tarkkuudelle ja kyberturvallisuudelle, terveydenhuollon kontekstissa niitä täydentää horisontaalinen NIS2-direktiivi (EU 2022/2555). Siinä missä AI Act kohdistuu tuotteen ja mallin tekniseen vankkuuteen, NIS2 velvoittaa terveydenhuollon toimijat varmistamaan koko toimintaympäristön ja toimitusketjun kestävyyden.

2.7.1 Sääntelykentän kokonaiskuva

Kielimalleihin (LLM) kohdistuva sääntely rakentuu useasta kerroksesta (Kuva 3).



Kuva 3: Tekoälyn sääntelykentän kerroksellinen rakenne, joka koostuu horisontaalisesta lainsäädännöstä, teknisistä standardeista ja toimialakohtaisista kliinisistä ohjeista.

EU:ssa pino rakentuu yleisestä mallitasosta (GPAI/LLM) ja järjestelmätasosta (sovellus/AI-järjestelmä). AI Act määrittää mallitasolle läpinäkyvyyden, dokumentaation ja tekijänoikeuksien kunnioittamisen sekä systeemisen riskin malleille tiukat lisävelvoitteet (mm. malliarvioinnit ja vahinkoraportointi); aikataulut olivat/ovat 2.8.2025 (velvoitteet), 2.8.2026 (EU-tason täytäntöönpano) ja 2.8.2027 (siirtymä aiemmille malleille). Terveydenhuollossa tämä kerrostuu MDR/IVDR-menettelyihin ja EHDS-tietokehikkoon, MDCG 2025-6 selkeyttää yhteispeliä.

Vaatimusten operationalisointia tukevat ISO/IEC 42001, ISO/IEC 23894 ja NIST AI RMF (GAI-profiili 2024), ja lääkkeiden elinkaaren osalta EMA (Euroopan lääkevirasto) on linjannut periaatteet. Näin muodostuu konkreettinen polku LLM-ratkaisujen todennettavaan, jäljitettävään ja hallittuun käyttöön terveydenhuollossa.

1. Horisontaalinen AI-sääntely ja lait, joka määrittävät yleiset pelisäännöt kaikille tekoälyjärjestelmille ja malleille EU:ssa (EU AI Act 2024/1689) sekä kansainvälinen ihmisoikeuskehikko (Euroopan neuvoston tekoälysopimus) ja tietysti GDPR, joka toimii koko säätelyn peruskalliona. (*Regulation (EU) 2024/1689 of the European Parliament and of the Council of 13 June 2024 laying down harmonised rules on artificial intelligence and amending Regulations (EC) No 300/2008, (EU) No 167/2013, (EU) No 168/2013, (EU) 2018/858, (EU) 2018/1139 and (EU) 2019/2144 and Directives 2014/90/EU, (EU) 2016/797 and (EU) 2020/1828 (Artificial Intelligence Act) (Text with EEA relevance)*, 2024)

2. Sektorisääntely, joka terveydenhuollossa tarkoittaa erityisesti lääkinnällisten laitteiden asetusta ja in vitro -diagnostiikan asetusta IVDR sekä EHDS-asetusta, joka harmonisoi terveystiedon käyttöä ja toissijaista hyödyntämistä. Näiden rinnalle nousee NIS2-direktiivi, joka velvoittaa terveydenhuollon "erittäin kriittisenä toimialana" varmistamaan infrastruktuurinsa ja tekoälypohjaisten toimitusketjujensa kyberresilienssin.
3. Tekniset standardit ja hallintamallit, joilla operoidaan riskienhallintaa, prosesseja ja todennettavuutta (ISO/IEC 42001:2023 AI-hallintajärjestelmä; ISO/IEC 23894:2023 AI-riskienhallinnan ohjeistus; NIST AI RMF 1.0 sekä vuoden 2024 Generative AI -profiili). (ISO, 2023)

Tekoälyyn keskittyvä eurooppalainen standardointikomitea CEN-CENELEC JTC 21 kehittää parhaillaan harmonisoituja standardeja (*European AI Standardization | CEN-CENELEC JTC 21* |, 2024), joiden tarkoituksena on tukea EU:n tekoälyasetuksen toimeenpanoa. Alla luonnostyylinen havainnollistus tulevasta;

1. Riskienhallintajärjestelmä (Risk Management System)

Tämä standardi määrittelee prosessit, joilla tunnistetaan, arvioidaan ja hallitaan tekoälyjärjestelmien aiheuttamia riskejä terveydelle, turvallisuudelle ja perusoikeuksille. Se kattaa koko elinkaaren suunnittelusta käytöstä poistamiseen.

2. Hallinto ja laadunhallintajärjestelmä (Governance and QMS)

Tämä on "sateenvarjostandardi", joka asettaa vaatimukset organisaation sisäisille prosesseille. Se varmistaa, että tekoälyjärjestelmän tarjoajalla on käytössään asianmukaiset resurssit, vastuut ja menettelytavat (mukaan lukien markkinoiden jälkeinen valvonta).

3. Data ja datan hallinta (Data and Data Governance)

Standardi asettaa laatuvaatimukset opetus-, validointi- ja testausaineistoille. Keskiössä on varmistaa, että data on edustavaa, virheetöntä ja että mahdolliset vinoumat (*bias*) on tunnistettu ja minimoitu syrjinnän ehkäisemiseksi.

4. Lokin pito ja tallentaminen (Logging and Record-keeping)

Tässä määritellään tekniset vaatimukset sille, mitä tapahtumia tekoälyjärjestelmän on tallennettava automaattisesti. Tavoitteena on varmistaa jäljitettävyys ja se, että järjestelmän toimintaa voidaan analysoida mahdollisten häiriöiden tai vaaratilanteiden jälkeen.

5. Avoimuus ja käyttäjille annettavat tiedot (Transparency and Information to Users)

Tämä standardi varmistaa, että tekoälyjärjestelmät on suunniteltu riittävän läpinäkyviksi. Käyttäjien on ymmärrettävä, miten järjestelmä toimii, mikä on sen tarkoitus ja mitkä ovat sen rajoitteet tai mahdolliset virhelähteet.

6. Ihmisen suorittama valvonta (Human Oversight)

Standardi antaa ohjeet siitä, miten järjestelmään rakennetaan "ihminen silmukassa" -mekanismeja. Tarkoituksena on antaa ihmiselle mahdollisuus puuttua tekoälyn toimintaan, keskeyttää se tai ohittaa sen tekemät päätökset kriittisissä tilanteissa.

7. Tarkkuus, vikasietoisuus ja kyberturvallisuus (Accuracy, Robustness and Cybersecurity)

Tässä määritellään mittarit ja testimenetelmät sille, kuinka tarkasti järjestelmä suoriutuu tehtävästään, miten se sietää virheitä tai poikkeuksellisia syötteitä (robust) ja miten se on suojattu ulkopuolisilta hyökkäyksiltä.

8. Vaatimustenmukaisuuden arviointi (Conformity Assessment)

Nämä standardit kuvaavat ne menettelyt, joilla yritys itse tai ulkopuolinen taho varmistaa ja todentaa, että tekoälyjärjestelmä täyttää kaikki sille asetetut vaatimukset ennen markkinoille saattamista. Uusimpien tietojen mukaan sääntelyä sujuvoitettiin siirtämällä täytäntöönpanon takarajaa elokuuhun 2028 ja sallimalla vaatimustenmukaisuuden arvioinnin integrointi osaksi olemassa olevia MDR- ja IVDR-prosesseja (Chen, 2026). Vaikka varsinaisia turvallisuusvaatimuksia ei lievennetty kuten aluksi spekuloitiin (*Proposal for a regulation to simplify rules on medical and in vitro diagnostic devices - Public Health*, 2026), uudistus vähensi valmistajien hallinnollista taakkaa mahdollistamalla teknisen dokumentaation ja markkinoille saattamisen menettelyjen yhdistämisen

2.7.2 Yleiskäyttöisten kielimallien (GPAI/LLM) velvoitteet

Käsitteellisesti aluksi on hyvä erottaa AI-järjestelmät ja yleiskäyttöiset AI-mallit (GPAI), joihin suurimmat kielimallit kuuluvat. OECD päivitti AI-järjestelmän määritelmänsä 2023–2024, ja se on heijastunut EU-kehyksiin; päivitys korostaa järjestelmien autonomian ja adaptiivisuuden vaihtelua sekä mallien kontekstisidonnaisuutta.

EU AI Act on voimassa oleva horisontaalinen asetus, joka sisältää erillisen lukunsa yleiskäyttöisille AI-malleille. Keskeiset vaatimukset LLM/GPAI-malleille ovat seuraavia:

Läpinäkyvyys ja tekninen dokumentaatio: Mallin tarjoajan on ylläpidettävä teknistä dokumentaatiota ja toimitettava tietoja sekä viranomaisille (AI Office) että mallia hyödyntäville toimijoille. Lisäksi edellytetään julkinen koulutussisällön yhteenveto (template julkaistu)

sekä tekijänoikeuslain noudattamista koskeva politiikka. (”Article 53: Obligations for Providers of General-Purpose AI Models | EU Artificial Intelligence Act”, 2025)

Systemisen riskin mallit (GPAI-SR): Malli katsotaan lähtökohtaisesti systemisen riskin malliksi, jos koulutuksessa käytetty kumulatiivinen laskentateho ylittää 10^25 FLOPs; tällöin vaatimukset laajenevat malliarviointeihin, vastatestaamiseen, vakavien tapausten raportointiin, kyberturvavaatimuksiin ja riskienhallintaan. Komissio voi nimetä systemisen riskin malleja myös vaikutuskriteerien perusteella. (*Article 51 - Classification of general-purpose AI models as general-purpose AI models with systemic risk*, 2025)

Lokitus ja alkuperä teknisistä velvoitteista: Teknisesti sisältöjen alkuperä- ja muutosketjun hallintaan on kaksi päälinjaa:

1. provenienssi eli sisältötodisteet (esim. allekirjoitettu metatieto, sisältötodiste-manifestit)
2. detektio (vesileimat, sormenjäljet).

NIST:in katsauksen mukaan mikään yksittäinen menetelmä ei ole täydellinen: tarvitaan yhdistelmiä, laajaa käyttöönottoa ja koordinoituja standardeja, ja menetelmät on sovitettava käyttötapaukseen. Esimerkiksi C2PA-standardi määrittelee avoimen, kryptografisesti sidotun Content Credentials -mallin, jolla sisällön alkuperä ja muokkaushistoria voidaan sitoa itse teokseen ja tarkistaa ketjussa. Tätä voitaisiin mahdollisesti hyödyntää lohkoketjujen AI Act lokituksen lähtökohtana (*Content Credentials : C2PA Technical Specification*, 2025).

Sääntelyn näkökulmasta tämä muodostaa kaksikerroksisen vaatimuksen:

1. läpinäkyvyys tulosteissa (AI Act, artikla 50: merkinnät ja tunnisteet sekä tunnistamisen mahdollistaminen)
2. läpinäkyvyys ja vastuu mallitasolla (GPAI-velvoitteet: dokumentaatio, tekijänoikeuspolitiikka, koulutusdatan yhteenveto).

Alustavelvoitteet (DSA) täydentävät kuvaa varmistamalla, että järjestelmätason riskit, kuten vaaleihin kohdistuva tekoälyavusteinen informaatiovaikuttaminen: tunnistetaan ja niitä lievennetään. Kokonaisuus edellyttää siksi sekä teknisiä ratkaisuja että hallinnollisia ja sopimuksellisia kontrollikehyksiä, jotka yhdessä ylläpitävät informaatiovakautta.

Aikataulut ja siirtymät: GPAI-velvoitteet tulivat sovellettaviksi 2.8.2025; Komission AI Office valvoo GPAI-velvoitteita EU-tasolla ja saa täysimääräiset täytäntöönpanovaltuudet 2.8.2026; ennen 2.8.2025 markkinoille tuoduilla malleilla on aikaa 2.8.2027 saakka päi-

vittää vaatimustenmukaisuus. Kuitenkin sääntely-ympäristö on yhä muotoutumisvaiheessa, ja siirtymäaikojen puitteissa on odotettavissa lainsäädännöllisiä tarkennuksia. (”Overview of Guidelines for GPAI Models | EU Artificial Intelligence Act”, 2025)

Komissio on julkaissut GPAI Code of Practice -toimintakoodin (10.7.2025) sekä ohjeet GPAI-velvoitteiden soveltamisalasta, jotka täsmentävät mm. dokumentoinnin sisältöä, mallien luokittelua ja mallikohtaisten riskienhallintatoimien arviointia. Koodi on vapaaehtoinen, mutta se tarjoaa käytännöllisen polun vaatimusten täyttämiseen läpinäkyvyyden, tekijänoikeuksien ja turvallisuus/kyberturvan osalta.

2.7.3 Terveydenhuollon erityiskysymykset: MDR/IVDR ja AI Act -yhteispeli, EHDS ja FRIA

Onko LLM “lääkinnällinen laite” on lähtökohtainen kysymys terveydenhuollon tekoälysovelluksissa. Jos kielimallia käytetään diagnoosiin, ennusteeseen, ”triageen” tai hoitosuosituksiin ja se tukee kliinistä päätöksentekoa laitteen tarkoituksenmukaisen käytön puitteissa, kyse on tyypillisesti lääkinnällisestä ohjelmistosta, jolloin soveltuvat MDR/IVDR-vaatimukset (luokittelu, kliininen arviointi, QMS, jälkimarkkinaseuranta). Uusi MDCG 2025-6-ohje selventää nimenomaisesti AI Actin ja MDR/IVDR:n yhteispeliä sekä sitä, miten AI Actin vaatimukset (datan hallinta, läpinäkyvyys, ihmisen valvonta, post-market-velvoitteet sisällytetään olemassa oleviin laatujärjestelmiin ja arviointiprosesseihin. (Joint Artificial Intelligence Board, 2025)

EU:n EHDS-asetus (2025/327) tuo kerroksen, joka koskee terveystiedon ensisijaista ja toissijaista käyttöä (mm. tutkimus ja innovaatiot) sekä tiedon jakamisen teknisiä ja organisatorisia järjestelyjä. Kielimallien kehittämisessä ja käyttöönotossa se tarkoittaa konkreettisia vaatimuksia pääsynhallintaan, suostumuksiin/poikkeuksiin, tietojen toissijaisen käytön portteihin ja tietoturvaan. (*Regulation (EU) 2025/327 of the European Parliament and of the Council of 11 February 2025 on the European Health Data Space and amending Directive 2011/24/EU and Regulation (EU) 2024/2847 (Text with EEA relevance)*, 2025)

FRIA (*Fundamental Rights Impact Assessment*): AI Act edellyttää tietyiltä korkean riskin sovelluksilta perusoikeusvaikutusten arviointia ennen käyttöönottoa, erityisesti kun toimijana on julkinen sektori tai yksityinen taho julkisen palvelun tuottajana. Terveydenhuollossa FRIA tulee kyseeseen, jos LLM-järjestelmä kuuluu AI Actin korkean riskin kategorioihin (esim. palvelujen saatavuuteen/kohteluun vaikuttavat päätökset), ja se linkittyy usein GDPR:n DPIA-menettelyihin. (”Article 27: Fundamental Rights Impact Assessment

for High-Risk AI Systems | EU Artificial Intelligence Act", 2026) Tämä on pitkä prosessi EU:ssa tuotekehitykselle (Taulukko 1)

Tietosuoja ja läpinäkyvyys käytännössä: EDPB:n (EU:n tietosuojaneuvoston) vuoden 2024 ChatGPT-työryhmän raportti ja AI-malleja koskeva lausunto korostavat, että generatiivisten mallien koulutus ja käyttö tuovat esiin erityiskysymyksiä oikeusperusteesta, tietojen alkuperästä, läpinäkyvyydestä ja oikaistavuudesta ja tietysti terveydenhuollossa nämä korostuvat entisestään. (*Report of the work undertaken by the ChatGPT Taskforce | European Data Protection Board*, 2024)

Taulukko 1: Lääkinnällisten laitteiden havainnollistava regulaatioprosessi.

Vaihe	Kuvaus	Arvioitu kesto	Pullonkaulat ja riskit
1. Tuotekehitys ja laatujärjestelmä (QMS)	Käyttötarkoituksen määrittely, riskiluokittelu, teknisen tiedoston (Technical File) kokoaminen ja ISO 13485 -laatujärjestelmän pystyttäminen.	6–12 kk	Oikean riskiluokan määrittäminen. Tekoälymallin opetusdatan dokumentointi ja läpinäkyvyysvaatimukset (AI Act).
2. Kliininen arviointi ja tutkimukset	MDR:n vaatiman kliinisen näytön kerääminen laitteen turvallisuudesta ja suorituskyvystä.	6–24+ kk	Kirjallisuuskatsauksen riittävyys (retrospektiivinen data) suhteessa tarpeeseen suorittaa uusia prospektiivisia kliinisiä tutkimuksia.
3. Ilmoitetun laitoksen (NB) arviointi	Riippumattoman ilmoitetun laitoksen suorittama laatujärjestelmän ja teknisen dokumentaation auditointi ja hyväksyntä.	13–18 kk	Rajallinen kapasiteetti (51 hyväksyttyä laitosta): resurssien pitäisi jatkossa riittää myös tekoälyarviointeihin.

4. Viranomaisrekisteröinti (EUDAMED)	Laitteen, UDI-tunnisteiden ja talouden toimijoiden rekisteröinti EU:n EUDAMED-tietokantaan.	1–2 kk	Vuodesta 2026 alkaen EUDAMED-rekisteröinti on ehdoton edellytys markkinoille saattamiselle.

On kuitenkin huomioitava, että kielimallien dynaaminen luonne haastaa perinteisen lääkinnällisten laitteiden staattisen sertifiointiprosessin. Tekoälyasetuksen 12 artiklan (lokin pito) ja MDR:n jälkimarkkinaseurannan (PMS) välinen yhteispeli korostuu, kun mallin suorituskykyä on valvottava jatkuvasti kliinisessä käytössä. Erityisen kriittistä on tunnistaa mallin suorituskyvyn rappeutuminen (*model drift*, esiteltiin aiemmin) tai hallusinaatioiden lisääntyminen ajan myötä, mikä edellyttää laadunhallintajärjestelmältä jatkuvaa validointia perinteisen pistekohtaisen hyväksynnän sijaan (Chen, Zaharia ja Zou, 2023), mitä käsiteltiin luvussa 2.5 tarkemmin. Lisäksi AI Actin painottama "ihmisen suorittama valvonta" kytkeytyy terveydenhuollossa suoraan lääkärin oikeudelliseen vastuuseen; järjestelmän on oltava selitettävissä ja läpinäkyvä (Artikla 13), jotta kliinikko kykenee itsenäisesti arvioimaan ja tarvittaessa ohittamaan kielimallin tuottaman suosituksen.

Sääntely-ympäristön dynaamisuutta ja pyrkimystä hallinnollisen taakan keventämiseen kuvaa Euroopan komission tuore esitys MDR ja in vitro -diagnostiikkaan tarkoitettujen laitteiden sääntöjen yksinkertaistamisesta (*Proposal for a regulation to simplify rules on medical and in vitro diagnostic devices - Public Health*, 2026). Esityksen keskiössä on pyrkimys sujuvoittaa erityisesti tekoälyä sisältävien lääkinnällisten laitteiden markkinoille saattamista selkeyttämällä AI Actin ja lääkinnällisten laitteiden säädöskehyksen välistä rajapintaa. Strategisesta näkökulmasta esitys heijastaa vastausta tässä tutkimuksessa aiemmin tunnistettuun "regulaatiotaakkaan", joka on muodostunut merkittäväksi esteeksi erityisesti pienten ja keskisuurten yritysten innovaatioille.

Summataan vielä EU ja USA:n eroja lopuksi: Yhdysvalloissa terveydenhuollon tietojärjestelmiä säädellään eri painotuksin kuin EU:ssa. EU:n lainsäädäntö (GDPR, MDR, IVDR) korostaa tietosuojaa, potilasturvallisuutta ja riskienhallintaa, kun taas Yhdysvaltain malli (Cures Act, HIPAA, ONC Final Rule) painottaa tiedon liikkuvuutta ja potilaan oikeutta saada oma tietonsa käyttöön.

2.7.4 Standardit ja hallintamallit terveydenhuollossa

Organisaation AI-hallinta: ISO/IEC 42001:2023 määrittää AI-hallintajärjestelmän (AIMS) vaatimukset ja ohjeet. Sitä voidaan pitää tekoälyjärjestelmien vastineena tietoturvan ISO 27001 -standardille, joka kattaa menettelytavat (*policy*), roolit, riskienhallinnan, dokumentoinnin ja jatkuvan parantamisen. Standardi soveltuu kuitenkin etupäässä tekoälyjärjestelmien käyttäjäorganisaatioille, eikä se valmistajien osalta sellaisenaan takaa AI Actin vaatimustenmukaisuutta, vaikka se tarjoaakin sopivan selkärangan velvoitteiden toiminnallistamiseksi. (ISO, 2023)

Riskienhallinta: ISO/IEC 23894:2023 antaa AI-spesifin riskienhallinnan prosessiohjeen (riskin tunnistus–arviointi–hallinta–seuranta). Terveydenhuollossa tämä kytketään laitepuolen ISO 14971 -riskikehykseen; käytännössä järjestelmällinen linkitys AI-riskeistä kliinisiin riskeihin on edellytys vaatimustenmukaisuudelle (ISO, 2024). EU-kontekstissa sääntelyn tueksi on nousemassa harmonisoitava tekoälyn riskienhallintastandardi prEN 18228, joka tulee osaltaan yhtenäistämään AI Actin asettamien vaatimusten käytännön toteutusta. (*CEN - CEN/CLC/JTC 21*, 2026)

NIST AI RMF 1.0 ja Generative AI -profiili (2024): NISTin kehikko jäsentää Govern–Map–Measure–Manage -elinkaaren, ja heinäkuun 2024 Generative AI -profiili tarkentaa LLM-spesifejä riskejä (hallusinaatiot, tietovuodot, väärinkäytöt), mittareita ja hallintatoimia. Nämä ovat käyttökelpoisia viitepohjia myös EU-ympäristössä, kunhan ne kytketään AI Actin ja MDR/IVDR:n vaatimuksiin. (Tabassi, 2023)

Lääkekehityksen ja valmisteiden elinkaaren näkökulma: EMA:n 2024 reflection paper kokoaa periaatteet AI/ML:n käytölle lääkkeen koko elinkaaressa (kehitys, arviointi, tuotanto, post-authorisation) (European Medicines Agency, 2024). Se korostaa validointia, data- ja mallin laatua, ihmisen valvontaa ja kommunikointia, jotka ovat relevantteja myös LLM-pohjaisissa ratkaisuissa (esim. kliinisen tiedon hallinta).

Vertailu sääntelyihin Yhdysvalloissa; FDA julkaisi 2024–2025 PCCP-lopullisen ohjeen (Predetermined Change Control Plan) AI-/ML-laitteiden iteratiivisia muutoksia varten, tämä mahdollistaa ennakkoon hyväksytyt päivityspolut ilman uutta markkinointilupaa jokaiselle muutokselle. Se on linjassa AI Actin ajatuksen kanssa elinkaarisesta valvonnasta ja post-market-seurannasta. (*FDA Finalizes Guidance on Predetermined Change Control Plans for AI-Enabled Medical Device Software | Insights | Ropes & Gray LLP*, 2024)

3. TUTKIMUSMENETELMÄT JA AINEISTO

Tämä diplomityö on luonteeltaan suunnittelutieteellinen (*design science*) tapaustutkimus, jossa yhdistetään laadullinen sekä määrällinen dokumenttianalyysi, ja konstruktiivinen järjestelmäkehitys. Tutkimuksen tavoitteena on sekä jäsentää sääntelyaineistoa että rakentaa tutkimusinstrumentiksi paikallinen, klausuulitasolla (vaatimukset, säädöskappale tai pykälä) toimiva tekoälyanalyysialusta. Menetelmävalinta perustuu tarpeeseen hallita kompleksista sääntelykehikkoa ja vähentää manuaalista vertailutyötä säilyttäen samalla analyysin läpinäkyvyyden ja auditointivalmiuden. Tutkimus eteni iteratiivisen "rakenna ja arvioi" -syklin mukaisesti. Aineiston ja koneellisesti tuotetun analyysin välisiä suhteita oli tarkasteltava huolellisesti manuaalisesti rinnakkain aktiivisen ohjelmistokehityksen kanssa.

Laadullinen dokumenttianalyysi ankkuroi työn sääntelykehykseen (luvut 2.5–2.7), kun taas konstruktiivinen osuus konkretisoi, miten sarja koneoppimismalleja, kielimalleja ja yleisemmin vektorihakua voidaan hyödyntää käytännön RegTech-ratkaisuna. Tässä luvussa keskitytään periaatteisiin ja kriteereihin, jotka ohjasivat toteutusta.

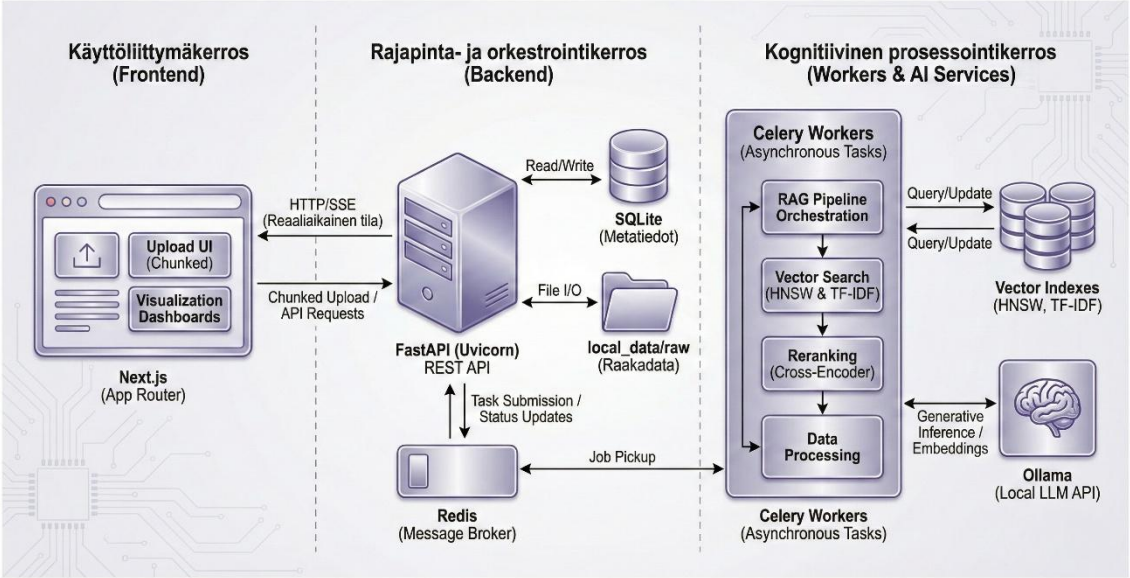
3.1 Arkkitehtuuri ja teknologiavalinnat

Järjestelmän arkkitehtuurin ja teknologiavalintojen ensisijaisena tavoitteena on ollut rakentaa tutkimusinstrumentti, joka kykenee käsittelemään monimutkaista sääntelyaineistoa toistettavasti ja tietoturvallisesti. Keskeinen suunnitteluperiaate on tiukka ”Local-First”-arkkitehtuuri, jossa sovellus ja kaikki sen suorittama kielellinen laskenta tapahtuvat paikallisessa infrastruktuurissa ilman riippuvuuksia ulkoisista pilvipalveluista. Tämä ratkaisu on valittu vastaamaan terveydenhuollon ja sääntelytyön tiukkoja tietosuoja-vaatimuksia, kuten GDPR-asetusta, sillä se varmistaa, etteivät arkaluonteiset dokumentit tai organisaation sisäiset analyysiprosessit poistu haltijan teknisestä kontrollista. Järjestelmä pohjautuu RAG-ajatteluun, sillä ohjelmistolla analysoitavat dokumentit voivat olla rakenteeltaan hyvinkin erilaisia, eli mahdollinen skaalaus ja säännöstenmukaiset viitteet on otettu alusta asti huomioon.

3.1.1 Kolmikerrosarkkitehtuuri ja asynkronisuus

Järjestelmä noudattaa modulaarista kolmikerrosarkkitehtuuria (Kuva 4), joka on suunniteltu varmistamaan skaalautuvuus ja käytettävyys myös raskaiden laskentaoperaatioiden aikana. Kaikki koneiston osat pyörivät erillään Docker-konteissa.

1. Käyttöliittymäkerros: Toteutettu Next.js App Router -kehyksellä, mikä mahdollistaa reaktiivisen käyttökokemuksen ja prosessien edistymisen reaaliaikaisen seurannan Server-Sent Events (SSE) -teknologialla.
2. Rajapintakerros (Backend API): Perustuu Python-pohjaiseen FastAPI-kehykseen, joka hallinnoi REST-rajapintoja, tiedostojen hallintaa ja työnkulun orkestrointia.
3. Laskentakerros (Workers): Koska RAG-analyysiputki sisältää viiveeltään merkittäviä operaatioita, kuten tekstin vektorointia ja klausuulien semanttista kohdistamista, varsinainen laskenta on eriytetty Celery-työläisille (asynkronisille taustaprosesseille). Viestinvälittäjänä toimiva Redis mahdollistaa tehtävien jonottamisen ja rinnakkaisen suorituksen, mikä varmistaa, etteivät raskaat NLP-operaatiot vaikuta käyttöliittymän vasteaikoihin.



Kuva 4:Järjestelmän kolmikerrosarkkitehtuuri, joka erottaa käyttöliittymän, rajapinnan ja asynkronisen kognitiivisen prosessointikerroksen toisistaan suorituskyvyn varmistamiseksi.

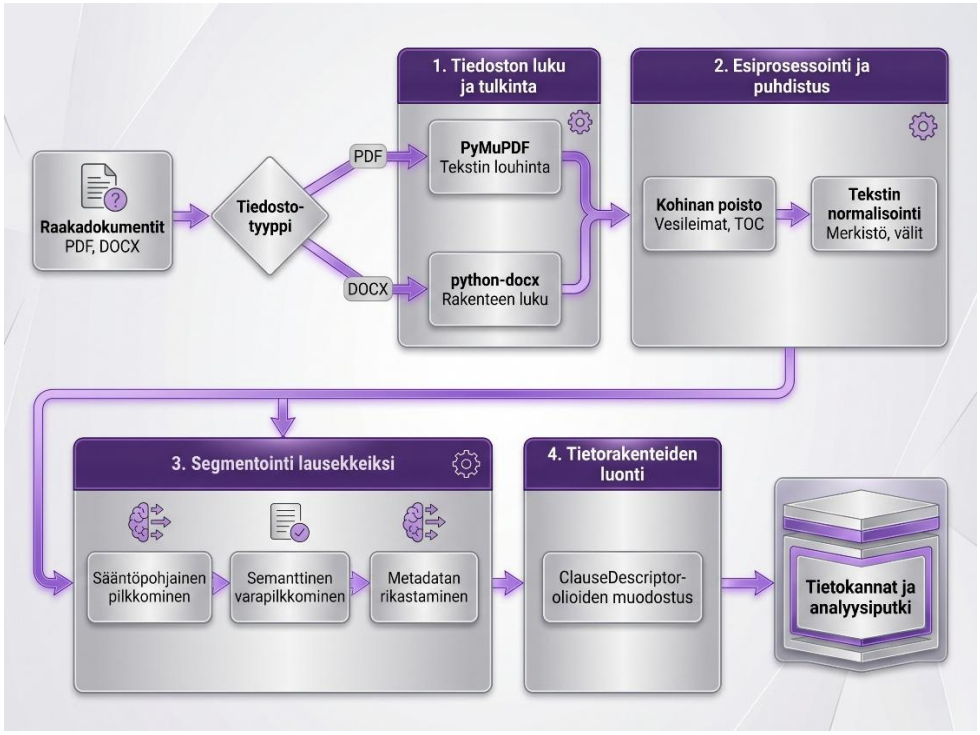
3.1.2 Tiedonhallinta ja vaatimustenmukaisuus

Tietojen tallennus ja haku on toteutettu ratkaisulla, jossa jokainen ajo ja sen parametrit tallennetaan ihmisen tarkastusta varten. Lisäksi järjestelmä tulostaa ajosta PDF-yhteenvedon vaatimusten täyttämiseksi. Järjestelmän tiedonhallinta on suunniteltu siten vastaamaan terveydenhuollon ja sääntelyyn liittyvien tekstien käsittelyssä vaadittavaa korkeaa tarkkuutta ja tietoturvaa. Toteutuksen tekniset valinnat pohjautuvat kahteen keskeiseen periaatteeseen:

- Paikallinen tietosuoja (*Privacy-by-Design*): Järjestelmä käyttää paikallista, tiedostopohjaista tiedonhallintaa (SQLite), mikä mahdollistaa analyysiympäristön eristämisen julkisesta verkosta. Tämä on kriittinen vaatimus käsiteltäessä arkaluonteisia terveydenhuollon säädöksiä tai organisaatiokohtaista sopimusdataa, joissa datan pysyminen paikallisessa levyjärjestelmässä on tietoturvan edellytys. SQLite on myös kevyt valinta, mikä lisää ohjelman lokaalin suorituskyvyn painoarvoa.
- Jäljitettävyys ja auditoitavuus: Kaikki analyysivaiheet, kuten klausuulien tunnisteet ja algoritmikohtaiset konfiguraatiot, tallennetaan strukturoidusti metadatana. Tämä mahdollistaa analyysiprosessin toistettavuuden ja tulosten auditoitavuuden, mikä on sääntely-ympäristöissä välttämätöntä (esim. AI Act -vaatimukset mallien läpinäkyvyydestä). Kaikki ajossa käytetyt säädöt (vaikka automaatti olisikin päällä) otetaan mukaan *audit trail* -tyyliin.

3.2 Analyysiputki esikäsittelystä datan järjestelyyn

Järjestelmän tekninen ydin on modulaarinen RAG-analyysiputki, joka vastaa dokumenttien lukemisesta, indeksoinnista ja semanttisesta hausta. Prosessi jakautuu neljään päävaiheeseen: aineiston sisään luku (Kuva 5), hybridihakuun ja uudelleenjärjestämiseen ja narratiiviin.



Kuva 5: Dokumenttien analysointiprosessin eli käsittelyputken vaiheet: aineiston sisäänluku ja esikäsittely.

Koko putki on suunniteltu alun perin *alignment*-periaatteella, jossa painotetaan tarkkaa klausuulitason (looginen kokonaisuus) kohdistamista pelkän generatiivisen vastauksen sijaan. Kyseessä ei ole siis perus ”tekoäly-yhteenveto” mihin tiputetaan dokumentteja.

1. Aineiston sisäänluku ja esikäsittely

Dokumenttien käsittely alkaa jäsennysvaiheella (*ingestion*, Kuva 5), jossa PDF- ja DOCX-muotoiset tiedostot muunnetaan rakenteiseksi dataksi. Jäsentimenä käytetään PyMuPDF-kirjastoa, joka mahdollistaa tekstin sijaintitiedon ja asettelun säilyttämisen. Ennen varsinaista tekstin louhintaa (sisällön erottelua) syöte käy läpi kaksivaiheisen suodatusprosessin kohinan vähentämiseksi. Ensimmäisessä valinnaisessa vaiheessa tunnistetaan ja poistetaan sisällysluettelosivut (TOC) analysoimalla sivujen pistetiheyttä ja numero-otsikko-rakenteita, mikä estää klausuulien virheellisen *duplikoitumisen*. Toisessa vaiheessa tekstistä suodatetaan valinnaisesti pois toistuvat ylä- ja alatunnisteet sekä vesileimat sääntöpohjaisilla estolistoilla. Jäsennys ja suodatus toteutetaan kohinan vähentämiseksi.

Puhdistettu teksti segmentoidaan loogisiksi kokonaisuuksiksi eli klausuuleiksi. Klausuuli on tässä järjestelmässä segmentoinnin perusyksikkö. Segmentointialgoritmi hyödyntää säännöllisiä lausekkeita (Regex) tunnistaakseen dokumentin hierarkkiset numerointirakenteet (esim. "4.1.2"). Samassa yhteydessä jokaiselle klausuulille määritetään sen velvoittavuus (*normativity*) analysoimalla modaaliverbejä, kuten "*shall*", "*should*" tai "*may*".

2. Hybridihaku (Hybrid Retrieval)

Tiedonhaku toteutetaan hybridimallilla, joka yhdistää tiheän (*dense*) ja harvan (*sparse*) haun parhaat puolet hakutarkkuuden maksimoimiseksi käyttäen moderneja *state-of-art* koneoppimismalleja. Tiheässä haussa klausuulit muunnetaan 768-ulotteisiksi vektoreiksi käyttäen Sentence-Transformers-malleja, ja ne tallennetaan paikalliseen HNSW-indeksiin (Hierarchical Navigable Small World) likimääräistä lähimmän naapurin hakua varten. Rinnakkain tämän kanssa ylläpidetään harvaa BM25-indeksiä, joka mahdollistaa tarkan avainsanapohjaisen haun.

Hakuvaiheessa järjestelmä suorittaa kyselyn molempiin indekseihin ja muodostaa tuloksista unionijoukon. Tämä lähestymistapa varmistaa, että haku löytää sekä semanttisesti vastaavat käsitteet (vektorihaku) että tarkat termiosumat (avainsanahaku), jotka saattaisivat jäädä pelkältä vektorihaulta huomaamatta.

3. Uudelleenjärjestäminen (*Reranking*)

Järjestelmän hakutarkkuutta optimoidaan erillisellä uudelleenjärjestämisvaiheella, joka kohdistuu alkuperäisen hybridihaun tuottamaan ehdokasjoukkoon. Tässä vaiheessa

hyödynnetään BGE-arkkitehtuuriin perustuvaa ristiinkoodaajaa (*cross-encoder*), joka kykenee suorittamaan kyselysegmentin ja dokumenttiklausuulin välisen interaktiivisen relevanssianalyysin tarkasti. Toisin kuin pelkkään vektorietäisyyteen perustuva haku, ristiinkoodain arvioi tekstien välisiä semanttisia suhteita huomattavasti hienojakoisemmin.

Ristiinkoodauksen laskennallista vaativuutta hallitaan _PairwiseBatchReranker-eräajoprosessilla. Tämä optimointi tehostaa tokenisointia ja nopeuttaa järjestämisvaihetta arviolta 5–10-kertaiseksi verrattuna perinteiseen parikohtaiseen pisteytykseen. Prosessin päätteeksi tulosjoukko suodatetaan dynaamisella, Z-pistemäärään perustuvalla menetelmällä (Z-score filter), joka mukautuu automaattisesti kunkin kyselyn tulosjakaumaan. Dynaaminen kynnysarvo varmistaa, että jatkokäsittelyyn ja kielimallille syötettävään kontekstiin valitaan ainoastaan tilastollisesti merkitseviä osumia. Tämä vähentää merkittävästi epärelevantin tiedon päätymistä mallille ja minimoi siten hallusinaatioiden riskiä vastaustuotannossa. Lopuksi havainnollistukseksi Z-pistemäärän matemaattinen kaava:

$$z = \frac{x - \mu}{\sigma}$$

missä x on klausuulin similaarisuuspiste, μ on keskiarvo ja σ keskihajonta.

3.3 Deterministiset sovitusalgoritmit

Järjestelmän laskennallinen prosessin jatko perustuu kahteen erikoistuneeseen suoritusmoodiin, jotka ratkaisevat erityyppisiä tekstianalyysin ongelmia. Vaikka kaikki moodit hyödyntävät samaa vektori-indeksiä, niiden päätöksentekologiikka poikkeaa toisistaan merkittävästi.

3.3.1 Vastaavuusanalyysi (*Alignment mode*)

Kohdistusmoodin tavoitteena on löytää vastaavuudet kahden eri dokumentin, esimerkiksi kahden eri standardin, välillä. Ongelmana on, että pelkkä samankaltaisuushaku tuottaisi sekavan "kaikki kaikille" -tuloksen. Tämän ratkaisemiseksi järjestelmä käyttää kaksijakoista sovitusalgoritmia (*Bipartite Matching*). Algoritmi tarkastelee kaikkia mahdollisia klausuulien välisiä pareja ja niiden samankaltaisuuspisteitä. Tämän jälkeen se valitsee "ahneella" (*greedy*) strategialla parhaan mahdollisen kokonaisratkaisun siten, että jokainen klausuuli yhdistetään vain todennäköisimpään vastineeseensa, estäen duplikaatit ja ristiin menevät heikot osumat.

Järjestelmä tuottaa kaksi matemaattisesti erilaista metriikkaa, joita ei voi sekoittaa keskenään, koska nämä vastaavat eri kysymyksiin:

1. *Alignment*-pisteytys: Yksittäisen klausuuliparin 1:1 ristiinkoodattu vahvuus. Tämä on tuloksissa validoitava varsinainen tulos tämän tutkielman kannalta.
2. *Table*-pisteytys (Canonical score): Klusterin sisäinen vertaus, joka lasketaan vertaamalla klusterin kanonista tekstiä kaikkiin sen jäseniin ja laskemalla näiden keskiarvo.

Pelkkä samankaltaisuus ei kuitenkaan kerro loogista suhdetta. Siksi järjestelmä ajaa lopullisille pareille suunnatun päättelyanalyysin (*Directional* NLI). Tämä malli ei mittaa vain tekstien samankaltaisuutta, vaan kysyy: "Jos väite A on totta, onko myös väite B totta?" Näin järjestelmä kykenee erottamaan (Taulukko 2), onko kyseessä molemminpuolinen vastaavuus (Mutual) vai kattaako toinen standardi toisen vain osittain (A implies B).

Vastaavuusanalyysin viimeisessä vaiheessa järjestelmä ajaa suunnatun päättelyanalyysin, joka hyödyntää nli-deberta-v3-base -tekoälymallia. Tämä NLI-kerros arvioi tekstien välisiä loogisia implikaatiosuhteita neljän kategorian avulla (Taulukko 2).

Taulukko 2: Kohdistusmoodin NLI:n loogiset kategoriat

Suhde	Tekninen määritelmä	Normatiivinen tulkinta
mutual	Molemminpuolinen implikaatio (A⇔B).	Tekstit sisältävät olennaisesti saman velvoitteen; suhde on loogisesti symmetrinen.
a_implies_b	Vasen teksti kattaa oikean (A⟹B), muttei päinvastoin.	Uusi tai muuttunut klausuuli on suppeampi versio alkuperäisestä.
b_implies_a	Oikea teksti kattaa vasemman (B⟹A), muttei päinvastoin.	Muuttunut klausuuli on laajempi versio alkuperäisestä.
none	Match on löytynyt, mutta loogista suuntaa ei voida vahvistaa.	Aihepiiri on sama, mutta sisältösuhde on epäselvä tai ristiriitainen.

Vielä syvällisemmässä luotauksessa katsotaan, miten yllä olevat syntyvät: jotta mainitut neljä suuntautunutta luokkaa (Directional NLI -kategoriat) voidaan saavuttaa, RAG-järjestelmän arkkitehtuurin on todellisuudessa suoritettava monivaiheinen prosessi:

1. Ensimmäinen testi: Ajetaan nli-deberta-v3-base syötteellä (Klausuuli A ⟹ Klausuuli B). Tallennetaan tulos (esim. entailment).
2. Toinen testi: Ajetaan sama malli käänteisellä syötteellä (Klausuuli B ⟹ Klausuuli A). Tallennetaan tulos (esim. neutral).
3. Heuristinen sääntötesti: Ohjelmakoodi, tässä python, arvioi nämä kaksi erillistä tulosta. Jos A ⟹ B on entailment ja B ⟹ A on neutral, järjestelmä luokittelee kokonaisvaltaisen suhteen kategoriaan "a_implies_b". Jos molemmat ovat entailment, tulos on "mutual".

Directional NLI -tuloksista johdetaan edelleen klausuulikohtainen kattavuusstatus, joka visualisoidaan heatmap-näkymässä (Kuva 8):

- covered (Vihreä): Klausuuli saa vähintään yhden sisääntulevan kattavuusreunan
- partial (Keltainen): Klausuuli kattaa toisen vaatimuksen (viittaa usein siihen, että alkuperäinen vaatimus oli laajempi)
- conflict (Punainen): Useampi eri lähde näyttää kattavan saman kohdan tavalla, joka vaatii manuaalista tarkistusta
- none (Harmaa): Klausuulille ei löytynyt merkityksellistä kattavuussuhdetta
- mutual (Tumman vihreä): Kattavuus on kaksisuuntainen. Tämä tarkoittaa, että molemmat suunnat implikoivat toisensa riittävän vahvasti, ja järjestelmän mallin mukaan tekstit sisältävät olennaisesti saman normatiivisen velvoitteen. Suhde on loogisesti symmetrinen

Yksittäisten klausuuliparien (*pairs*) lisäksi vastaavuusanalyysi tuottaa klusteritason aggregaation (*clusters*) jos esimerkiksi on monia klausuuleja jotka ovat toistensa kaltaisia. Tämä esitetään käyttöliittymän ”*Table*”-näkymässä, jossa aineisto ryhmitellään semanttisten teemojen mukaan, mahdollistaen laajemman yleiskuvan muodostamisen dokumenttimassasta. Näistä luodaan edustavin mahdollinen kuvaus generatiivisesti, joka on ryhmänsä edustavin teksti. *Table* -näkymä on tarkoitettu monidokumentti-sääntelyanalyysiin: pelkästään jatkokehitykseen, mutta se käsitellään tässäkin työssä design science tutkimuksen takia suppeasti.

Viimeiseksi vastaavuusanalyysi tuottaa graafin ja generatiivisen narratiivin seuraavilla tavoilla:

1. Generatiivinen narratiivi

Narratiivivaiheessa kielimalli (LLM) muuntaa analyysin tulokset automaattisesti luonnolliseksi kieleksi autonomisella otteella ilman manuaalisia kehotteita. Laskentaresurssien

ja konteksti-ikkunan optimoimiseksi järjestelmä hyödyntää hyötykuorman optimointia (*payload optimization*), jossa se valitsee matemaattisesti vain merkityksellisimmät (top-K) tekstiosat käsiteltäväksi.

Toisin kuin perinteinen RAG, narratiivi rakentuu vasta usean analyysikerroksen jälkeen. Järjestelmä koostaa deterministisestä *alignment*-putkesta tiiviin paketin, joka sisältää yleiskuvan, vahvimmat vastaavuudet, suunnatut erot ja manuaalista tarkistusta vaativat kohdat. Tavoitteena on korkeatasoinen delta-analyysi, joka painottaa sääntelyllisiä muutoksia, kattavuuden asymmetrioita ja normatiivisia siirtymiä.

- Laadunvarmistuksen kolme teknistä strategiaa:
- Evidenssipohjainen kondensaatio: Mallille syötetään vain tulkinnan kannalta kriittinen tiivistelmä (esim. enintään 5 vahvinta paria ja 4 suunnattua eroa) koko raportin toistamisen sijaan.
- Rakenteellinen viisiosainen synteesi: Generointia ohjaa tiukka skeema (yleiskuva, vastaavuudet, kattavuuserot, normatiiviset muutokset ja huomiot), mikä takaa teknisen koherenssin.
- Diversiteettiotanta: Algoritmi poimii näytteitä tasaisesti eri dokumentin osioista välttääkseen narratiivin kapeutumisen vain yhteen teemaan.

Järjestelmä sisältää myös heuristisen varareitin (*fallback*), joka tuottaa rakenteellisen raportin, vaikka LLM-kutsu epäonnistuisi. Koska generatiivinen vaihe on vain lisäkerros, sen mahdolliset häiriöt eivät vaaranna deterministisen ydinanalyysin tuloksia.

2. Makrotason visuaalinen 3D-klusterigraafi

Klausuulitason 1:1-vastaavuuksien lisäksi järjestelmä tuottaa koko dokumenttimassasta makrotason näkymän, joka visualisoidaan *Table*-välilehden interaktiivisena 3D-klusterigraafina (Kuva 7). Graafi havainnollistaa sääntelydatan N-to-1 -synteesiä, jossa samankaltaiset lauseet on ryhmitelty yhtenäisten klusterikeskusten ympärille satelliiteiksi. Tämä visualisointi rakennetaan suoraan analyysiputken tuottamasta *provisions*-tietorakenteesta heijastaen dokumenttien todellista teemarakennetta.

Käyttäjä voi interaktiivisesti tarkastella yksittäisiä tihentymiä, kuten kuvassa 7 korostettua klusteria 22 (Klausuuli 7.4). Solmua tarkastelemalla asiantuntija näkee välittömästi klusterin koon, sisäisen ”aggregaattiarvon” sekä klusteria edustavan kanonisen tekstin. Graafin avulla on mahdollista hahmottaa yhdellä silmäyksellä aineiston vahvimmat vastaavuustihentymät sekä mahdolliset yksittäisiksi jäävät vaatimukset.

3.3.2 *Bipartite matching* -arviointi

Jotta järjestelmän suorittamaa vastaavuusanalyysia ja siinä hyödynnettävää kaksijakoista sovitusalgoritmia (*bipartite matching*) voidaan arvioida tieteellisesti, tutkimuksessa määritellään arviointimatriisi, joka perustuu asiantuntijan tekemään vertailuun suhteessa algoritmin tuottamiin ennusteisiin:

True Positive (TP) eli Tosi positiivinen: Järjestelmä tunnistaa klausuulien välisen vastaavuuden, ja asiantuntija vahvistaa niiden olevan asiasisällöllisesti pari.

False Positive (FP) eli Epätosi positiivinen: Järjestelmä ehdottaa vastaavuutta (esim. korkean vektorisimilaarisuuden vuoksi), mutta todellisuudessa klausuulit eivät vastaa toisiaan.

False Negative (FN) eli Epätosi negatiivinen: Järjestelmä ei löydä vastaavuutta pariinsa, vaikka klausuulit todellisuudessa muodostavat parin. Kyseessä on järjestelmän tekemä missaus.

True Negative (TN) eli Tosi negatiivinen: Järjestelmä jättää oikeaoppisesti yhdistämättä klausuulit, joilla ei ole asiasisällöllistä yhteyttä.

Nämä kategoriat mahdollistavat järjestelmän kohdistustuloksen laskemisen objektiivisesti.

3.3.3 Muutosanalyysi (*Diff mode*)

Muutosanalyysissä analysoidaan saman dokumentin (esim. sopimusehdot tai standardit) muutoksia ajan yli. Algoritmi yhdistelee useampaa menetelmää muutosten havaitsemiseen:

Täsmäytys (*Matching*): Ensisijaisesti pyritään ID-pohjaiseen täsmäytykseen: jos klausuulin tunniste (esim. "4.1") on pysynyt samana, järjestelmä vertaa suoraan tekstisisältöä. Jos tunnistetta ei löydy, esimerkiksi jos lukuja on numeroitu uudelleen: algoritmi siirtyy semanttiseen täsmäytykseen. Tällöin se etsii vektorimallien avulla sisällöllisesti lähimmän vastineen uuden version puolelta. Ajo tarkistaa myös tekstin samankaltaisuuden estääkseen vääriä osumia.

Luokittelu: löydetyt parit analysoidaan automaattisesti neljään kategoriaan muutoksen vakavuuden mukaan: Muuttumaton (*Unchanged*): Teksti on pysynyt täysin samana. Tekstuaalinen (*Textual*): Pieniä sanamuotojen korjauksia (esim. kirjoitusvirheet tai taivutukset), joissa alkuperäinen merkitys säilyy. Ennustettu semanttinen samankaltaisuus on yhä hyvin korkea. Parametrinen (*Parametric*): Tekstin sisältämät numeeriset arvot tai määreet (esim. raja-arvot tai yksiköt) ovat muuttuneet lauserakenteen pysyessä lähinnä

samana. Nämä parametrimuutokset (vanha arvo → uusi arvo) erotellaan automaattisesti omaan listaansa. Merkityksellinen (*Semantic*): Kappaleen asiasisältö tai merkitys on muuttunut merkittävästi. Parametrisiä muutoksia ei ollut lainkaan tuloksissa, koska tarkasteltavassa aineistossa ei ollut lainkaan parametrisiä arvoja. Ne ovat jatkokehityksen osalta kuitenkin ehkä tärkein mittari, miksi ne ovat mukana.

Visuaalinen ”kirurginen” ikkuna on muutosanalyysin varsinaisena ytimenä: Käyttöliittymä näyttää yhteenvedon lisätyistä, poistetuista, muuttumattomista ja muokatuista klausuuleista. Tarkemmassa näkymässä sanaston tason erot (*word-by-word diff*) korostetaan visuaalisesti: poistetut sanat yksinkertaisesti yliviivataan punaisella ja lisätyt merkitään vihreällä (Kuva 11).

3.4 Aineistovalinta

Tutkimuksen aineistovalinnassa on painotettu kehitetyn järjestelmän dokumenttiagnostisuutta, eli kykyä käsitellä erilaisia sääntelymalleja rakenteesta riippumatta. Ohjelmiston kehitysprosessin aikana on hyödynnetty kohdeyritysten, ABB:n ja Taipuva Consulting Oy:n, tarjoamia aineistoja. Kyseisiä yrityskohtaisia materiaaleja ei esitellä tässä työssä julkisesti voimassa olevien salassapitosopimusten (NDA) vuoksi.

Diplomityön kokeellisessa osiossa ja järjestelmän suorituskyvyn analysoinnissa käytetään ensisijaisena aineistona ISO-standardeja, erityisesti ISO/IEC 27001 -standardin eri versioita. Standardien esittämisen rajoitusten vuoksi lähdedokumenttien tekstisisältöjä ei toisteta työssä sellaisenaan, eikä LLM narratiivia voida julkisesti näyttää. Sen sijaan analyysi kohdistuu järjestelmän tuottamiin jäsenneltyihin tuloksiin, kuten klausuulien välisiin similaarisuuspisteisiin, loogisiin suhteisiin ja generatiivisiin synteeseihin, jotka havainnollistavat ohjelman kykyä hallita monipykälistä sääntelydataa.

Kokeellinen osio rajattiin tähän kyseiseen 27001-standardiversiopariin, jotta tutkimuksen painopiste voitiin pitää järjestelmän teknisessä kehityksessä, algoritmien hienosäädössä sekä riittävän syvällisessä klausuulitason validoinnissa annettujen aikatauluresurssien puitteissa. Kuten aiemmin mainittu, valittu standardi edustaa monien alojen velvoitteita, terveydenhuollon kuin myös muiden kriittisten alojen.

4. TULOKSET JA ANALYYSI

Tässä luvussa raportoidaan tutkimuksen kokeellisen osion tulokset ja arvioidaan kehitetyn analyysialustan suoriutumista sääntelyaineiston analyysissa. Luku etenee valmiin järjestelmän käyttöliittymäkuvauksesta tarkempaan suorituskykyanalyysiin, jossa tarkastellaan prosessointiaikoja ja resurssivaatimuksia paikallisessa infrastruktuurissa, päättyen lopulta ohjelman tulostuksen laadulliseen validointiin verrattuna todelliseen aineistoon. Suoritettu validointiprosessi toteuttaa tässä tutkimuksessa *human-in-the-loop*-periaatteen, mikä vastaa suoraan EU:n tekoälyasetuksen (AI Act) 14 artiklan asettamaa velvoitetta inhimillisestä valvonnasta.

Tulosten laadun arvioinnissa keskitytään automaattisen klausuulikohdistuksen tarkkuuteen pareille, muutosvertailun ”kirurgiseen” näkymään, sekä kielimallin tuottaman narratiivisen tiiviin yhteenvedon informatiivisuuteen. Järjestelmän luotettavuus ja käytännön arvo osoitetaan aineistoon perustuvalla vertailulla.

4.1 Toteutettu ohjelmistoratkaisu

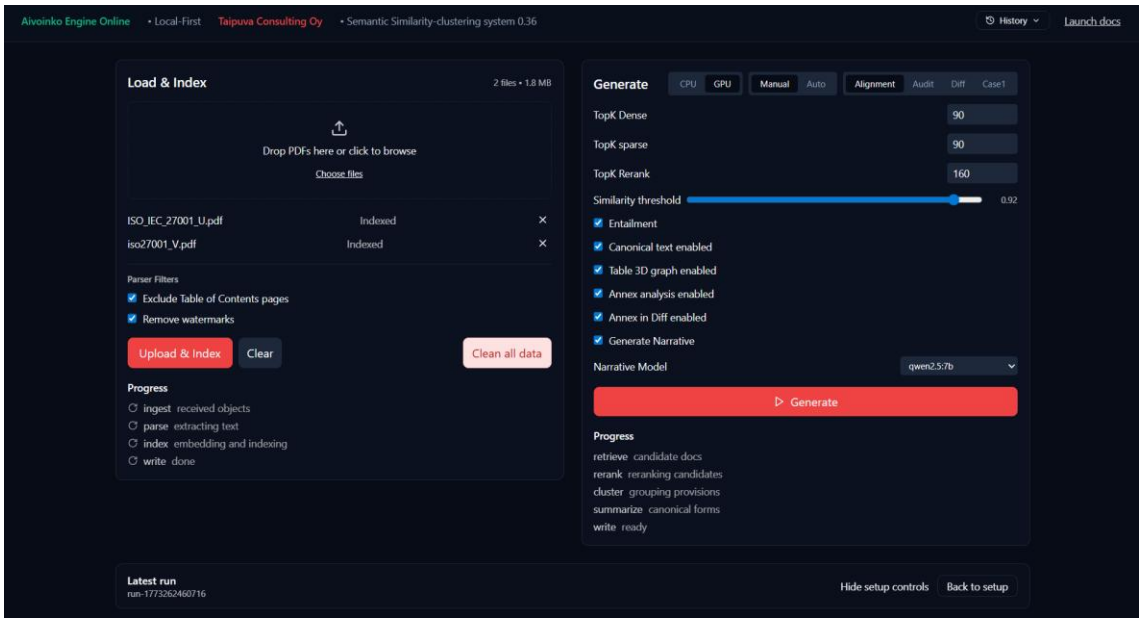
Toteutus pohjautuu luvussa 3 esiteltyihin menetelmiin, ja se on optimoitu vastaamaan luvussa 1 asetettuihin tutkimuskysymyksiin sekä teorialuvussa 2 esitettyihin ongelmiin. Ohjelmisto toimii autonomisena luokittelijana, joka muuntaa staattisen sääntelyaineiston visuaaliseksi, jäljitettäväksi ja jäsennellyksi tiedoksi. Seuraavaksi tarkastellaan ohjelmiston toiminnallista kokonaisuutta ja käyttöliittymän tarjoamia työkaluja, joiden avulla tutkimuksen tulokset on laskettu.

4.1.1 Järjestelmän parametrivalinnat ja käyttöliittymä

Järjestelmän käyttöliittymä (Kuva 6) on suunniteltu asiantuntijavetoiseen prosessiin, jossa käyttäjä voi hallita koko analyysiputkea aineiston lataamisesta raportin generointiin. Käyttöliittymän konfigurointinäkymä on jaettu kahteen yksinkertaiseen pääosioon: aineiston hallintaan (*Load & Index*) ja analyysiparametrien säätöön (*Generate*).

Aineiston hallintaosiossa käyttäjä lataa esimerkiksi PDF-muotoiset dokumentit ja valitsee esikäsittelysuodattimet, kuten sisällysluetteloiden ja ylä- sekä alatunnisteiden automaattisen poiston. Analyysiosiossa käyttäjä voi hienosäätää RAG-putken parametreja, mikä on kriittistä analyysin tarkkuuden ja toistettavuuden kannalta. Tämän tutkimuksen pääasiallisessa testiajossa käytettiin seuraavia, kuvassa 6 näkyviä säädettäviä parametreja.

- TopK Dense (90): Määrittää, kuinka monta semanttisesti lähintä kandidaattia haetaan vektori-indeksistä.
- TopK Sparse (BM25) (90): Määrittää avainsanahakuun perustuvien kandidaattien määrän.
- TopK Rerank (160): Määrittää niiden klausuulien määrän, jotka syötetään laskennallisesti raskaammalle ristiinkoodaajalle (*Cross-encoder*) tarkempaa pisteytystä varten.
- Similarity Threshold (0.92): Samankaltaisuuden kynnysarvon (*similarity threshold*) valinnalla on kriittinen vaikutus klusteroinnin tuloksiin.



Kuva 6: Tekoälyjärjestelmän käyttöliittymä

Käyttöliittymä tarjoaa asetuksia manuaalisesti, ja vaikka ”adaptiivinen” asetus on mahdollinen, testiajoissa parametrit hienosäädettiin manuaalisesti parhaan mahdollisen kontrollin ja tarkkuuden varmistamiseksi työssä. Samalla kuvasta 6 näkyy järjestelmän modulaarisuus, valita voi esimerkiksi graafin tai ei tarpeen mukaan, tai olla sisällyttämättä klusterointia eli kanonisen tekstin muodostusta lainkaan prosessointiajan säästämiseksi.

4.1.2 Vastaavuusanalyysin toiminnallinen toteutus ja tulosmetriikat

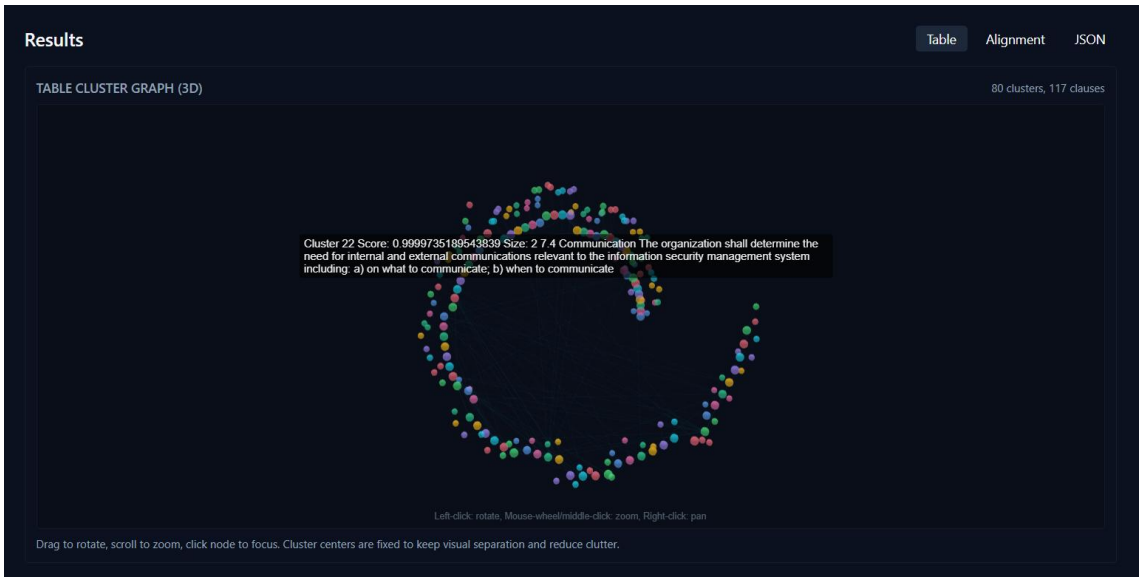
Järjestelmän tekninen ydin oli modulaarinen RAG-analyysiputki, joka painottaa tarkkaa pykälätason kohdistamista kuten luvussa 3 esitettiin. Vastaavuusanalyysi on determinis-

tistä ajoista fundamentaalein. Vaaditusta näkökulmasta riippuen, käyttäjä voi jättää samankaltaisimmat käsittelemättä myöhemmin muutosanalyysin kautta, koska silloin vanha ja uusi tiedosto ovat samanlaisia - eli mikään ei ole muuttunut edellisestä versiosta. Toisaalta, jos käyttäjä haluaa dokumenttien väliset absoluuttiset samankaltaisuudet eri sääntelyiden välillä, korkeisiin samankaltaisuuksiin tulee keskittää huomiota. Vastaavuusanalyysin käyttöliittymä jaetaan kahteen välilehteen, jotka näyttävät eri tasoja:

1. Klusterien välinen aggregaattipiste (*Canonical score*, Kuvat 6 ja 7): *Table*-näkymässä esitettävä arvo kuvaa klusterin sisäistä yhtenäisyyttä. Se lasketaan kaikkien samaan klusteriin kuuluvien segmenttien keskiarvona. Vaikka tämä arvo tukee klusteroinnin makrotason tarkastelua, siihen ei syvennytä tässä tulososiossa tarkemmin.
2. Klausuuliparien välinen samankaltaisuuspiste (*Pair-score*, Kuva 9): Alignment-näkymässä esitettävä arvo mittaa kahden yksittäisen klausuulin välistä semanttista samankaltaisuutta eri dokumenttien välillä. Nämä ovat työn varsinaisia tuloksia.

Vastaavuusanalyysin *Table*-näkymän, voisi myös kutsua koontinäkymäksi; keskeinen elementti on klausuuliklustereille muodostettava kanoninen teksti (*canonical text*), joka toimii koko klusteriryhmän edustustekstinä. Teksti ei ole pelkkä staattinen viittaus aineistoon, vaan se muodostetaan kognitiivisen putken loppuvaiheessa dynaamisesti. Järjestelmä hyödyntää tässä ensisijaisesti paikallista kielimallia (kuten Qwen2.5:7B tai Mistral Small 3:24B:Q4_K_M), joka tiivistää klusterin kaikkien jäsenten perusteella synteettisen, normatiivisen ydinsisällön yksi klusteri kerrallaan edeten koko joukon läpi. Tämä osoittaa, että järjestelmän toiminta on generoivaa jo klusteritasolla, mikä vahvistaa työn teoriassa korostettua yhdistelmätekoälyjärjestelmä -arkkitehtuuria: tekoäly ei ainoastaan raportoi löydöksiä, vaan osallistuu aktiivisesti tiedon syntetisoimiseen analyysiprosessin eri vaiheissa. LLM -mallien erot olivat tässä kontekstissa pieniä.

Todellisuudessa, tämä kanoninen teksti on käytännöllinen, jos dokumentteja olisi kahta suurempi massa, joissa olisi samantyyppisiä (mutta ei samanlaisia) vaatimuksia, sillä se generoisi edustavimman siitä klusterista. Tämä analyysi on siis toissijainen työn tutkimuskohteeseen nähden, koska tarkoitus on keskittyä kahden eri dokumentin vertailuun. Käyttöliittymän ja sen toiminnallisuuksien esittely on kuitenkin perusteltua työn suunnittelutieteellisen (design science) tutkimusotteen vuoksi, sillä numeeristen analyysitulosten ohella itse kehitetty ohjelmisto muodostaa keskeisen osan tutkimuksen tavoitteita.

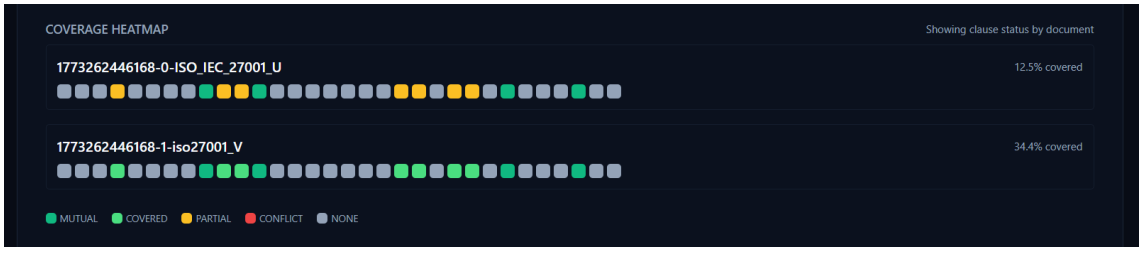


Kuva 7: Alignment-ajon Table-näkymän interaktiivinen 3D-klusterigraafi

Tutkimuksen tavoitteen kannalta kiinnostavaa oli 1:1 vertailu, ei niinkään klusteritasolla vaan siis pareittain. Tämä ei tapahdu ”*Table*” -välilehdellä missä graafi sekä kanoniset tekstipuristeet ovat, vaan varsinaisella vastaavuusanalyysin *alignment pairs* -välilehdellä (Kuva 9).

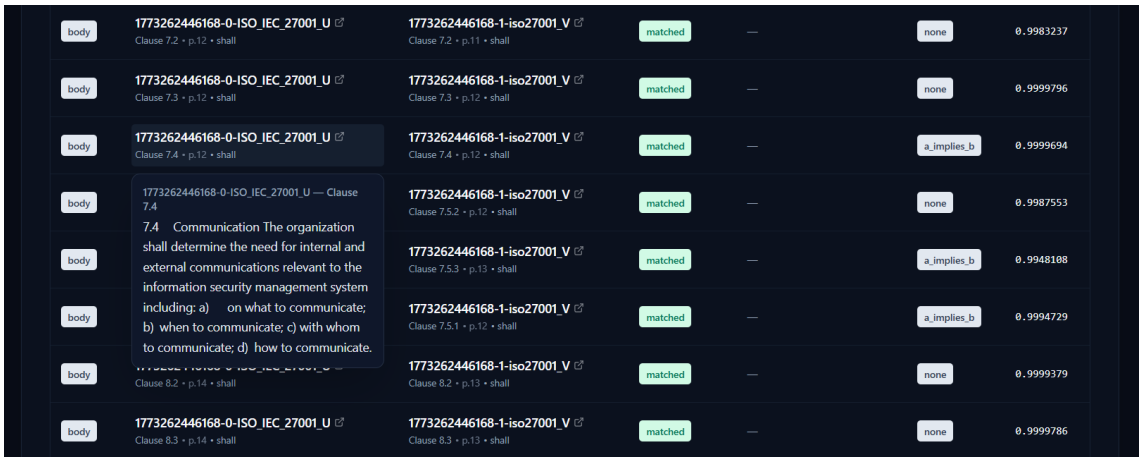
Alignment pairs -välilehti kokoaa similariteettianalyysin keskeisimmät tulokset. Näkymä erottelee normatiivisesti sitovat vaatimukset ("Shall"-tunniste) ei-sitovista, kuten sovelta-misalaa kuvaavista klausuuleista ("Other"-tunniste). Tämä luokittelu tehostaa asiantun-tijatyötä merkittävästi, sillä huomio voidaan kohdistaa puhtaasti varsinaisiin velvoitteisiin.

Lämpökartta näyttää asian visuaalisesti ja tarkemmin (Kuva 8).



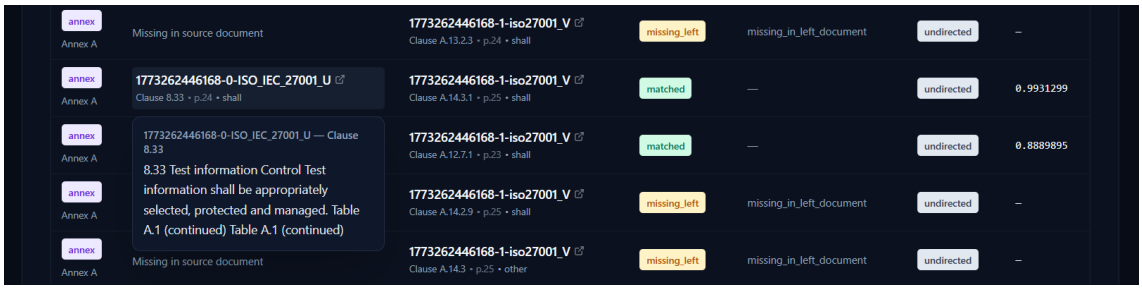
Kuva 8: Alignment ajon heatmap tuloste leipätekstin klausuuleille. Varsinaisessa käyttöliittymässä kursorin vieminen kohdan päälle avaa tarkempia yksityiskohtia klausuulista.

Kattavuusnäkymän (*heatmap*) tulokset noudattavat luvussa 3 määriteltyä NLI-logiikkaa: keltaisella (*partial*) ja kirkkaanvihreällä (*covered*) merkityt parit vastaavat koneellisen analyysin löytämiä *a_implies_b* -relaatioita. Analyysissa havaittiin lisäksi, että malli antoi useille erittäin korkean similaarisuuspisteen saaneille klausuuleille loogiseksi tunnis-teeksi "*None*". Tulosten perusteella "*None*"-tunniste ei siis merkitse vaatimusten asiasi-sällöllistä erilaisuutta, vaan ainoastaan sitä, ettei malli kyennyt tunnistamaan niiden vä-lillä yksiselitteistä loogista implikaatiosuuntaa.



Kuva 9: Vastaavuusanalyysin (Alignment mode) tuottamat klausuulikohtaiset similariteettipisteet ja loogiset NLI-relaatiot. Pisteet on normalisoitu välille 0–1 logistisella sigmoid-funktiolla tulosten tulkittavuuden parantamiseksi.

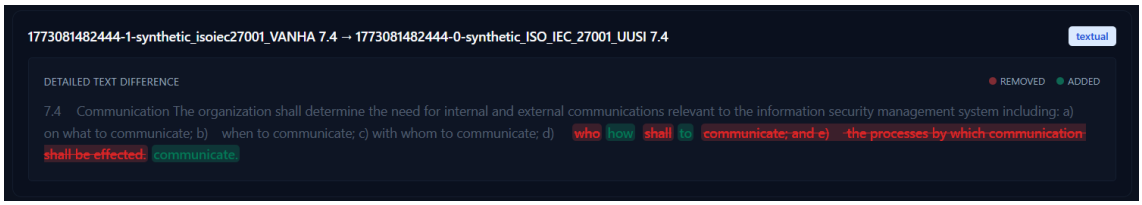
Parien vertailuun keskitytään validoinnissa 4.3 ja 5 pohdinnassa tarkemmin. Järjestelmän arkkitehtuurissa on kiinnitetty erityistä huomiota siihen, että sääntelytekstit eivät mahdollisesti ole numeroinniltaan yhtenäisiä. Dokumentit koostuvat usein varsinaisesta leipätekstistä (*body*) sekä teknisistä liitteistä (*annex*), jotka saattavat noudattaa täysin erilaista numerointi- ja esitystapaa. Kehitetty algoritmi on suunniteltu agnostiseksi näille rakenteellisille eroille (Kuva 10). *Annex* osan logiikassa ei ollut mukana klusterointia, joten se merkkaa *missing* -tunnisteella jos jokin klausuuli puuttuu toisesta dokumentista.



Kuva 10: Vektoripohjainen haku kykenee yhdistämään sisällöllisesti vastaavat vaatimukset (esim. 8.33 ja A.14.3.1) huolimatta merkittävistä eroista klausuulien numeroinnissa tai hierarkkisessa sijoittelussa, kuvassa Annex A löydökset.

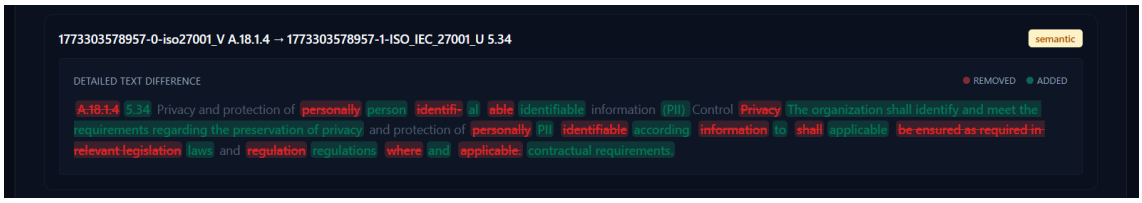
4.1.3 Muutosanalyysin näkymän tuloksia

Muutosanalyysissä tutkitaan saman dokumentin muutoksia ajan yli ensisijaisesti tekstin muutosten näkökulmasta dokumenttien välillä kuten kuvassa 11 ja 12. Analyysissä hyödynnetään luvussa 3.3.2 määriteltyä neliportaista luokittelua, jossa muutokset jaotellaan niiden asiasisällöllisen merkityksen mukaan. Esimerkkitapauksessa järjestelmä on tunnistanut klausuulin muutoksen ja luokitellut sen tyypiltään tekstuaaliseksi (*textual*).



Kuva 11: Diff näkymästä yksittäinen klausuuli, jossa muutokset näkyvät selkeästi käyttäjälle, klausuulista tulee ”textual”.

Kuvassa 12 nähdään *semantic*-tunniste muutosanalyysissä. Siinä on muuttunut sisältö selkeästi klausuulien välillä, mutta myös niiden numerointi on eri A.18.1.4 ja 5.34. Ne löytävät silti toisensa, koska puhuvat samasta asiasta eli henkilödatan suojelemisesta.



Kuva 12: Annexissa diff moodi löytää myös eri numeroinneilla ja kirjaimilla olevat klausuulit, sekä tekee niistä onnistuneen muutosanalyysin. Kuvassa esimerkkinä A.18.1.4 ja 5.34 toisesta dokumentista joiden idea on sama, mutta merkitys muuttunut.

Diff-näkymän vertailussa ohjelma pilkkoo tekstin sana- tai lausetasolla palauttaen diff_tokens-listan, joka erottelee muuttumattomat (*equal*), lisätyt (*insert*) ja poistetut (*delete*) osat kuten kuvissa 11 ja 12 näkyy. Tämä kirurginen tarkkuus säästää asiantuntijaresursseja, kun huomio voidaan keskittää vain olennaisiin muutoksiin pitkien tekstien sisällä. Järjestelmä mahdollistaa *human-in-the-loop*-periaatteen toteutumisen siten, että käyttäjä voi avata alkuperäisen dokumentin tarkasti oikeasta kohdasta vain vertailuparia klikkaamalla. Tämä poistaa sääntelytyölle tyypillisen manuaalisen etsintätyön ja parantaa analyysin luotettavuutta ja auditointivalmiutta.

4.2 Suorituskykyanalyysi

Järjestelmän suorituskyky ja skaalautuvuus on optimoitu asynkronisen työnkäsittelyn ja paikallisen laitteiston tehokkaan hyödyntämisen ympärille. Ohjelma on suunniteltu toimimaan joustavasti eri laitteistoympäristöissä, aina kannettavista tietokoneista tehokkaisiin GPU-palvelimiin, mikä on suora seuraus sen paikallisesta -arkkitehtuurista.

Järjestelmän optimoitu suorituskyky osoittautui riittäväksi laajempienkin dokumenttien analysointiin, mutta nyt keskityttiin ISO/IEC 27001 -standardin analysointiin. Testiajossa GPU:lla NVIDIA GeForce RTX 2060 Super Ventus -näytönohjaimella varustetulla laitteistolla koko standardin läpikäynti ja narratiivisen raportin generointi vei noin 13 minuuttia. Havainto on merkittävä, sillä se osoittaa paikallisen, suhteellisen matalan kynnyksen

laitteiston riittävyyden vaativaan tekoälyavusteiseen sääntelyanalyysiin. CPU-ajo menee selvästi yli tunnin mittaiseksi. Ohjelman putkea voidaan siis ajaa ilman GPU:ta, mutta GPU ajo oli varsinkin optimointivaiheessa erittäin tärkeää sen moninkertaisen rinnakkaislaskentatehokkuuden takia verrattuna suorittimiin.

Kuten aiemmin kerrottu, laskennallinen tehokkuus nojaa Celery-työläisten ja Redis-viestinvälittäjän käyttöön, mikä mahdollistaa raskaiden RAG-putkien ajamisen taustaprosesseina ilman käyttöliittymän lukittumista. Suorituskykyä parannetaan entisestään esikäsittelyvaiheessa suodattamalla pois epärelevantti sisältö, kuten sisällysluettelot ja vesileimat, mikä vähentää turhaa laskentaa ja tokenien kulutusta joka onnistui kaikissa ajoissa. Lisäksi toistuvaa analyysia nopeutetaan SQLite-pohjaisella välimuistilla, johon tallennetaan aiemmat loogisen päättelyn (NLI) vastaukset. Tehokkuutta voidaan myös hallita valinnoilla, että mitä analyysiin halutaan mukaan, esim. graafit ja kanonisen tekstin voi klikata pois käytöstä suoraan käyttöliittymästä (Kuva 6).

Laitteistokohtainen skaalautuvuus toteutettiin dynaamisilla eräkoilla (*batch sizes*), jotka mahdollistavat VRAM-muistin optimaalisen käytön. Keskeinen tekninen rakennelma on _PairwiseBatchReranker-moduuli, joka optimoi *cross-encoder*-mallin toimintaa ryhmittelemällä syötteet rinnakkaisiksi tensoriryhmiksi. Tämä ratkaisu poistaa perinteisen lausekeparikohtaisen tokenisoinnin pullonkaulan ja nopeuttaa uudelleenjärjestämisvaihetta jopa 5–10-kertaiseksi.

Generatiivisen vaiheen suorituskykyä hallitaan *payload*-optimoinnilla. Sen sijaan, että paikalliselle kielimallille kuten Mistral Small 3:24B:Q4_K_M, tai Qwen2.5:7B) syötettäisiin kokonaisia PDF-dokumentteja, järjestelmä lähettää vain täsmäävimmät klausuulit jäsennellyssä muodossa. Tämä "*Attention on need-to-know basis*" -lähestymistapa pienentää muistijälkeä, ehkäisee hallusinaatioita ja varmistaa, että generoitu vastaus syntyy nopeasti. Hybridi-haku, jossa BM25 (CountVectorizer)-esikarsinta vähentää raskaamman semanttisen haun kuormaa, viimeistelee järjestelmän kyvyn suoriutua vaativasta regulatiivisesta analyysista ilman pilvi-infrastruktuurin kustannuksia tai viiveitä.

Taulukko 3: Super Ventus GPU ajon tehokkuus (myös kanonisen tekstin generointi, joka ei ollut varsinainen osa tuloksia).

Ominaisuus	Arvo
Laitteistoympäristö	Paikallinen ajo (Offline, GPU)
Analysoitu aineisto	2 PDF-dokumenttia (20 ja 23 sivua)
Kokonaiskesto (RAG-putki)	769,3 s (~13 min)
Kielimallin koko (Narratiivi)	8B:Q4 parametria

Järjestelmän taustalokeista (*backend*) on havaittavissa, että arkkitehtuuri kykenee käsittelemään suuria määriä rinnakkaisia tilakyselyitä varsinaisen raskaan kognitiivisen prosessoinnin ollessa käynnissä erillisessä työläisprosessissa (*workers*). Tämä todistaa luvussa 3 esitellyn asynkronisen kolmikerrosarkkitehtuurin toimivuuden: käyttöliittymä pysyy responsiivisena, vaikka taustalla ajetaan laskennallisesti raskaita vektorointi- ja uudelleenluokittelualgoritmeja. Taustalokeista ei otettu kuvaa tähän työhön, tilan säästämiseksi.

Lokitiedoista on myös todennettavissa, että lokaalin kielimallin (Ollama) tekemä narratiivin generointi on kiinteä osa tätä kokonaisaikaa. Generointia pyytävä rajapintakutsu (POST /api/generate) valmistui onnistuneesti vain sekunnin murto-osia ennen koko analyysiputken sulkeutumista. Kokonaisaika sisältää siten kaikki järjestelmän vaiheet dokumenttien jäsennyksestä ja puhdistuksesta loogisten vastaavuuksien etsimiseen (NLI) ja lopullisen luonnollisen kielen raportin tuottamiseen.

4.3 Järjestelmän validointi ja keskeiset havainnot

Löydökset osoittavat, että sääntelytyön eri vaiheet vaativat erilaisia tulosnäkymiä. Käydään ne tässä aliluvussa läpi. Validointia varten aineistosta poimittiin 10 klausuulin satunnaisotos. Otanta suoritettiin ohjelmallisesti Pythonin sisäänrakennetun random-kirjaston avulla. Otettakoon huomioon, että kaikki putkessa käytetyt AI ja neuroverkot ovat koulutetttu laajalla materiaalilla, joten biasia suhteessa tähän tutkittuun standardiin, ei pitäisi olla olemassa.

Järjestelmän validoinnissa keskitytään erityisesti standardien leipätekstin (*body text*) klausuuliin 7.4 joka oli satunnaisotannan kiinnostavin löytö. Muita klausuuleita arvioidaan lyhyemmin. Koko aineiston manuaalinen läpikäynti ei ole tulosten validoinnin kannalta tarkoituksenmukaista, vaan valitut esimerkit tarjoavat riittävän edustavan otoksen järjestelmän suorituskyvyn ja analyysin tarkkuuden arvioimiseksi. Tuloksista tuli selväksi tosiasia, että aineisto vastaa erittäin läheisesti toisiaan.

4.3.1 Klausuulien mikrotason validointi

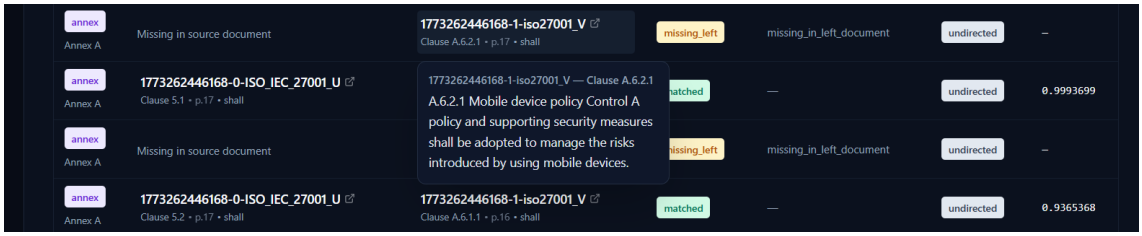
Samat ajot sekä vastaavuus, että muutosanalyysi on siis suoritettu kaikille klausuuleille, mutta nyt keskitytään aluksi 7.4 pykälään erityisesti. Testiaineistossa alkuperäinen ”Vanha” versio sisältää tämän klausuulin kohdalla viisi vaatimusta (a–e), kun taas ”Uusi” versio tiivistää kohdan d ja poistaa kokonaan kohdan e. Järjestelmän kognitiivinen kerros tuotti klausuuliparille seuraavat tulokset:

- Samankaltaisuuspisteet: BGE-ristiinkoodaaja (*cross-encoder*) antoi parille erittäin korkean similaarisuusarvon 0,9999694.
- Looginen päättely (NLI): DeBERTa-malli tunnisti tekstien välisen epäsymmetrian ja asetti parille tunnisteen *a_implies_b*. Tämä osoittaa mallin havainneen, että suppeampi ”Uusi” klausuuli sisältyy loogisesti laajempaan ”Vanha”-versioon. Tämä on keskeinen tulos.
- Lämpökartta (*heatmap*): Ohjelman *heatmap*-visualisointi heijasti NLI-tulosta suoraan: ”Uusi” dokumentti sai klausuulin kohdalla keltaisen PARTIAL-merkinnän, kun taas ”Vanha” dokumentti merkittiin vihreällä COVERED-leimalla.
- Järjestelmä suoritti klausuulille 7.4 sanatasoisen *diff*-analyysin, jossa poistetut osuudet (kuten *"who shall" ja "and e) the processes..."*) yliviivattiin visuaalisesti ja lisätyt sanat korostettiin. Algoritmi luokitteli tämän muutoksen kategoriaan *textual*. Kuvassa 12 näkyy, että klausuulin väliset erot on eroteltu sanatasolla alkuperäisen aineiston mukaisesti. *Diff* muutosanalyysi näkymän onnistuminen oli samanlaista kaikissa tutkituissa klausuuleissa.

Nämä klausuuliin 7.4 liittyvät havainnot osoittavat, että vaikka matemaattinen samankaltaisuus on huomattavan korkea identtisen sanaston vuoksi, järjestelmän looginen kerros ja visuaaliset indikaattorit tunnistavat vaatimusten laajuudessa tapahtuvan muutoksen.

Selkeä erikoisuus otannasta löytyi ”9.3.1” ja ”9.3” välillä. 9.3.1 oli sulauttanut klausuulit 9.3.2 ja 9.3.3 itseensä klusteriksi – koska ne olivat yhdessä sama kuin toisen dokumentin 9.3 klausuuli. Tämä yhteensulautuma oli saanut ”*mutual*” tunnisteen. *Score*: 0.9990512 eli selvästi matalampi, johtuen otsikoista 9.3.2 ja 9.3.3 jotka olivat sulautuneet yhdeksi klausuulin 9.3.1 alle. Tämä kuvastaa klusteroinnin onnistumista *body text* -osassa.

A.6.2.1 -klausuuli osoitti, että ohjelmisto löytää toisesta dokumentista puuttuvat klausuulit. Tässä ohjelmasta kuvankaappaus (Kuva 13) alla, jossa näkyy myös selvästi että ”*missing_left*” on aktiivinen joidenkin parien välillä.



Kuva 13: Toisesta dokumentista puuttuvan klausuulin havaitseminen ohjelmistolla, koska klusterointia ei käytetty annex -osassa.

Klausuuli 5.1: Suurin yksittäinen analysoitu similariteettiero klausuulien välillä olikin artefakti, koska 5.1 klausuulissa *”NOTE Reference to “business” in this document can be interpreted broadly to mean those activities…”* uudessa versiossa. Tämän alignment pari *score* oli 0.9847204. *None*-tunnisteella.

Annex osiosta otetaan toinen klausuuli ”*Protection of information systems during audit testing*” joka onnistui, vaikka numeroinnit olivat täysin erilaiset molemmissa dokumenteissa. Toisessa se on 8.33 ja toisessa A.14.3.1 mutta hybridihaku löysi nekin yhdenmukaisesti (Kuva 10). Numeroinnin ei tarvitse olla yhtenäinen.

A.9.2.4 oli ohjelman parien etsinnässä yhdistänyt uuden dokumentin (A) 5.17 klausuuliin. Tämä on oikein, numerointi on muuttunut uuteen versioon. *Shall* tunniste, ja samankaltaisuus 0.9902975, tekstissäkin siis pieniä muutoksia.

Korkeimman samankaltaisuusarvon saaneet klausuulit ovat:

7.1, *score*: 0.9999795. identtiset klausuulit. *Shall* tunniste. *None*.
5.2, score: 0.9999047. Täysin identtiset klausuulit, välissä sivunumeroita ja leimoja, joten tekstin esikäsittely oli onnistunut. *Shall* tunniste. *None*.
”*Mutual*” tunnisteen sai klausuuli 4.4, *score*: 0.9995958, *Shall* tunniste.

Viimeiseksi otetaan tarkasteluun *Other* tunnisteella olevia satunnaisesti (ei *Shall*):
6.1, *score*: 0.9999571. identtiset, mutta ei normatiivinen, ei mitään pykälää, eli pelkkä otsikkoklausuuli. *Other*-tunniste on siispä osuva.

4.3.2 Makrotason validointi, kohdistustulokset ja yhteenveto

Käyttöliittymästä saatujen tulosten perusteella voidaan todeta, että ohjelmiston tuottamat similaarisuuspisteet ovat linjassa alkuperäisen aineiston kanssa: molemmat osoittavat dokumenttien välisen vastaavuuden olevan erittäin korkea. Analysoitujen klausuuliparien similaarisuus vaihtelee välillä 0,9152 - 0,9999 (asteikolla 0–1). Valtaosa pareista sijoittuu yli 0,99 similaarisuuteen, mikä tarkoittaa, että tekninen sanasto ja lauserakenteet ovat säilyneet lähes identtisinä versioiden välillä. Manuaalinen vertailu vahvistaa ohjelmiston havainnon: versioiden väliset erot ovat todellisuudessa vähäisiä. Tuloksista näkyi, että aineiston *Annex* osion vanhemmassa versiossa klausuuleja oli 114 ja uudessa 93 sekä se, että suurin muutos on dokumenttien välillä juuri *Annex* -osiossa.

Taulukkoon 4 on kirjattu kohdistustulokset, joiden yhteenveto ensinnä:

Tulosten perusteella järjestelmä suoriutui otoksen puitteissa parien muodostamisesta ja niiden puuttumisen tunnistamisesta virheettömästi. Otoksen kymmenestä klausuulista

yhdeksän (9) luokiteltiin todeksi positiiviseksi, sillä algoritmin ehdottama pari vastasi jokaisessa tapauksessa asiantuntijan tekemää arviota asiasisällöllisestä vastaavuudesta. Yksi 1 klausuuleista luokiteltiin todeksi negatiiviseksi (True Negative, TN), sillä järjestelmä jätti oikeaoppisesti yhdistämättä klausuulin A.6.2.1, jolle ei ollut todellista asiasisällöllistä vastinetta vertailtavassa versiossa. Sen lähin vastine olisi ollut niin paljon laajempi sisällöltään, ettei sitä voi pitää klausuulin suorana vastineena.

Järjestelmän kohdistusalgoritmi onnistui valitussa kymmenen satunnaistetun klausuulin otoksessa yhdistämään parit asiasisällöllisesti oikein ja välttämään virheelliset yhdistämiset, tuottamatta yhtään epätosia positiivisia tai negatiivisia tuloksia. Koska kohdeaineiston sisäinen leksikaalinen ja rakenteellinen samankaltaisuus on poikkeuksellisen korkea, tämä tulos antaa vahvan viitteen algoritmin perustoimivuudesta. On kuitenkin huomioitava, että kymmenen havainnon otoskoko ei mahdollista pitkälle meneviä tilastollisia yleistyksiä järjestelmän suorituskyvystä laajemmassa mittakaavassa. Tämän tutkimuksen puitteissa kokeellinen otos toimii ennen kaikkea teknisenä konseptin todentajana (*proof-of-concept*), joka osoittaa kehitetyn arkkitehtuurin soveltuvuuden sääntelytekstien analysointiin.

Taulukko 4:Yhteenveto vastaavuusanalyysin tuloksista

Klausuuli (Uusi / Vanha)	Similaarisuuspiste	Looginen suhde (NLI)	Normatiivisuus	Auditoitavuus	Kohdistustulos
7.4	0.9999694	A_implies_B	Shall	Kyllä	TP
9.3.1-9.3.3 (vs. 9.3)	0.9990512	None	Shall	Kyllä	TP
A.6.2.1	-	-	Shall	Kyllä	TN
5.1	0.9847204	None	Shall	Kyllä	TP
7.1	0.9999795	None	Shall	Kyllä	TP
A.9.2.4 (vs. (A) 5.17)				Kyllä	TP
6.1	0.9999571	None	Other	Kyllä	TP
4.4	0.9995958	Mutual	Shall	Kyllä	TP
5.2	0.9999047			Kyllä	TP
A.14.3.1 (vs. (A) 8.33)	0.9931299	None	Shall	Kyllä	TP

None ja *mutual* tunnisteet eivät *a_implies_b* tapaan näyttäneet toimivan niin hyvin. *None* ja *mutual* -tunnisteiden erot eivät olleet selkeitä.

Tuloksista narratiivi oli suunniteltu täysin luvun 3 mukaisesti, summaamaan erot ja similariteetit. LLM-narratiivi on todellisuudessa sivun mittainen, mutta julkisen tutkielman kontekstissa se jouduttiin jättämään pois tässä työssä, jo esitellyistä syystä aineistovalinnassa.

Näitä havaintoja ja niiden laajempaa sääntelyllistä merkitystä pohditaan syvällisemmin luvussa 5. Yhteenvetona luvun 4 kokeellisista tuloksista voidaan todeta, että kehitetyn järjestelmän analyysivoima ja käyttöliittymän tarjoama informaatioarvo perustuvat käyttäjälle sen modulaariseen rakenteeseen:

1. Vastaavuusanalyysi: Tarjoaa makrotason näkymän visuaalisena 3D-klusterigraafina ja kanonisina teksteinä, sekä mikrotason erittelyn klausuulikohtaisina vastaavuuspareina pisteytyksinä sekä loogisina tunnisteina.
2. Muutosanalyysi: Erottelee dokumenttien väliset tekstimuutokset kirurgisella sanatasolla ja luokittelee havainnot automaattisesti niiden semanttisen ja rakenteellisen laajuuden mukaan.
3. Narratiivi: Syntetisoi edellisten deterministisen vaiheiden löydökset ja tuottaa auditointivalmiin, suoraan alkuperäislähteisiin ankkuroituvan luonnollisen kielen yhteenvedon.

Ohjelmiston mikrotason validoinnin lisäksi yhdistelmäjärjestelmän käytettävyyttä ja asiantuntija-arvoa arvioitiin laadullisesti useissa interaktiivisissa esittelytilaisuuksissa kevään 2026 aikana. Järjestelmän analyysikykyä ja käyttöliittymän tarjoamaa informaatioarvoa demonstroitiin livenä sekä kohdeyrityksen (Taipuva Consulting Oy) edustajille että Tampereen yliopiston ohjaajille.

Esittelyissä keskityttiin erityisesti järjestelmän kykyyn tuottaa välitön visuaalinen näkymä standardiversioiden välisistä eroista, mikä perinteisesti vaatii sääntelyasiantuntijoilta päivien manuaalista työtä. Kohdeyritysten johdolta ja asiantuntijoilta saatu palaute vahvisti, että kehitetty autonominen analyysiputki tuottaa sellaista asiasisällöllistä lisäarvoa ja tarkkuutta, joka vastaa lääketieteellisen teknologian tiukkoja laadunvarmistusvaatimuksia, pohjana jatkokehitykselle moninaisiin *use-case* -tapauksiin.

5. KESKUSTELU JA JOHTOPÄÄTÖKSET

Tässä viimeisessä luvussa arvioidaan tutkimuksen keskeisiä tuloksia ja niiden merkitystä suhteessa asetettuihin tutkimuskysymyksiin sekä teoreettiseen viitekehykseen. Tutkimuksen tavoitteena oli kehittää ja validoida automatisoitu analyysialusta, joka kykenee tehostamaan terveydenhuollon sääntelyn hallittavuutta ja vähentämään asiantuntijoiden kokemaa regulaatiotaakkaa. Kehitetty "*Local-First*" -arkkitehtuuriin pohjautuva järjestelmä osoitti, että monimutkaisten ISO-standardien versiohallinta ja klausuulitason vastaavuusanalyysi on mahdollista toteuttaa tietoturvallisesti paikallisessa infrastruktuurissa kevyellä laitteistolla, tarjoten asiantuntijalle auditoitavan ja jäljitettävän lopputuloksen. Kokeellisen osion (Luku 4) tulosten perusteella tavoitteet luvusta 1, saavutettiin onnistuneesti. Myöhemmin luvussa pohditaan järjestelmän mahdollisuuksia ja esitetään suosituksia jatkokehitykselle terveysteknologian sääntelyn automatisoimiseksi.

5.1 Tulosten pohdinta ja johtopäätökset

Tässä tutkimuksessa saavutetut kokeelliset tulokset osoittavat, että kehitetty analyysialusta täyttää sille asetetut tekniset ja toiminnalliset tavoitteet sääntelyaineiston automatisoidussa käsittelyssä. Tutkimusprosessin aikana työn painopistettä tarkennettiin vastaamaan versionhallinnan erityishaasteisiin, minkä seurauksena tunnistettiin useita jatkokehitysmahdollisuuksia, jotka rajattiin tämän tutkielman ulkopuolelle sääntelyllisinä ja teknisinä laajennuksina. Aliluvuissa mennään yksityiskohtien kautta makropohdintaan.

Tämän painopisteen takia kanonisen tekstin merkitys jäi vähäiseksi aineistodokumenttien samankaltaisuuden takia, ja kaikki pohdinta perustuu vastaavuusanalyysin tuloksiin, jossa vertailtiin dokumentin eri versioita keskenään. 5.1.1 keskittyy vastaavuusanalyysin pohdintaan, kun 5.1.2 taas muutosanalyysin ja narratiivin johtopäätöksiin.

5.1.1 Teknisen samankaltaisuuden ja normatiivisen merkityksen väliset ristiriidat mikrotasolla

Tutkimuksen kokeellinen osio paljasti kriittisen jännitteen matemaattisen samankaltaisuuden ja sääntelyllisen merkityksen välillä, mikä korostuu erityisesti klausuulin 7.4 analyysissa. Vaikka "uusi" versio sisälsi huomattavan asiasisällöllisen muutoksen, kokonaisen prosessivaatimuksen (kohta e) poistamisen jota *cross-encoder* ei havainnut, vaan antoi korkean similariteetin. Tämä virheellinen luokitus on tyypillinen suurten kielimallien

ja ristiinkoodaajien taipumukselle "sokeutua" tekstin geneeriselle leksikaaliselle massalle. Similaarisuuden ja logiikan välinen jännite vastaavuusanalyysi-näkymässä: Vektoriavaruuteen perustuvat kielimallit ovat tunnetusti alttiita sokeutumaan tekstin pituudelle ja sanastolliselle päällekkäisyydelle (McCoy, Pavlick ja Linzen, 2019). Koska valtaosa klausuulin rakenteesta ja sanastosta säilyi identtisenä, algoritmin tuottama äärimmäisen korkea similaarisuuspiste (0,9999694) peitti alleen sääntelyllisesti merkittävän muutoksen. Uudessa versiossa klausuulia on vapaampi velvoite kuin vanhassa. Tämän kuitenkin huomasi NLI koneoppimismalli, juuri miksi se alun perin ohjelmaan suunniteltiinkin ja kategorisoi sen ”*a_implies_b*” - tunnistella.

Sääntelyteksteissä yksittäisen alakohdan puuttuminen tai lisääminen muuttaa usein koko vaatimuksen normatiivista laajuutta. Toimitetut kuvat "Vanha"- ja "Uusi"-dokumenttien klausuulista 7.4 tarjoavat erinomaisen tutkimusasetelman järjestelmän kognitiivisen prosessointikerroksen mittareiden arviointiin. Alkuperäinen "Vanha" versio sisältää viisi vaatimusta (a–e), kun taas "Uusi" versio tiivistää kohdan d) muotoon "*how to communica…*" ja poistaa kokonaan kohdan e) ("*the processes by which communication shall be* eff…").

Manuaalisesti tarkasteltuna:

Vanhempi versio on "auditointivarmempi". Se pakottaa organisaation nimeämään nimenomaisen vastuuroolin (kuka) ja kuvaamaan viestinnän osaksi prosessia, eikä vain satunnaiseksi toiminnaksi. Uusi muoto on selvästi vapaamuotoisempi. Vaikka muutos on kielellisesti pieni, se antaa organisaatiolle enemmän vapautta valita viestintätavat verrattuna vanhaan.

Todellisuudessa nämä kaksi eri versiota samasta klausuulista aineistossa ovat sisällöllisesti lähes identtisiä. Uusi versio on implisiittinen (olettaa, että "miten" sisältää "kenen"), vanha versio on vain tarkempi normatiivisesti.

Sääntelyn näkökulmasta pisteytys on kuitenkin vaarallisen harhaanjohtava, sillä yhden kokonaisen prosessivaatimuksen (kohta e) poistuminen on auditoinnin kannalta merkittävä poikkeama.

Siispä järjestelmän kriittinen varmistusmekanismi tässä oli DeBERTa NLI -tekoälymalli, joka asetti parille loogisen tunnisteen *a_implies_b* (Kuva 9). Tämä osoittaa järjestelmän kyvyn ymmärtää epäsymmetrisiä relaatioita: suppeampi "Uusi" klausuuli sisältyy loogisesti laajempaan "Vanha" klausuuliin, mutta ei toisinpäin. Tämä oli keskeinen, kiinnostava löydös.

Lämpökartta eli *heatmap* (Kuva 8) visualisoi onnistuneesti NLI-mallin havainnon: "Uusi" dokumentti saa klausuulin 7.4 kohdalla keltaisen merkinnän (PARTIAL), kun taas

"Vanha" saa vihreän merkinnän (COVERED). Tämä antaa asiantuntijalle välittömän signaalin siitä, että uusi versio ei kata vanhan version kaikkia vaatimuksia.

Eli toisin sanoen sama asia logiikan kielellä: Vanhan vaatimusten täyttäminen tarkoittaa automaattisesti myös uuden vaatimusten täyttämistä, koska se on sen tarkempi osajoukko. NLI *a_implies_b* toimi voimakkaana indikaattorina työssä, mutta muiden tunnisteiden kanssa oli ongelmia:

Molemminpuoliset suuntatunnisteet ("*none*", "*mutual*") eivät toimineet vahvoina substantiivisten lausekkeiden erojen indikaattoreina tässä työssä: ja hyvin samankaltaisissa, geneerisessä standarditeksteissä ne olivat huomattavasti vähemmän erottavia kuin similariteettipisteet ja suora tekstivertailu, kuten myös (McCoy, Pavlick ja Linzen, 2019) tutkimuksissa todetaan suuntatunnisteista. ISO-standardit ovat näille liian geneerisiä ja symmetrisiä, varsinkin kun puhutaan muutosanalyysistä. Ne toimisivat paremmin selkeämmin erilaisille standardeille kirjallisuuden mukaan. Ohjelmisto oli alun perin tarkoitettu monien erilaisten dokumenttien välille, joten fokuksen siirryttyä parien analysointiin, DI-työssä indikaattorit pidettiin edelleen samoina.

Mahdollisesti parempi indikaattori sääntelytekstien loogisten suhteiden ja erojen todentamiseen pareille olisi todennäköisesti vaatimusten atominen purkaminen (*Atomic Rule / Fact Decomposition*) yhdistettynä LLM-pohjaiseen asiantuntija-arviointiin (*LLM-as-a-Judge*). Tässä lähestymistavassa klausuulia ei verrata yhtenäisenä merkkijonona tai vektorina. (Min *ym.*, 2023)

Klusteroinnin onnistuminen nousi esiin yhtenä järjestelmän merkittävimmistä vahvuuksista erityisesti dokumenttien rakenteellisten muutosten hallinnassa. Kuten luvun 4 tuloksissa havaittiin, järjestelmä kykeni tunnistamaan tilanteen, jossa "uuden" version klausuuli 9.3.1 oli käytännössä sulauttanut itseensä alaklausuulit 9.3.2 ja 9.3.3. Tämän ansiosta algoritmi pystyi muodostamaan näistä semanttisen klusterin, joka vastasi onnistuneesti toisen asiakirjan laajempaa 9.3-klausuulia. Tämä havainto on analyysin kannalta kriittinen: standardien päivittyessä on tyypillistä, että vaatimuksia jaotellaan uudelleen, yhdistellään tai niiden numerointihierarkiaa muutetaan ilman, että varsinainen normatiivinen sisältö muuttuu merkittävästi. Tästä sulautumisesta tarvitaan jatkokehityksessä selvä tunniste analyysiraporttiin.

Parien löytämisen tehokkuus vielä lopuksi: vastaavuusanalyysin kvantitatiiviset tulokset osoittivat järjestelmän kyvykkyyden erinomaiseksi. Kokeellisessa otoksessa kohdistusalgoritmi saavutti täydellisen tarkkuuden ja saannin. Erityisen merkittävää oli järjestelmän kyky tunnistaa oikeaoppisesti vastineen puuttuminen (True Negative), mikä toden-

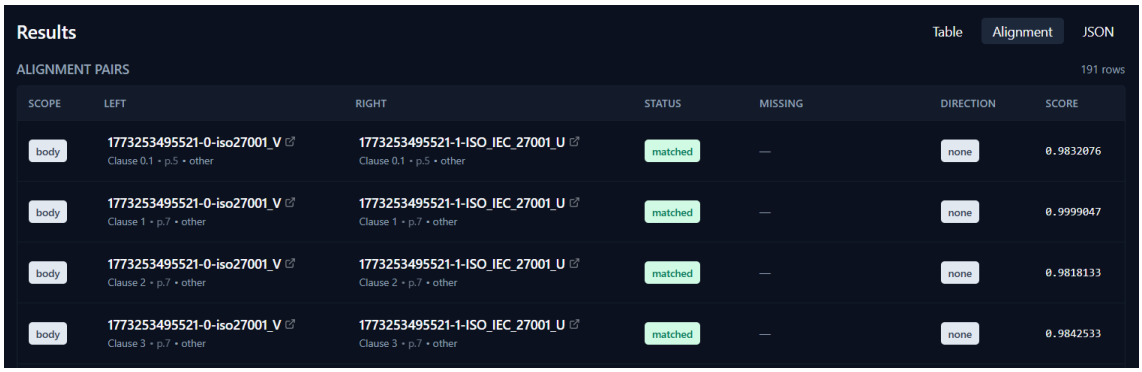
taa sen soveltuvuuden myös sääntelymuutosten aukkoanalyysiin (*gap analysis*). Tulevaisuudessa tämän ”parien tunnistuksen tarkkuutta” voidaan säätää, jolloin esimerkiksi tapaukset, missä uusi klausuuli kattaa vaikkapa puhelinten sijasta kaikki älylaitteet, voidaan löytää ”mahdolliseksi pariksi”, jonka käyttäjä sitten validoi lopuksi.

5.1.2 Makrotason havainnot ja johtopäätökset

Yhteenvetona vastaavuusanalyysi onnistui löytämään muodollisesti poistetut klausuulit, jotka olivat pääosin *Annex* osiossa, mutta näihin olisi ollut mielekästä tehdä myös klusterointi. *Annex* -osan klausuulien määrä on pienentynyt, joka ilmeni myös LLM narratiivista vastaavuusanalyysin lisäksi. Vanhemmassa versiossa niitä oli 114 ja uudessa 93.

Klausuulitason logiikan mikrotarkastelun lisäksi järjestelmän makrotason analyysi paljasti tärkeitä havaintoja algoritmien herkkyydestä sääntelytekstin rakenteellisille nyansseille. Erityisesti kommenttien, kuten huomautusten (*"note"*), käsittely osoittautui deterministisen samankaltaisuuslaskennan kannalta haastavaksi. Yksittäisen huomautuksen lisääminen uuteen versioon laski algoritmista saatavaa similaarisuuspistettä merkittävästi, vaikka klausuulin varsinainen velvoittava sisältö säilyi identtisenä. Koska tällaiset huomautukset voivat sääntelykontekstissa sisältää tulkinnan kannalta olennaista tietoa, niiden systemaattinen suodattaminen esikäsittelyvaiheessa voisi vaarantaa analyysin eheyden. Järjestelmä ei voi toimia autonomisena säädösmuutosten tulkitsijana, vaan sen rooli on toimia asiantuntijan huomiota suuntaavana ja analyysia nopeuttavana työkaluna. Mutta, kuten on todettu teoriassa (luvussa 2.5), neuroverkkojen logiikka on tilastollista päättelyä, eli se voi tehdä yleistäviä virheitä. None ja mutual tunnisteet olivat analyysin osa, joka tulee saamaan jatkokehityksessä erilaisen käyttökehyksen geneeriselle aineistolle.

Tehokkaana asiantuntijatyötä nopeuttavana strategiana havaittiin modaaliverbeihin perustuvan normatiivisuustunnistuksen hyödyntäminen. Järjestelmän tuottamien "*Shall*"- ja "*Other*"-tunnisteiden avulla käyttöliittymästä voitaisiin tiivistää erilliseen ”yleistä”-pakettiin ei-määräävät tekstiosiot, kuten dokumenttien soveltamisalat (*scope*) tai yleiset johdannot (Kuvassa 14). Tämä vähentäisi asiantuntijan kognitiivista kuormaa kohdistamalla huomion puhtaasti auditoitaviin velvoitteisiin. Ne olivat kaikki aineiston kannalta oikein validoiduissa klausuuleissa.



Kuva 14: Other-tunnisteen alle luokitellut ei-normatiiviset yleiset johdannot ja soveltamisalat (scope).

Sanatasoinen muutosanalyysi (*Diff*) osoittautui käytännön asiantuntijatyön kannalta järjestelmän ”kirurgiseksi” ominaisuudeksi, joka tulisi olla tarkastelussa seuraava vastaavuusanalyysin jälkeen. Luokittelun deterministisiin rajoihin liittyy kuitenkin sääntelyllistä tulkinnanvaraisuutta. Esimerkiksi klausuulin 7.4 kohdalla järjestelmä luokitteli eron puhtaasti tekstilliseksi (*textual*), koska valtaosa klausuulin tokeneista säilyi muuttumattomana. Kuten aiemmin luvussa 5.1.1 todettiin, juridisen ja normatiivisen merkityksen näkökulmasta poisto oli kuitenkin merkittävä, jolloin luokitus olisi voinut olla myös semanttinen (*semantic*). Tämä rajanveto korostaa sitä, että tekoälyn asettamat numeeriset kynnysarvot vaativat aina rinnalleen ihmisen suorittaman asiantuntija-arvion (*human-in-the-loop*). Ongelma muutosanalyysissä oli se, että se tulkitsi muuttuneeksi joitain välilyönti -tyyppisiä eroja, kuten ”*protection*” ja ”*pro- tection*”. Moduulin logiikkaan tarvitaan vielä lisää hiomista.

Diff-näkymä perkaa kuitenkin tekstimuutokset esiin kirurgisella tarkkuudella, yliviivaten poistetut osuudet ja korostaen lisäykset, mikä mahdollistaa asiantuntijalle nopean verifioinnin suoraan alkuperäislähteistä. Tällöin tekoäly ei enää ”väitä” asioita ilman perusteita, vaan se toimii kognitiivisena ohjaimena, joka kohdistaa asiantuntijan huomion sääntelymassan kriittisimpiin kohtiin säilyttäen täyden mekaanisen ja loogisen kontrollin käyttäjällä. Tämä korosti tutkimuskysymyksen 2 toteutumista yhdessä vastaavuusanalyysin kanssa, muutosvertailua voidaan tehostaa ohjelmiston avulla huomion suuntaamisen kautta tälläkin moodilla hyvin.

Deterministisen putken tuloksia kokoavan generatiivisen narratiivin (LLM) arviointi osoitti, että paikallinen, suhteellisen pieni 8 miljardin parametrin (8B) malli kykenee tuottamaan tiivistä synteesiä kohdistamaan huomiota makrotasoon, kun se ankkuroidaan huolellisesti esikäsiteltyyn aineistoon. Järjestelmän generoima narratiivi tiivisti dokumenttien väliset makrotason erot: se tunnisti uudemman version puutteet laajoissa teknisissä liitteissä ja nosti esiin keskeiset loogiset implikaatiosuhteet klausuuleissa 7.4 ja

6.1. Analyysialustan suorituskykytestaus (Luku 4.2) osoitti kiistatta, että vaativa tekoälyavusteinen sääntelyanalyysi on mahdollista toteuttaa täysin paikallisessa (*Local-First*) infrastruktuurissa kevyellä laitteistolla.

Narratiivin osuuden tieteellinen arvo ja luotettavuus perustuvat sen RAG-pohjaiseen arkkitehtuuriin: malli ei tuo yleisiä väitteitä suoraan standardeista, vaan sen tuottama teksti on suoraan johdettu ja sidottu deterministisen vastaavuusanalyysin antamiin faktoihin. Toisin sanoen generatiivinen tekoäly ei toimi järjestelmässä raakadatan ensisijaisena tulkitsijana, vaan analyysin viimeisenä, havainnollistavana kerroksena. Tämä lähestymistapa varmistaa, että asiantuntijalle tarjottu narratiivi on auditointivalmis, sillä se sisältää suorat viitteet alkuperäisiin lähteisiin, mikä mahdollistaa väitteiden välittömän verifioinnin.

Kaikkea koneoppimisen tuottamaa materiaalia pitää tarkastella kriittisesti, kuten todettiin jo tutkielman alussa, jota tämäkin pohdinta edustaa. Järjestelmän perimmäisenä tarkoituksena ei ole toimia autonomisena säädöstulkintoja tuottavana ”mustana laatikona”, vaan läpinäkyvänä analyysimoottorina, joka tukee asiantuntijan päätöksentekoa, vaikka prosessointiputki onkin automatisoitu. Tämä lähestymistapa vastaa suoraan EU:n tekoälyasetuksen asettamiin tiukkoihin vaatimuksiin. Ohjelmiston kehityksessä keskiöön on nostettu ihmisen suorittama valvonta, kuten asetuksen 14 artikla edellyttää: tekoälyjärjestelmä on suunniteltava siten, että luonnolliset henkilöt voivat tosiasiallisesti valvoa sen toimintaa ja ehkäistä automaatioharhaan liittyviä riskejä.

Käytännössä tämä valvontamahdollisuus toteutuu järjestelmän tarjoaman poikkeuksellisen jäljitettävyyden ja läpinäkyvyyden kautta. Esimerkiksi työssä kehitetty muutosanalyysi-näkymä on konkreettinen sovellus tekoälyasetuksen 13 artiklan mukaisesta läpinäkyvyysvaatimuksesta, joka velvoittaa järjestelmät toimimaan tavalla, jolla käyttäjä voi tulkita ulostulon alkuperän ja merkityksen. Ohjelmasta klausuuliparia klikkaamalla, aukeaa alkuperäinen dokumentti suoraan oikeasta kohdasta auki tehokkuuden maksimoimiseksi.

5.2 Yhteenveto tutkimuskysymyksistä

Tutkimuksen päätavoitteena oli selvittää, miten automatisoitu, useita eri tekoälyteknologioita ja determinismiä yhdistelevä analyysialusta voi tehostaa terveydenhuollon sääntelyaineiston hallintaa. Kokeellisen osion havainnot osoittavat, että kehitetty Yhdistelmätekoälyjärjestelmä kykenee autonomisesti tunnistamaan, luokittelemaan ja raportoimaan

standardien välisiä rakenteellisia ja sisällöllisiä eroja. Järjestelmä muuttaa sääntelyasiantuntijan roolin mekaanisesta tiedon etsijästä tulosten validoijaksi, mikä tehostaa sääntelytaakan hallintaa merkittävästi.

1. Pääkysymys arvioi algoritmisen muutostunnistuksen tehokkuutta. Kokeelliset tulokset osoittivat, että pelkkä matemaattiseen vektorisimilaarisuuteen nojaaminen on riittämätöntä sääntelytekstien analyysissa, sillä se on altis leksikaaliselle sokeutumiselle (kuten klausuulin 7.4 tapaus osoitti). Tämä kriittinen puute paikattiin kuitenkin onnistuneesti hybridimallilla, jossa deterministinen kohdistus yhdistettiin suunnatun loogisen päättelyn (Directional NLI) koneoppimismalliin. Tämä kahdennustekniikka kykeni tunnistamaan luotettavasti asymmetriset kattavuussuhteet ja normatiivisten vaatimusten erot, mikä on sääntelyanalyysin luotettavuuden ehdoton edellytys. Näiden mittarien vastaavuusanalyysin perusteella käyttäjä pystyi siirtymään muutosanalyysinäkymään mikrotason tekstilliseen erittelyyn, joka osoittautui hyödylliseksi muutostentulkinnan tehokkuuden kannalta.
2. Alakysymys 2 käsitteli lokaalin arkkitehtuurin suorituskykyä ja ohjelmistokehityksen teknisiä haasteita. Tutkimus osoitti, että kokeellinen "*Local-First*" -arkkitehtuuri on paitsi tietosuojan (GDPR) kannalta välttämätön, myös laskennallisesti täysin toteuttamiskelpoinen. Generatiiviset kanoniset tekstit ja narratiivi onnistuivat myös ilman internet yhteyttä ulkoisiin malleihin. Kokeellinen työkalu onnistuttiin rakentamaan määräajassa, joka kuvaa nykyisten metodien tehokkuutta ohjelmistokehityksessä.
3. Kolmas alakysymys keskittyi automaation luettavuuteen ja jäljitettävyyteen. Kehitetty järjestelmä välttää tekoälylle tyypillisen "musta laatikko" -ongelman ankkuroimalla kaikki generatiiviset havainnot suoraan lähdemateriaaliin (RAG-arkkitehtuuri). Pääosallinen analyysi eli vastaavuusanalyysi sekä myös LLM narratiivi sisälsi viitteet ja klikkaamalla oikeasta kohdasta alkuperäisen dokumentin avaamisen. Myös kaikki analyysit tallennettiin ajohistoriaan. Tämä tukee suoraan sääntelyn edellyttämää inhimillistä valvontaa (*human-in-the-loop*) ja ehkäisee automaatioharhaa tarjoamalla asiantuntijalle suorat viitteet alkuperäislähteisiin tulosten verifiointia varten.

Kvantitatiivisten tulosten osalta on syytä harjoittaa akateemista lähdekritiikkiä omaa tutkimusasetelmaa kohtaan. Vastaavuusanalyysissä saavutettu äärimmäinen tarkkuus ja saanti kymmenen klausuulin otoksessa on erinomainen tulos, mutta tilastotieteen näkökulmasta kymmenen havaintoa (n=10) altistaa tulokset varianssille. Tässä tutkimuk-

sessa satunnaisotos toimi siten pääosin laadullisena vahvistuksena sille, että ohjelmiston sisäinen logiikka (kuten a_implies_b -tunnistus) ohjautuu oikein. Laaja-alainen numeerinen luotettavuus edellyttäisi kuitenkin satojen klausuuliparien vertailua useiden eri standardien ja dokumenttien välillä.

5.3 Jatkokehitys

Kehitetyn ohjelmistoalustan modulaarinen arkkitehtuuri ja paikallinen toteutustapa luovat vankan pohjan järjestelmän jatkokehitykselle ja skaalaamiselle. Järjestelmän suunnittelussa on panostettu merkittävästi komponenttien väliseen riippumattomuuteen, mikä mahdollistaa yksittäisten osa-alueiden päivitykset ilman koko analyysiputken uudelleenrakentamista. Monia erilaisia osia on helppo rakentaa myöhemmin, kuten yksittäisen klausuulin LLM-tulkinta ja tunniste siitä, että onko tärkeää organisaation kannalta (perustuen lisämateriaaliin, joka olisi ajettu järjestelmään).

5.3.1 Tekninen skaalautuvuus ja mallien päivitykset

Järjestelmän skaalaaminen vaativampiin analyysitehtäviin on toteutettavissa suoraviivaisesti hyödyntämällä suurempia kielimalleja, joissa on laajennettu konteksti-ikkuna. Tämä parantaisi erityisesti narratiivisen raportoinnin laatua ja mahdollistaisi entistä laajempien dokumenttikokonaisuuksien samanaikaisen käsittelyn. Toisaalta tutkimus osoitti, että mikäli generatiivinen yhteenveto ei ole ensisijainen tavoite, itse luokittelumoottoria ja vastaavuusanalyysia ja tekoälytiivistelmiä klausuuleista voidaan ajaa kustannustehokkaasti myös CPU-pohjaisilla järjestelmillä.

5.3.2 Automaation syventäminen, auditointi ja muutosvahti

Tulevaisuuden kehityskohteena on siirtyminen staattisesta analyysista dynaamiseen sääntelyn seurantaan. Keskeisiä toiminnallisia laajennuksia tulevat olemaan:

Vaikutusarviointi (*Impact Analysis*) eli työkalu, joka analysoi automaattisesti, miten tietty säädösmuutos vaikuttaa organisaation olemassa olevaan dokumentaatioon. Sekä;

Sääntelyllinen muutosvahti: Automaattinen valvontamekanismi, joka seuraa säädösten päivityksiä ja ilmoittaa organisaatiolle niiden vaikutuksista sisäisiin prosesseihin.

Lisäksi järjestelmä voi jatkossa toimia virtuaalisena auditoijana, joka vertaa normatiivisia vaatimuksia (esim. lainsäädäntö) suoraan yrityksen tarjoamaan todistusaineistoon (esim. laatuohjeistus). Tämän perusteella ohjelmisto kykenee päättelemään, pitääkö aineistoa muuttaa ja millä tavoin.

LÄHTEET

”Article 27: Fundamental Rights Impact Assessment for High-Risk AI Systems | EU Artificial Intelligence Act” (2026). Saatavissa: https://artificialintelligenceact.eu/article/27/ (Viitattu: 8. helmikuuta 2026).

Article 51 - Classification of general-purpose AI models as general-purpose AI models with systemic risk (2025) *EU-ai*. Saatavissa: https://artificialintelligenceact.eu/article/51/ (Viitattu: 8. helmikuuta 2026).

”Article 53: Obligations for Providers of General-Purpose AI Models | EU Artificial Intelligence Act” (2025). Saatavissa: https://artificialintelligenceact.eu/article/53/ (Viitattu: 8. helmikuuta 2026).

Artzt, M. ja Dung, T.V. (2022) ”Artificial Intelligence and Data Protection: How to Reconcile Both Areas from the European Law Perspective”, *Vietnamese Journal of Legal Sciences*, 7(2), s. 39–58. Saatavissa: https://doi.org/10.2478/vjls-2022-0007.

AWS (2025) *Security considerations for data in generative AI - AWS Prescriptive Guidance*. Saatavissa: https://docs.aws.amazon.com/prescriptive-guidance/latest/strategy-data-considerations-gen-ai/security.html (Viitattu: 8. helmikuuta 2026).

Bartz v. Anthropic PBC, 3:24-cv-05417 - CourtListener.com (2024) *CourtListener*. Saatavissa: https://www.courtlistener.com/docket/69058235/bartz-v-anthropic-pbc/ (Viitattu: 25. helmikuuta 2026).

Bishop, C.M. (2006) *Pattern recognition and machine learning*. New York: Springer (Information science and statistics).

Bommasani, R. *ym.* (2021) ”On the Opportunities and Risks of Foundation Models”. arXiv. Saatavissa: https://doi.org/10.48550/ARXIV.2108.07258.

Bøgh, S.A. (2015) *A World Built on Standards*.

CEDPO AI Working Group (2023) ”Generative AI: The Data Protection Implications”. Saatavissa: https://cedpo.eu/wp-content/uploads/generative-ai-the-data-protection-implications-16-10-2023.pdf.

CEN - CEN/CLC/JTC 21 (2026). Saatavissa: https://standards.cencenelec.eu/ords/f?p=205:22:::::FSP_ORG_ID,FSP_LANG_ID:2916257,25&cs=114251C6C0B684FBBC069923513BF6348 (Viitattu: 15. toukokuuta 2026).

Chen, L., Zaharia, M. ja Zou, J. (2023) ”How is ChatGPT’s behavior changing over time?” arXiv. Saatavissa: https://doi.org/10.48550/ARXIV.2307.09009.

Chen, R. (2026) *EU AI Act Omnibus Amendment 2026: What the May 7 Deal Means for Medical Device Manufacturers*. Saatavissa: https://meddeviceguide.com/blog/eu-ai-act-omnibus-amendment-2026-medical-device-impact-guide (Viitattu: 15. toukokuuta 2026).

Christakis, T. (2019) ”Transfer of EU Personal Data to U.S. Law Enforcement Authorities After the CLOUD Act: Is There a Conflict with the GDPR?”, *SSRN Electronic Journal* [Preprint]. Saatavissa: https://ssrn.com/abstract=3397047.

Content Credentials : C2PA Technical Specification (2025). Saatavissa: https://spec.c2pa.org/specifications/specifications/2.2/specs/C2PA_Specification.html (Viitattu: 24. helmikuuta 2026).

Data Protection Commissioner v. Facebook Ireland Limited ja Maximillian Schrems (2020) *ECLI:EU:C:2020:559*. Saatavissa: https://eur-lex.europa.eu/legal-content/FI/TXT/?uri=CELEX:62018CJ0311 (Viitattu: 7. toukokuuta 2026).

Delétang, G. *ym.* (2023) ”Language Modeling Is Compression”. arXiv. Saatavissa: https://doi.org/10.48550/ARXIV.2309.10668.

European AI Standardization | *CEN-CENELEC JTC 21* | (2024). Saatavissa: https://jtc21.eu/ (Viitattu: 8. helmikuuta 2026).

European Commission’s use of Microsoft 365 infringes data protection law for EU institutions and bodies | *European Data Protection Supervisor* (2026). Saatavissa: https://www.edps.europa.eu/press-publications/press-news/press-releases/2024/european-commissions-use-microsoft-365-infringes-data-protection-law-eu-institutions-and-bodies_en (Viitattu: 12. maaliskuuta 2026).

European Health Data Space Regulation (EHDS) - Public Health (2025). Saatavissa: https://health.ec.europa.eu/ehealth-digital-health-and-care/european-health-data-space-regulation-ehds_en (Viitattu: 8. helmikuuta 2026).

European Medicines Agency (2024) *Reflection paper on the use of Artificial Intelligence (AI) in the medicinal product lifecycle*.

FDA Finalizes Guidance on Predetermined Change Control Plans for AI-Enabled Medical Device Software | *Insights* | *Ropes & Gray LLP* (2024). Saatavissa: https://www.ropesgray.com/en/insights/alerts/2024/12/fda-finalizes-guidance-on-predetermined-change-control-plans-for-ai-enabled-device (Viitattu: 8. helmikuuta 2026).

Friston, K. (2010) ”The free-energy principle: a unified brain theory?”, *Nature Reviews Neuroscience*, 11(2), s. 127–138. Saatavissa: https://doi.org/10.1038/nrn2787.

Frontier AI: capabilities and risks – discussion paper (2025) *GOV.UK*. Saatavissa: https://www.gov.uk/government/publications/frontier-ai-capabilities-and-risks-discussion-paper (Viitattu: 8. helmikuuta 2026).

Gao, Y. *ym.* (2023) ”Retrieval-Augmented Generation for Large Language Models: A Survey”. arXiv. Saatavissa: https://doi.org/10.48550/ARXIV.2312.10997.

Gerard, D. (2025) ”Deloitte Australia writes government report with AI — and fake references”, *Pivot to AI*, 28 elokuuta. Saatavissa: https://pivot-to-ai.com/2025/08/28/deloitte-australia-writes-government-report-with-ai-and-fake-references/ (Viitattu: 16. maaliskuuta 2026).

Grace, K. *ym.* (2025) ”Thousands of AI Authors on the Future of AI”, *Journal of Artificial Intelligence Research*, 84. Saatavissa: https://doi.org/10.1613/jair.1.19087.

Guest, G., Namey, E. ja Chen, M. (2020) ”A simple method to assess and report thematic saturation in qualitative research”, *PLOS ONE*. Toimittanut A. Soundy, 15(5), s. e0232076. Saatavissa: https://doi.org/10.1371/journal.pone.0232076.

Guidance for generative AI in education and research | *UNESCO* (2023). Saatavissa: https://www.unesco.org/en/articles/guidance-generative-ai-education-and-research (Viitattu: 8. helmikuuta 2026).

Gurman (2023) ”Samsung Bans Generative AI Use by Staff After ChatGPT Data Leak”, *Bloomberg.com*, 2 toukokuuta. Saatavissa: https://www.bloomberg.com/news/articles/2023-05-02/samsung-bans-chatgpt-and-other-generative-ai-use-by-staff-after-leak (Viitattu: 10. maaliskuuta 2026).

Harari, Y.N. (2015) *Sapiens: A Brief History of Humankind*. Kääntänyt H. Watzman ja J. Purcell. New York, NY: HarperCollins Publishers.

Hassabis, D. *ym.* (2017) ”Neuroscience-Inspired Artificial Intelligence”, *Neuron*, 95(2), s. 245–258. Saatavissa: https://doi.org/10.1016/j.neuron.2017.06.011.

He, K. *ym.* (2015) ”Deep Residual Learning for Image Recognition”. arXiv. Saatavissa: https://doi.org/10.48550/arXiv.1512.03385.

Heaton, J. (2018) ”Ian Goodfellow, Yoshua Bengio, and Aaron Courville: Deep learning: The MIT Press, 2016, 800 pp, ISBN: 0262035618”, *Genetic Programming and Evolvable Machines*, 19(1–2), s. 305–307. Saatavissa: https://doi.org/10.1007/s10710-017-9314-z.

ISO (2023) ”Information technology — Artificial intelligence — Management system”. Saatavissa: https://www.iso.org/standard/42001 (Viitattu: 8. helmikuuta 2026).

ISO (2024) ”Information technology — Artificial intelligence — Guidance on risk management”. Saatavissa: https://www.iso.org/standard/77304.html (Viitattu: 8. helmikuuta 2026).

Joint Artificial Intelligence Board (2025) ”Interplay between the Medical Devices Regulation (MDR) & In vitro Diagnostic Medical Devices Regulation (IVDR) and the Artificial Intelligence Act (AIA)”. Saatavissa: https://health.ec.europa.eu/document/download/b78a17d7-e3cd-4943-851d-e02a2f22bbb4_en.

Jones, C.R. ja Bergen, B.K. (2025) ”Large Language Models Pass the Turing Test”. arXiv. Saatavissa: https://doi.org/10.48550/ARXIV.2503.23674.

Kazzazi, F. (2021) ”The automation of doctors and machines: A classification for AI in medicine (ADAM framework)”, *Future Healthcare Journal*, 8(2), s. e257–e262. Saatavissa: https://doi.org/10.7861/fhj.2020-0189.

Kelly, G.A. (1991) *The psychology of personal constructs*. Facsim. ed. London New York: Routledge in association with the Centre for personal construct psychology.

Kim, R. (2025) ”What to Know About the $1.5 Billion Bartz v. Anthropic Settlement”, *Copyright Alliance*, 28 lokakuuta. Saatavissa: https://copyrightalliance.org/participating-bartz-v-anthropic-settlement/ (Viitattu: 16. maaliskuuta 2026).

Koreeda, Y. ja Manning, C. (2021) ”ContractNLI: A Dataset for Document-level Natural Language Inference for Contracts”, teoksessa M.-F. Moens ym. (toim.) *Findings of the Association for Computational Linguistics: EMNLP 2021*. *Findings 2021*, Punta Cana, Dominican Republic: Association for Computational Linguistics, s. 1907–1919. Saatavissa: https://doi.org/10.18653/v1/2021.findings-emnlp.164.

Korzybski, A. (2005) *Science and sanity: an introduction to non-Aristotelian systems and general semantics*. 5. ed., 3. print. Brooklyn, N.Y: Inst. of General Semantics.

Lasso Security (2023) *More than 1500 HuggingFace API Tokens Were Exposed*. Saatavissa: https://www.lasso.security/blog/1500-huggingface-api-tokens-were-exposed-leaving-millions-of-meta-llama-bloom-and-pythia-users-for-supply-chain-attacks (Viitattu: 7. toukokuuta 2026).

LeCun, Y., Bengio, Y. ja Hinton, G. (2015) ”Deep learning”, *Nature*, 521(7553), s. 436–444. Saatavissa: https://doi.org/10.1038/nature14539.

Lewis, P. *ym.* (2021) ”Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”. arXiv. Saatavissa: https://doi.org/10.48550/arXiv.2005.11401.

Lorenz, P., Perset, K. ja Berryhill, J. (2023) ”Initial policy considerations for generative artificial intelligence”, *OECD Artificial Intelligence Papers* [Preprint]. Saatavissa: https://doi.org/10.1787/fae2d1e6-en.

Masukume, G. (2024) ”The Impact of AI on Scientific Literature: A Surge in AI-Associated Words in Academic and Biomedical Writing”. Health Informatics. Saatavissa: https://doi.org/10.1101/2024.05.31.24308296.

McCoy, R.T., Pavlick, E. ja Linzen, T. (2019) ”Right for the Wrong Reasons: Diagnosing Syntactic Heuristics in Natural Language Inference”, *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*. *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, Florence, Italy: Association for Computational Linguistics, s. 3428–3448. Saatavissa: https://doi.org/10.18653/v1/P19-1334.

”MedTech Europe 2024 Regulatory Survey: key findings and insights” (2024) *MedTech Europe*. Saatavissa: https://www.medtecheurope.org/resource-library/medtech-europe-2024-regulatory-survey-key-findings-and-insights/ (Viitattu: 8. helmikuuta 2026).

Mehrabi, N. *ym.* (2022) ”A Survey on Bias and Fairness in Machine Learning”, *ACM Computing Surveys*, 54(6), s. 1–35. Saatavissa: https://doi.org/10.1145/3457607.

Miller, C. (2022) *Chip War: the fight for the world’s most critical technology*. London New York Sydney Toronto New Delhi: Simon & Schuster.

Min, S. *ym.* (2023) ”FActScore: Fine-grained Atomic Evaluation of Factual Precision in Long Form Text Generation”, *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, Singapore: Association for Computational Linguistics, s. 12076–12100. Saatavissa: https://doi.org/10.18653/v1/2023.emnlp-main.741.

Minsky, M. ja Papert, S. (1969) *Perceptrons: An Introduction to Computational Geometry*.

Moldovanska, E. (2025) *Microsoft: U.S. Access to EU Data Confirmed*. Saatavissa: https://www.convotis.com/en/news/microsoft-access-eu-data/ (Viitattu: 8. helmikuuta 2026).

Moravec, H. (1995) *Mind children: the future of robot and human intelligence*. 4. print. Cambridge: Harvard Univ. Press.

Müller, V.C. (2008) ”Margaret A. Boden, Mind as Machine: A History of Cognitive Science, 2 vols: Oxford University Press, Oxford, 2006, xlvii+1631, cloth $225, ISBN 0-19-924144-9”, *Minds and Machines*, 18(1), s. 121–125. Saatavissa: https://doi.org/10.1007/s11023-008-9091-9.

NCSC (2022) *Principles for the security of machine learning*. Guidance. United Kingdom: National Cyber Security Centre (NCSC). Saatavissa: https://www.ncsc.gov.uk/collection/machine-learning-principles.

Niiniluoto, I. (2002) *Critical scientific realism*. 1. publ. in pbk. Oxford: Oxford University Press (Clarendon library of logic and philosophy).

OECD (2023) *Health at a Glance 2023: OECD Indicators*. OECD Publishing (Health at a Glance). Saatavissa: https://doi.org/10.1787/7a7afb35-en.

OpenAI (2024) *March 20 ChatGPT outage: Here’s what happened*. Saatavissa: https://openai.com/index/march-20-chatgpt-outage/ (Viitattu: 10. maaliskuuta 2026).

”Overview of Guidelines for GPAI Models | EU Artificial Intelligence Act” (2025). Saatavissa: https://artificialintelligenceact.eu/gpai-guidelines-overview/ (Viitattu: 8. helmikuuta 2026).

Proposal for a regulation to simplify rules on medical and in vitro diagnostic devices - Public Health (2026). Saatavissa: https://health.ec.europa.eu/publications/proposal-regulation-simplify-rules-medical-and-vitro-diagnostic-devices_en (Viitattu: 9. maaliskuuta 2026).

Qazi, I.A. *ym.* (2025) ”Automation Bias in Large Language Model Assisted Diagnostic Reasoning Among AI-Trained Physicians”. Health Informatics. Saatavissa: https://doi.org/10.1101/2025.08.23.25334280.

Regulation (EU) 2024/1689 of the European Parliament and of the Council of 13 June 2024 laying down harmonised rules on artificial intelligence and amending Regulations (EC) No 300/2008, (EU) No 167/2013, (EU) No 168/2013, (EU) 2018/858, (EU) 2018/1139 and (EU) 2019/2144 and Directives 2014/90/EU, (EU) 2016/797 and (EU) 2020/1828 (Artificial Intelligence Act) (Text with EEA relevance) (2024). Saatavissa: http://data.europa.eu/eli/reg/2024/1689/oj (Viitattu: 8. helmikuuta 2026).

Regulation (EU) 2025/327 of the European Parliament and of the Council of 11 February 2025 on the European Health Data Space and amending Directive 2011/24/EU and Regulation (EU) 2024/2847 (Text with EEA relevance) (2025). Saatavissa: http://data.europa.eu/eli/reg/2025/327/oj (Viitattu: 8. helmikuuta 2026).

Report of the work undertaken by the ChatGPT Taskforce | European Data Protection Board (2024). Saatavissa: https://www.edpb.europa.eu/our-work-tools/our-documents/other/report-work-undertaken-chatgpt-taskforce_en (Viitattu: 8. helmikuuta 2026).

Rosenblatt, F. (1958) ”The perceptron: A probabilistic model for information storage and organization in the brain.”, *Psychological Review*, 65.

Rumelhart, D.E., Hinton, G.E. ja Williams, R.J. (2002) ”Learning Representations by Back-Propagating Errors”, teoksessa T. Polk ja C. Seifert (toim.) *Cognitive Modeling*. The MIT Press, s. 213–222. Saatavissa: https://doi.org/10.7551/mitpress/1888.003.0013.

Shumailov, I. *ym.* (2025) ”Author Correction: AI models collapse when trained on recursively generated data”, *Nature*, 640(8058), s. E6–E6. Saatavissa: https://doi.org/10.1038/s41586-025-08905-3.

Sun, J., Luo, Z. ja Li, Y. (2025) ”A Compliance Checking Framework Based on Retrieval Augmented Generation”, teoksessa O. Rambow ym. (toim.) *Proceedings of the 31st International Conference on Computational Linguistics*. *COLING 2025*, Abu Dhabi, UAE: Association for Computational Linguistics, s. 2603–2615. Saatavissa: https://aclanthology.org/2025.coling-main.178/ (Viitattu: 17. maaliskuuta 2026).

Tabassi, E. (2023) *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*. NIST AI 100-1. Gaithersburg, MD: National Institute of Standards and Technology (U.S.), s. NIST AI 100-1. Saatavissa: https://doi.org/10.6028/NIST.AI.100-1.

Umar, K. *ym.* (2025) ”Enhancing Regulatory Compliance Through Automated Retrieval, Reranking, and Answer Generation”, teoksessa T. Gokhan ym. (toim.) *Proceedings of the 1st Regulatory NLP Workshop (RegNLP 2025)*. Abu Dhabi, UAE: Association for Computational Linguistics, s. 91–96. Saatavissa: https://aclanthology.org/2025.regnlp-1.14/ (Viitattu: 8. helmikuuta 2026).

Vaswani, A. *ym.* (2017) ”Attention is All you Need”.

Wang, L. *ym.* (2024) ”A survey on large language model based autonomous agents”, *Frontiers of Computer Science*, 18(6), s. 186345. Saatavissa: https://doi.org/10.1007/s11704-024-40231-1.

Widder, D.G., West, S. ja Whittaker, M. (2023) ”Open (For Business): Big Tech, Concentrated Power, and the Political Economy of Open AI”. Rochester, NY: Social Science Research Network. Saatavissa: https://doi.org/10.2139/ssrn.4543807.

Wiz Research (2023) *38TB of data accidentally exposed by Microsoft AI researchers | Wiz Blog*, *wiz.io*. Saatavissa: https://www.wiz.io/blog/38-terabytes-of-private-data-accidentally-exposed-by-microsoft-ai-researchers (Viitattu: 7. toukokuuta 2026).

Xi, Z. *ym.* (2025) ”The rise and potential of large language model based agents: a survey”, *Science China Information Sciences*, 68(2), s. 121101. Saatavissa: https://doi.org/10.1007/s11432-024-4222-0.

Zaharia et al., (2024) *The Shift from Models to Compound AI Systems*, *The Berkeley Artificial Intelligence Research Blog*. Saatavissa: http://bair.berkeley.edu/blog/2024/02/18/compound-ai-systems/ (Viitattu: 8. helmikuuta 2026).